HFMM Thesis
Decision Log

High-Frequency Market Making with RL Under Different Volatility Regimes

KIT Financial Engineering MSc Thesis

Hakkında

Bu doküman, tez boyunca karşılaşılan her önemli karar noktasını, değerlendirilen seçenekleri ve alınan kararları kronolojik olarak kaydeder. Her yeni karar anında güncellenmesi amaçlanmıştır.

Format: WP | İkilem | Seçenekler | Alınan Karar | Neden | Etki

Kaynak: Claude Projects hafızası + ChatGPT konuşma geçmişi birleştirilerek oluşturulmuştur. Mart 2026.

WP0 — Proje Altyapısı

WP0	#1 Projeyi hemen RL olarak mı kuralım, yoksa önce altyapı mı?
İkilem	Hızlıca RL kodu yazmaya başlamak ile reproducible, izlenebilir bir pipeline kurmak arasında seçim.
Seçenekler	A) Direkt RL script yaz | B) Önce run_id / config snapshot / log / seed sistemi kur
Karar	B — Önce research-grade altyapı kuruldu.
Neden	Sonradan toparlamak imkansız olurdu. run.py, RunContext, CSVMetricLogger, meta.json, git commit hash sistemi baştan kuruldu.
Etki	Tüm WP'ler boyunca her deney otomatik loglandı, tekrarlanabilir oldu. 'Pilot phase' anlatısı bu altyapı sayesinde savunulabilir hale geldi.

WP0	#2 Proje yapısı: tek script mi, work-package disiplini mi?
İkilem	Hızlı prototipleme için tek dosyada çalışmak mı, yoksa config/ src/wp1/ results/runs/ ayrımı mı?
Seçenekler	A) Tek büyük script | B) WP bazlı modüler yapı + JSON config sistemi
Karar	B — config/, src/wpX/, results/runs/, data/processed/ ayrımı benimsendi.
Neden	Her WP'nin bağımsız test edilebilmesi ve ileride job_entry() ile çağrılabilmesi için zorunluydu.
Etki	run.py dispatcher sistemi: hangi config verilirse o iş paketi çalışıyor. Tüm deneyler izole, karşılaştırılabilir.

WP1 — Baseline Stratejiler

WP1	#3 RL'yi tek başına mı kuralım, yoksa güçlü baseline'larla mı çevreleyeyim?
İkilem	RL ajanı hemen eğit ve sonuçlara bak, yoksa önce 2 klasik baseline implement et?
Seçenekler	A) Direkt PPO'ya geç | B) Naive symmetric + Avellaneda-Stoikov baseline zorunlu kıl
Karar	B — Her iki baseline tamamlanmadan WP3'e geçilmedi.
Neden	RL'nin 'ne kadar iyi' olduğunu söyleyebilmek için referans nokta şart. AS, inventory-aware analitik çözüm olarak güçlü bir üst sınır sağladı.
Etki	PPO ~4x Sharpe ile baseline'ları geçince bu sayıların anlamlı bir referansı oldu.

WP1	#4 Fill modelini basit mi, yoksa intensity tabanlı mı yapalım?
İkilem	Sabit fill olasılığı kullanmak mı (kolay), yoksa $\lambda(\delta) = A \cdot \exp(-k \cdot \delta)$ Poisson modeli mi?
Seçenekler	A) Sabit p=0.5 fill | B) $\lambda(\delta) = A \cdot \exp(-k \cdot \delta)$, $P = 1-\exp(-\lambda \cdot dt)$
Karar	B — Intensity tabanlı Poisson modeli seçildi.
Neden	Market making literatürünün omurgası bu modeldir (Avellaneda-Stoikov, 2008). Fee ve latency de eklendi. Projenin kimliğini belirleyen temel karardı.
Etki	AS'nin analitik formülleri de bu modeli varsayıyor. Model tutarlılığı sağlandı. Tez akademik literature dayandı.

WP1 / WP3 — Geçiş Kararları

WP1/WP3	#5 RL aksiyonunu buy/sell/hold mu, yoksa spread+skew olarak mı tanımlayalım?
İkilem	Action space'i basit yön kararı (al/sat/bekle) mı, yoksa market-maker mantığıyla spread ve skew mi?
Seçenekler	A) Discrete: al/sat/bekle | B) MultiDiscrete([5,5]): $h \in \{1..5\}$ ticks, $m \in \{-2..+2\}$ ticks
Karar	B — Half-spread h ve skew m olarak tanımlandı.
Neden	Market making'de karar spread genişliği ve inventory lean'dir, yön değil. Bu parametrizasyon AS ile doğal karşılaştırma imkanı verdi.
Etki	25 aksiyonlu action space, hem agresif hem pasif quoting'i kapsıyor. Inventory yönetimi doğal biçimde modellenebildi.

WP2 — Sentetik Rejim Tespiti

WP2	#6 Gerçek piyasa verisi mi, kontrollü sentetik dünya mı?
İkilem	Real market data kullanmak mı (proposal'da vardı), yoksa synthetic controlled environment mı?

Seçenekler	A) Yahoo Finance / gerçek HFT verisi | B) ABM + Markov chain, tamamen sentetik
Karar	B — Tamamen sentetik veri seçildi.
Neden	Seed/reproducibility ile aynı yolu tüm ajanlara göstermek, ve hangi farkın rejim bilgisinden geldiğini temiz izole etmek için zorunluydu. Real data confounding factor yaratırdı.
Etki	Tüm karşılaştırmalar aynı exog seri üzerinde yapıldı. Null result'ın 'gerçek piyasa gürültüsü' diye açıklanması engellendi.

WP2	#7 Rejimleri nasıl tanımlayacağız?
İkilem	HMM/GARCH gibi ağır istatistiksel model mi, yoksa rolling realized volatility ile basit threshold mı?
Seçenekler	A) HMM veya GARCH | B) Rolling RV (window=50) + warmup percentile threshold
Karar	B — Rolling RV baseline olarak seçildi; HMM sonradan robustness kontrolü için eklendi.
Neden	'Yorumlanabilirlik ve no-look-ahead' kriterleri öne çıktı. Rolling RV mekanizması şeffaf, implement etmesi hızlı.
Etki	rv_baseline %60.7, hmm %81.8 doğrulukla eklendi. İkisinde de null result → detektör kalitesi açıklaması elenirdi.

WP2	#8 WP2 accuracy %33 çıkınca ne yapacağız?
İkilem	İlk denemede detection accuracy rastgele seviyedeydi (%32.6). Devam mı, düzelt mi?
Seçenekler	A) Bu accuracy ile devam et | B) Timescale mismatch'i teşhis et, parametreleri düzelt
Karar	B — Kök neden bulundu: rv_window çok büyük, transition matrix hızlı geçişli.
Neden	rv_window=100 iken rejim süresi ~10 adımdı. Pencere birden fazla rejimi kapsıyordu. Sticky matrix + window=50 + warmup=1000 ile accuracy %60.7'ye çıktı.
Etki	WP2'nin gerçekten 'bitti' diyebildiğimiz nokta bu fix oldu. Threshold gap 5x genişledi.

WP2	#9 Sigma çarpanlarını ne kadar sert ayarlayalım?
İkilem	Project notes'ta [0.5, 1.0, 2.0] yazıyordu; son config'de [0.6, 1.0, 1.8] — neden yumuşattık?
Seçenekler	A) Sert ayrım [0.5, 1.0, 2.0] | B) Daha makul yakınlık [0.6, 1.0, 1.8]
Karar	B — [0.6, 1.0, 1.8] olarak yumuşatıldı.
Neden	Rejimlerin fazla kolay ayırt edildiği 'yapay dünya' yerine biraz daha gerçekçi, biraz belirsiz bir ortam hedeflendi.
Etki	Detection zorlaştı ama daha gerçekçi oldu. Bu ayrım tez metodoloji bölümünde savunulabilir.

WP3 — Gymnasium Environment

WP3	#10 Rejim bilgisini ajana açıkça verelim mi?
İkilem	sigma_hat zaten observation'da varken regime one-hot eklemek gerçekten yeni bilgi mi katıyor?
Seçenekler	A) Sadece sigma_hat ver | B) Hem sigma_hat hem regime one-hot ver; ablation ile test et
Karar	B — İkisi de verildi, sonra adil ablation ile karşılaştırıldı.
Neden	Bu soruyu baştan sormak tezin ana hipoteziydi. Ablation ile test zorunluydu.
Etki	Null result'ın kök nedeni bu karar sayesinde açıklandı: blind ajan sigma_hat'ten rejimi implicitly öğrenebildi.

WP3	#11 Reward saf PnL mi, yoksa inventory penalty ekleyelim mi?
İkilem	$R = \Delta Equity$ mi, yoksa $R = \Delta Equity - \eta \cdot inv^2$ mi?
Seçenekler	A) Saf PnL reward | B) $PnL - \eta \cdot inv^2$ quadratic penalty
Karar	B — Quadratic inventory penalty eklendi.
Neden	Saf PnL'de ajan inventory biriktirip büyük tek taraflı bahis oynayabilir. Penalty, gerçek market-maker davranışını (risk-neutral quoting) özendirir.
Etki	η ablation ile optimal değer η=0.001 bulundu. Reward shaping tezin önemli bir metodolojik katkısı oldu.

WP3	#13 PPO'ya geçmeden önce sanity check zorunlu mu?
İkilem	Env doğruluğunu test etmeden PPO eğitimine başlamak mı, yoksa önce WP1 ile karşılaştırma mı?
Seçenekler	A) Direkt PPO'ya geç | B) naive_h2 sonucunun WP1 sim ile eşleştiğini doğrula
Karar	B — WP3 sanity check yapıldı; gym naive_h2 ≈ sim naive_h2 onaylandı.
Neden	Env yanlışsa PPO sonuçları anlamsız olurdu. Özellikle exog mid injection ve reward hesabı hata riskiydi.
Etki	PPO sonuçlarına güven arttı. Sonradan PPO başarısız olsaydı 'env mi bozuk?' sorusu elenmiş oldu.

WP4 — PPO Training

WP4	#14 İlk RL koşusunu final sonuç gibi mi okuyalım?
İkilem	WP4'te tek seed, 200K ts ile aware >> blind çıktı. Bu tezi kanıtlıyor mu?
Seçenekler	A) Sonucu kabul et, tezi yaz | B) Pilot say, çok seed ile OOS protokolü kur
Karar	B — WP4 sonucu pilot olarak etiketlendi.
Neden	Tek seed, in-sample, 200K timesteps çok yetersiz. Akademik güvenilirlik için OOS + çok seed zorunluydu.
Etki	WP5 tasarımı buradan şekillendi: 20 seed, train/test split, 1M timesteps.

WP4 / WP5 — Geçiş Kararları

WP4-WP5	#15 WP4 ayarlarını final mı, pilot mu sayacağız?
İkilem	total_timesteps=200K, ent_coef=0.0, η=0.01 ile başlanmıştı. Bunlar ana deney ayarları mı?
Seçenekler	A) Bu ayarlarla devam et | B) Pilot say, daha uzun training + exploration ile tekrarla
Karar	B — WP5 main için 1M timesteps + ent_coef=0.01 + η=0.001 seçildi.
Neden	Düşük exploration (ent_coef=0.0) ile ajan erken converge ediyor olabilirdi. 200K ts ile policy olgunlaşmamış olabilirdi.
Etki	Ana deney ayarları: total_timesteps=1M, ent_coef=0.01, η=0.001. Bu config w5_main.json'a sabitlendı.

WP5 — Out-of-Sample Evaluation

WP5	#16 OOS protokolüne geçiş: in-sample iyi görünmek yeterli mi?
İkilem	Eğitim verisinde iyi performans = başarılı tez mi?
Seçenekler	A) In-sample değerlendirme | B) train_frac=0.7, OOS test split, seed bazlı model eğitimi
Karar	B — train_frac=0.7 ile out-of-sample protokol kuruldu.
Neden	In-sample overfitting akademik olarak kabul edilmez. Projenin 'oyuncak demo'dan 'araştırma deneyi'ne geçiş noktasıydı.
Etki	Null result OOS'ta çıktı. Bu sonucun güvenilirliği OOS protokolüne dayanıyor.

WP5	#17 WP5'te hangi naive baseline'ı sabitleyeceğiz?
İkilem	Naive sweep vardı (h=1..5). OOS karşılaştırma için tek sabit bir naive gerekiyordu.
Seçenekler	A) h=1 (çok agresif) | B) h=2 (orta) | C) h=3 (pasif)
Karar	h=2, m=0 — orta nokta seçildi.
Neden	WP1 sweep'te h=2 en dengeli performansı verdi; ne aşırı agresif ne aşırı pasif.
Etki	Tüm karşılaştırmalarda naive referans noktası h=2 tick sabit spread oldu.

WP5	#18 Kaç seed yeterli?
İkilem	3 seed ile variance gözlemlendi, ama hüküm vermek için yetmiyordu.
Seçenekler	A) 3 seed pilot — devam et | B) 20 seed ana deney
Karar	B — 20 seed ana deney olarak çalıştırıldı.
Neden	Statistical test için minimum sample gerekiyordu. 3 seed ile p-value anlamlı olmaz. 20 seed paired t-test için yeterli.
Etki	20 seed ile Sharpe p=0.261 (inconclusive), equity p=0.023 (ppo_blind lehine). Null result sağlam statistiksel temele oturdu.

WP5	#19 ppo_aware varyansı görünce ilk neyi tune edeceğiz?
İkilem	Yüksek variance'ın pek çok olası nedeni vardı: timesteps, exploration, reward, obs clipping...
Seçenekler	A) Direkt timesteps artır | B) Önce η ablation ile reward scale'i doğru ölçeğe otur
Karar	B — Eta ablation önceliklendirildi; η=0.001 optimal bulundu.
Neden	Reward yanlış ölçekte olursa hiçbir hyperparameter tuning anlamlı olmaz. Temeli önce sağlamlaştır.
Etki	η=0.001 tüm main experiment konfigürasyonuna taşındı. Ablation tablosu tez metodoloji bölümüne girdi.

WP5	#20 Timesteps ve exploration'ı büyütelim mi?
İkilem	200K / ent_coef=0.0'dan ana deneye geçişte ne değişmeli?
Seçenekler	A) Sadece seed sayısını artır | B) 1M timesteps + ent_coef=0.01
Karar	B — Her ikisi birlikte artırıldı.
Neden	Aware ajan çok erken ve zayıf explore ederek dengesiz policy öğrenmiş olabilirdi. Daha fazla training + exploration bu riski azaltır.
Etki	Ana deney fair attempt oldu. Null result daha güçlü: 'yeterince eğitilmedi' itirazı geçersiz.

WP5	#21 Regime-wise raporlama opsiyonel mi, zorunlu mu?
İkilem	Toplam equity metriği yeterli mi, yoksa L/M/H bazında breakdown şart mı?
Seçenekler	A) Sadece toplam metrikler | B) Per-regime Sharpe, fill rate, inv_p99 tablosu
Karar	B — Regime-wise raporlama zorunlu kılındı.
Neden	Tezin ana sorusu rejim farkıyla ilgili. Aware ajan gerçekten farklı davranıyorsa bu L/M/H kırılımında görünmeliydi.
Etki	metrics_wp5_oos_by_regime.csv üretildi. Action analysis'te regime-bazlı h/m dağılımı tezin önemli bulgularından biri oldu.

WP5	#22 Action analysis'te varyansı nasıl ölçeceğiz?
İkilem	Error bar'lar within-seed std mi, cross-seed std mi göstermeli?
Seçenekler	A) Her seed için std hesapla, ortalamasını göster | B) Seed-level aggregation + cross-seed std
Karar	B — analyze_actions.py'de _seed_level_stats eklendi, cross-seed std'ye geçildi.
Neden	Within-seed std bize stratejinin tek bir koşudaki dalgalanmasını verir, ama güvenilirliği ölçmez. Cross-seed std 'farklı piyasalarda ne kadar tutarlı' sorusunu yanıtlar.
Etki	Grafik paper-ready hale geldi. P(h=5) undertrading göstergesi de aynı şemaya eklendi.

WP5	#23 20-seed null result sonrasında ne yapacağız?
İkilem	aware ≈ blind çıktı. Tezi 'başarısız' mı sayacağız, yoksa null result'ı savunacak mıyız?
Seçenekler	A) Daha fazla timestep / farklı mimari dene | B) Null result'ı temel bulgu olarak konumlandır + detector robustness ile destekle
Karar	B — Null result akademik bulgu olarak sahiplenildi; 3 detector x 20 seed robustness deneyi eklendi.
Neden	sigma_hat zaten observation'da olduğu için explicit regime label redundant — bu güçlü ve özgün bir akademik argüman. Pilot (3 seed) sonuçları: rv_baseline aware=0.850 vs blind=0.814, rv_dwell aware=0.804 vs blind=0.814, HMM aware=0.713 vs blind=0.814. HMM %81.8 doğrulukla bile aware geride — 'düşük detection accuracy' açıklaması elendi.
Etki	Detector robustness full run başlatıldı (120 model). Argüman güçlendi: null result detection kalitesinden bağımsız, signal redundancy temel açıklama.

WP5	#24 Detector robustness full run'ı başlatmak: pilot yeterli mi?
İkilem	3-seed pilot null result'ı tüm detectorlarda gösterdi. Full 120-model run'a gerek var mı?
Seçenekler	A) Pilot (3 seed) yeterli, null result kabul et | B) Full run: 3 detector x 20 seed x 2 strateji = 120 model
Karar	B — Full run başlatıldı. Config: w5_detector_full.json. CPU, tahmini ~70-80 saat.
Neden	Pilot'ta sadece 3 seed var — istatistiksel güç yetersiz. Paired t-test için her detector'da 20 seed gerekiyor. HMM %81.8 ile bile null result çıkıyorsa çok güçlü bir argüman ama 20 seed olmadan savunmak zor.
Etki	Full sonuçlar gelince her detector için ayrı paired t-test yapılacak. 'Detection quality değil, signal redundancy' argümanı istatistiksel olarak sağlamlaşacak (veya çürüyecek).

Genel Proje Kararları

Genel	#25 Yazmaya hemen başlayalım mı, yoksa önce araştırmayı derinleştirelim mi?
İkilem	Mezun olmak için tez yeterli mi, yoksa paper hedefiyle daha derinlemesine mi gidilmeli?
Seçenekler	A) Erken yaz, mezun ol | B) Önce hikayeyi netleştir, karar/deney öncelikli yürüt
Karar	B — Araştırma derinleştirildi; yazım ikincil tutuldu.
Neden	Supervisor ile paper hedefi konuşulmuştu. Null result'ı güçlü kılmak (detector robustness, action analysis, regime-wise) önce tamamlandı.
Etki	Tez hem MSc tezi hem paper taslağı olarak konumlandı. Uzun vadeli plan: A, k parametrelerini regime'e bağlamak.

WP5 — Ablasyon ve İleri Analizler

WP5	#26 Ablasyon tasarımı: kaç varyant yeterli?
İkilem	aware vs blind ikili karşılaştırması yeterliydi, ama danışman "σ̂ her ikisinde de var, bu confounded" dedi. Kaç varyant tasarlayalım?
Seçenekler	A) 2 varyant: aware vs blind | B) 5 varyant: sigma_only, regime_only, combined, oracle_pure, oracle_full
Karar	B — 5 varyant tasarlandı ve 20 seed ile eğitildi.
Neden	Danışmanın confounding eleştirisini doğrudan yanıtlamak için σ̂'yi tamamen çıkaran (regime_only, oracle_pure) ve mükemmel rejim bilgisi veren (oracle_pure, oracle_full) varyantlar gerekiyordu.
Etki	Oracle paradoksu ortaya çıktı: oracle_full (Sharpe: 0.722), sigma_only'yi (Sharpe: 0.753) geçemedi. Bu, null result'ın en güçlü kanıtı oldu.

WP5	#27 Oracle paradoksu: anomali mi, bulgu mu?
İkilem	oracle_full sigma_only'den daha düşük Sharpe aldı. Bu bir bug mı yoksa gerçek bir akademik bulgu mu?
Seçenekler	A) Kodu kontrol et, bug ara | B) Bulgu olarak kabul et, istatistiksel olarak doğrula
Karar	B — Önce kod doğrulandı (bug yok), sonra paired t-test ile p=0.301 (Sharpe), p=0.360 (equity) bulundu — istatistiksel olarak anlamlı fark yok.
Neden	Mükemmel rejim bilgisi bile sigma_only'yi geçemiyorsa bu signal redundancy'nin doğrudan kanıtı. Anomali değil, tezin temel argümanının en sert testi.
Etki	"Oracle paradoksu" tezin kritik bulgularından biri olarak konumlandırıldı. Danışmanın confounding eleştirisine nihai yanıt verildi.

WP5	#28 Detector robustness full run tamamlandı: sonuç ne?
İkilem	Full run (3 detector × 20 seed × 2 strateji = 120 model) tamamlandı. Sonuçlar pilot ile tutarlı mı?
Seçenekler	A) Pilot yeterliydi, full run gereksizdi | B) Full run null result'ı istatistiksel olarak güçlendirdi
Karar	B — rv_baseline p=0.114, rv_dwell p=0.110, HMM p=0.082 (hepsi anlamlı değil). ANOVA: F=0.003, p=0.997.
Neden	%81.8 doğruluklu HMM ile dahi null result korunuyor. "Detection kalitesi düşük olduğu için null çıktı" itirazı tamamen elendi.
Etki	Null result üç bağımsız dedektörde tutarlı — signal redundancy argümanı istatistiksel olarak sağlam.

Genel Proje Kararları — Tez Yazım Süreci

Genel	#29 Bonferroni düzeltmesi: kaç karşılaştırma sayacağız?
İkilem	Ablasyon tablosunda 10 satır var ama script başlangıçta α=0.01/12=0.00083 kullanıyordu. Doğru payda ne?
Seçenekler	A) 12 kullan (6 karşılaştırma × 2 metrik) | B) 10 kullan (gerçek satır sayısı)

Karar	B — α=0.01/10=0.001 olarak düzeltildi.
Neden	Tabloda fiilen 10 karşılaştırma var; payda gerçek test sayısıyla eşleşmeli. Pratik etki ihmal edilebilir (tüm "EVET" kararları aynı kaldı) ama iç tutarlılık zorunlu.
Etki	thesis_15 → thesis_16 geçişinde düzeltildi. İstatistiksel doğruluk sağlandı.

Genel	**#30 "Kanıtlamaktadır" dili: çok güçlü mü?**
İkilem	Tezde "rejim etiketinin bilgiyi yedekli sunduğunu kanıtlamaktadır" gibi ifadeler vardı. Sentetik ortamda bu kadar kesin dil uygun mu?
Seçenekler	A) Güçlü dili koru, bulgunun ağırlığını vurgula | B) "Tutarlıdır", "güçlü kanıt sunar" gibi epistemik açıdan daha doğru ifadeler kullan
Karar	B — Tüm "kanıtlamaktadır" ifadeleri yumuşatıldı.
Neden	Ampirik çalışmalarda "kanıtlar" yerine "destekler/ile tutarlıdır" akademik standarttır. Danışman ve hakem yorumunda bu fark kritik olabilir.
Etki	thesis_16'da dil tutarlı ve savunulabilir hale geldi.

Genel	**#31 Şekil numaraları kaydı: nasıl önleriz?**
İkilem	PNG dosyaları (fig3_regime_sharpe, fig4_detector_robustness, fig5_action_analysis) yanlış şekil açıklamalarına eşleştirilmişti.
Seçenekler	A) Manuel kontrol her sürümde | B) Script'te şekil-açıklama eşleşmesini yorumla belgele
Karar	B — gen_thesis scripti her add_picture() çağrısına açıklayıcı yorum eklendi. thesis_16'da düzeltme yapıldı.
Neden	Şekil kayması okuyucuya "tez acele toparlanmış" izlenimi verir. Akademik belgede görsel-metin tutarlılığı zorunlu.
Etki	thesis_16 ile tüm 5 şekil doğru yerleşti. Versiyon kontrol yorumları eklendi.

Özet: En Kritik 12 Karar

ChatGPT ve Claude'un ortak değerlendirmesine göre tezin seyrini en çok etkileyen kararlar:

#	Karar	WP
1	Research-grade pipeline kurmak	WP0
2	Naive + AS baseline'larını zorunlu kılmak	WP1
3	Synthetic controlled market seçmek	WP2
4	Rolling RV + no-look-ahead rejim tespiti	WP2
5	Aksiyonu spread + skew olarak tanımlamak	WP3
6	Reward'ı PnL − $\eta \cdot inv^2$ yapmak	WP3
7	Aware vs blind'ı adil observation ablation olarak kurmak	WP3/WP5
8	OOS + çoklu seed + eta tuning + null result sahiplenmek	WP5
9	Detector robustness full run (120 model) — signal redundancy argümanını kanıtlamak	WP5
10	5 varyantlı ablasyon + oracle paradoksu	WP5
11	Detector robustness full run (120 model) null result teyidi	WP5
12	Dil yumuşatma + istatistiksel iç tutarlılık (Bonferroni, şekil sırası)	Yazım