

HFMM Thesis

Decision Log

High-Frequency Market Making with RL Under Different Volatility Regimes

KIT Financial Engineering MSc Thesis
Nisan 2026 — Sürüm 28

Hakkında

Bu doküman, tez boyunca karşılaşılan her önemli karar noktasını, değerlendirilen seçenekleri ve alınan kararları kronolojik olarak kaydeder. Her yeni karar anında güncellenmesi amaçlanmıştır.

Format: WP | İkilem | Seçenekler | Alınan Karar | Neden | Etki

Kaynak: Claude Projects hafızası + ChatGPT konuşma geçmişi birleştirilerek oluşturulmuştur. Mart 2026.

WP0 — Proje Altyapısı

WP0	#1 Projeyi hemen RL olarak mı kuralım, yoksa önce altyapı mı?
İkilem	Hızlıca RL kodu yazmaya başlamak ile reproducible, izlenebilir bir pipeline kurmak arasında seçim.
Seçenekler	A) Direkt RL script yaz B) Önce run_id / config snapshot / log / seed sistemi kur
Karar	B — Önce research-grade altyapı kuruldu.
Neden	Sonradan toparlamak imkansız olurdu. run.py, RunContext, CSVMetricLogger, meta.json, git commit hash sistemi baştan kuruldu.
Etki	Tüm WP'ler boyunca her deney otomatik loglandı, tekrarlanabilir oldu. 'Pilot phase' anlatısı bu altyapı sayesinde savunulabilir hale geldi.

WP0	#2 Proje yapısı: tek script mi, work-package disiplini mi?
İkilem	Hızlı prototipleme için tek dosyada çalışmak mı, yoksa config/ src/wp1/ results/runs/ ayrımı mı?
Seçenekler	A) Tek büyük script B) WP bazlı modüler yapı + JSON config sistemi
Karar	B — config/, src/wpX/, results/runs/, data/processed/ ayrımı benimsendi.
Neden	Her WP'nin bağımsız test edilebilmesi ve ileride job_entry() ile çağrılabilmesi için zorunluydu.
Etki	run.py dispatcher sistemi: hangi config verilirse o iş paketi çalışıyor. Tüm deneyler izole, karşılaştırılabilir.

WP1 — Baseline Stratejiler

WP1	#3 RL'yi tek başına mı kuralım, yoksa güçlü baseline'larla mı çevreleyeyim?
İkilem	RL ajanı hemen eğit ve sonuçlara bak, yoksa önce 2 klasik baseline implement et?
Seçenekler	A) Direkt PPO'ya geç B) Naive symmetric + Avellaneda-Stoikov baseline zorunlu kıl
Karar	B — Her iki baseline tamamlanmadan WP3'e geçilmedi.
Neden	RL'nin 'ne kadar iyi' olduğunu söyleyebilmek için referans nokta şart. AS, inventory-aware analitik çözüm olarak güçlü bir üst sınır sağladı.
Etki	PPO ~4x Sharpe ile baseline'ları geçince bu sayıların anlamlı bir referansı oldu.

WP1	#4 Fill modelini basit mi, yoksa intensity tabanlı mı yapalım?
İkilem	Sabit fill olasılığı kullanmak mı (kolay), yoksa $\lambda(\delta) = A \cdot \exp(-k \cdot \delta)$ Poisson modeli mi?
Seçenekler	A) Sabit $p=0.5$ fill B) $\lambda(\delta) = A \cdot \exp(-k \cdot \delta)$, $P = 1 - \exp(-\lambda \cdot dt)$
Karar	B — Intensity tabanlı Poisson modeli seçildi.
Neden	Market making literatürünün omurgası bu modeldir (Avellaneda-Stoikov, 2008). Fee ve latency de eklendi. Projenin kimliğini belirleyen temel karardı.
Etki	AS'nin analitik formülleri de bu modeli varsayıyor. Model tutarlılığı sağlandı. Tez akademik literature dayandı.

WP1 / WP3 — Geçiş Kararları

WP1/WP3	#5 RL aksiyonunu buy/sell/hold mu, yoksa spread+skew olarak mı tanımlayalım?
İkilem	Action space'i basit yön kararı (al/sat/bekle) mı, yoksa market-maker mantığıyla spread ve skew mi?
Seçenekler	A) Discrete: al/sat/bekle B) MultiDiscrete([5,5]): $h \in \{1..5\}$ ticks, $m \in \{-2..+2\}$ ticks
Karar	B — Half-spread h ve skew m olarak tanımlandı.
Neden	Market making'de karar spread genişliği ve inventory lean'dir, yön değil. Bu parametrizasyon AS ile doğal karşılaştırma imkanı verdi.
Etki	25 aksiyonlu action space, hem agresif hem pasif quoting'i kapsıyor. Inventory yönetimi doğal biçimde modellenebildi.

WP2 — Sentetik Rejim Tespiti

WP2	#6 Gerçek piyasa verisi mi, kontrollü sentetik dünya mı?
-----	--

İkilem	Real market data kullanmak mı (proposal'da vardı), yoksa synthetic controlled environment mı?
Seçenekler	A) Yahoo Finance / gerçek HFT verisi B) ABM + Markov chain, tamamen sentetik
Karar	B — Tamamen sentetik veri seçildi.
Neden	Seed/reproducibility ile aynı yolu tüm ajanlara göstermek, ve hangi farkın rejim bilgisinden geldiğini temiz izole etmek için zorunluydu. Real data confounding factor yarattırdı.
Etki	Tüm karşılaştırmalar aynı exog seri üzerinde yapıldı. Null result'ın 'gerçek piyasa gürültüsü' diye açıklanması engellendi.

WP2	#7 Rejimleri nasıl tanımlayacağız?
İkilem	HMM/GARCH gibi ağır istatistiksel model mi, yoksa rolling realized volatility ile basit threshold mı?
Seçenekler	A) HMM veya GARCH B) Rolling RV (window=50) + warmup percentile threshold
Karar	B — Rolling RV baseline olarak seçildi; HMM sonradan robustness kontrolü için eklendi.
Neden	'Yorumlanabilirlik ve no-look-ahead' kriterleri öne çıktı. Rolling RV mekanizması şeffaf, implement etmesi hızlı.
Etki	rv_baseline %60.7, hmm %81.8 doğrulukla eklendi. İkisinde de null result → detektör kalitesi açıklaması elenirdi.

WP2	#8 WP2 accuracy %33 çıkınca ne yapacağız?
İkilem	İlk denemede detection accuracy rastgele seviyedeydi (%32.6). Devam mı, düzelt mi?
Seçenekler	A) Bu accuracy ile devam et B) Timescale mismatch'i teşhis et, parametreleri düzelt
Karar	B — Kök neden bulundu: rv_window çok büyük, transition matrix hızlı geçişli.
Neden	rv_window=100 iken rejim süresi ~10 adımdı. Pencere birden fazla rejimi kapsıyordu. Sticky matrix + window=50 + warmup=1000 ile accuracy %60.7'ye çıktı.
Etki	WP2'nin gerçekten 'bitti' diyebildiğimiz nokta bu fix oldu. Threshold gap 5x genişledi.

WP2	#9 Sigma çarpanlarını ne kadar sert ayarlayalım?
İkilem	Project notes'ta [0.5, 1.0, 2.0] yazıyordu; son config'de [0.6, 1.0, 1.8] — neden yumuşattık?
Seçenekler	A) Sert ayırım [0.5, 1.0, 2.0] B) Daha makul yakınlık [0.6, 1.0, 1.8]
Karar	B — [0.6, 1.0, 1.8] olarak yumuşatıldı.
Neden	Rejimlerin fazla kolay ayırt edildiği 'yapay dünya' yerine biraz daha gerçekçi, biraz belirsiz bir ortam hedeflendi.
Etki	Detection zorlaştı ama daha gerçekçi oldu. Bu ayırım tez metodoloji bölümünde savunulabilir.

WP3 — Gymnasium Environment

WP3	#10 Rejim bilgisini ajana açıkça verelim mi?
İkilem	σ_{hat} zaten observation'da varken regime one-hot eklemek gerçekten yeni bilgi mi katıyor?
Seçenekler	A) Sadece σ_{hat} ver B) Hem σ_{hat} hem regime one-hot ver; ablation ile test et
Karar	B — İkisi de verildi, sonra adil ablation ile karşılaştırıldı.
Neden	Bu soruyu baştan sormak tezin ana hipoteziydi. Ablation ile test zorunluydu.
Etki	Null result'ın kök nedeni bu karar sayesinde açıklandı: blind ajan σ_{hat} 'ten rejimi implicitly öğrenebildi.

WP3	#11 Reward saf PnL mi, yoksa inventory penalty ekleyelim mi?
İkilem	$R = \Delta \text{Equity}$ mi, yoksa $R = \Delta \text{Equity} - \eta \cdot \text{inv}^2$ mi?
Seçenekler	A) Saf PnL reward B) $\text{PnL} - \eta \cdot \text{inv}^2$ quadratic penalty
Karar	B — Quadratic inventory penalty eklendi.
Neden	Saf PnL'de ajan inventory biriktirip büyük tek taraflı bahis oynayabilir. Penalty, gerçek market-maker davranışını (risk-neutral quoting) özendirir.
Etki	η ablation ile optimal değer $\eta=0.001$ bulundu. Reward shaping tezin önemli bir metodolojik katkısı oldu.

WP3	#13 PPO'ya geçmeden önce sanity check zorunlu mu?
İkilem	Env doğruluğunu test etmeden PPO eğitime başlamak mı, yoksa önce WP1 ile karşılaştırma mı?
Seçenekler	A) Direkt PPO'ya geç B) naive_h2 sonucunun WP1 sim ile eşleştiğini doğrula
Karar	B — WP3 sanity check yapıldı; gym naive_h2 $\approx$ sim naive_h2 onaylandı.
Neden	Env yanlışsa PPO sonuçları anlamsız olurdu. Özellikle exog mid injection ve reward hesabı hata riskiydi.
Etki	PPO sonuçlarına güven arttı. Sonradan PPO başarısız olsaydı 'env mi bozuk?' sorusu elenmiş olurdu.

WP4 — PPO Training

WP4	#14 İlk RL koşusunu final sonuç gibi mi okuyalım?
İkilem	WP4'te tek seed, 200K ts ile aware >> blind çıktı. Bu tezi kanıtlıyor mu?
Seçenekler	A) Sonucu kabul et, tezi yaz B) Pilot say, çok seed ile OOS protokolü kur
Karar	B — WP4 sonucu pilot olarak etiketlendi.
Neden	Tek seed, in-sample, 200K timesteps çok yetersiz. Akademik güvenilirlik için OOS + çok seed zorunluydu.

Etki	WP5 tasarımı buradan şekillendi: 20 seed, train/test split, 1M timesteps.
------	---

WP4 / WP5 — Geçiş Kararları

WP4-WP5	#15 WP4 ayarlarını final mı, pilot mu sayacağız?
İkilem	total_timesteps=200K, ent_coef=0.0, $\eta=0.01$ ile başlanmıştı. Bunlar ana deney ayarları mı?
Seçenekler	A) Bu ayarlarla devam et B) Pilot say, daha uzun training + exploration ile tekrarlar
Karar	B — WP5 main için 1M timesteps + ent_coef=0.01 + $\eta=0.001$ seçildi.
Neden	Düşük exploration (ent_coef=0.0) ile ajan erken converge ediyor olabilirdi. 200K ts ile policy olgunlaşmamış olabilirdi.
Etki	Ana deney ayarları: total_timesteps=1M, ent_coef=0.01, $\eta=0.001$. Bu config w5_main.json'a sabitlendi.

WP5 — Out-of-Sample Evaluation

WP5	#16 OOS protokolüne geçiş: in-sample iyi görünmek yeterli mi?
İkilem	Eğitim verisinde iyi performans = başarılı tez mi?
Seçenekler	A) In-sample değerlendirme B) train_frac=0.7, OOS test split, seed bazlı model eğitimi
Karar	B — train_frac=0.7 ile out-of-sample protokol kuruldu.
Neden	In-sample overfitting akademik olarak kabul edilmez. Projenin 'oyuncak demo'dan 'araştırma deneyi'ne geçiş noktasıydı.
Etki	Null result OOS'ta çıktı. Bu sonucun güvenilirliği OOS protokolüne dayanıyor.

WP5	#17 WP5'te hangi naive baseline'ı sabitleyeceğiz?
İkilem	Naive sweep vardı (h=1..5). OOS karşılaştırma için tek sabit bir naive gerekiyordu.
Seçenekler	A) h=1 (çok agresif) B) h=2 (orta) C) h=3 (pasif)
Karar	h=2, m=0 — orta nokta seçildi.
Neden	WP1 sweep'te h=2 en dengeli performansı verdi; ne aşırı agresif ne aşırı pasif.
Etki	Tüm karşılaştırmalarda naive referans noktası h=2 tick sabit spread oldu.

WP5	#18 Kaç seed yeterli?
İkilem	3 seed ile variance gözlemlendi, ama hüküm vermek için yetmiyordu.
Seçenekler	A) 3 seed pilot — devam et B) 20 seed ana deney
Karar	B — 20 seed ana deney olarak çalıştırıldı.

Neden	Statistical test için minimum sample gerekiyordu. 3 seed ile p-value anlamlı olmaz. 20 seed paired t-test için yeterli.
Etki	20 seed ile Sharpe $p=0.261$ (inconclusive), equity $p=0.023$ (ppo_blind lehine). Null result sağlam istatistiksel temele oturdu.

WP5	#19 ppo_aware varyansı görünce ilk neyi tune edeceğiz?
İkilem	Yüksek variance'ın pek çok olası nedeni vardı: timesteps, exploration, reward, obs clipping...
Seçenekler	A) Direkt timesteps artır B) Önce η ablation ile reward scale'i doğru ölçeğe otur
Karar	B — Eta ablation önceliklendirildi; $\eta=0.001$ optimal bulundu.
Neden	Reward yanlış ölçeğe olursa hiçbir hyperparameter tuning anlamlı olmaz. Temeli önce sağlamlaştırdık.
Etki	$\eta=0.001$ tüm main experiment konfigürasyonuna taşındı. Ablation tablosu tez metodoloji bölümüne girdi.

WP5	#20 Timesteps ve exploration'ı büyütelim mi?
İkilem	200K / ent_coef=0.0'dan ana deneye geçişte ne değişmeli?
Seçenekler	A) Sadece seed sayısını artır B) 1M timesteps + ent_coef=0.01
Karar	B — Her ikisi birlikte artırıldı.
Neden	Aware ajan çok erken ve zayıf explore ederek dengesiz policy öğrenmiş olabilirdi. Daha fazla training + exploration bu riski azaltır.
Etki	Ana deney fair attempt oldu. Null result daha güçlü: 'yeterince eğitilmedi' itirazı geçersiz.

WP5	#21 Regime-wise raporlama opsiyonel mi, zorunlu mu?
İkilem	Toplam equity metriği yeterli mi, yoksa L/M/H bazında breakdown şart mı?
Seçenekler	A) Sadece toplam metrikler B) Per-regime Sharpe, fill rate, inv_p99 tablosu
Karar	B — Regime-wise raporlama zorunlu kılındı.
Neden	Tezin ana sorusu rejim farkıyla ilgili. Aware ajan gerçekten farklı davranıyorsa bu L/M/H kırılımında görünmeliydi.
Etki	metrics_wp5_oos_by_regime.csv üretildi. Action analysis'te regime-bazlı h/m dağılımı tezin önemli bulgularından biri oldu.

WP5	#22 Action analysis'te varyansı nasılölçeceğiz?
İkilem	Error bar'lar within-seed std mi, cross-seed std mi göstermeli?
Seçenekler	A) Her seed için std hesapla, ortalamasını göster B) Seed-level aggregation + cross-seed std
Karar	B — analyze_actions.py'de _seed_level_stats eklendi, cross-seed std'ye geçildi.

Neden	Within-seed std bize stratejinin tek bir koşuldaki dalgalanmasını verir, ama güvenilirliği ölçmez. Cross-seed std 'farklı piyasalarda ne kadar tutarlı' sorusunu yanıtlar.
Etki	Grafik paper-ready hale geldi. P(h=5) undertrading göstergesi de aynı şemaya eklendi.

WP5	#23 20-seed null result sonrasında ne yapacağız?
İkilem	aware $\approx$ blind çıktı. Tezi 'başarısız' mı sayacağız, yoksa null result'ı savunacak mıyız?
Seçenekler	A) Daha fazla timestep / farklı mimari dene B) Null result'ı temel bulgu olarak konumlandır + detector robustness ile destekle
Karar	B — Null result akademik bulgu olarak sahiplenildi; 3 detector x 20 seed robustness deneyi eklendi.
Neden	sigma_hat zaten observation'da olduğu için explicit regime label redundant — bu güçlü ve özgün bir akademik argüman. Pilot (3 seed) sonuçları: rv_baseline aware=0.850 vs blind=0.814, rv_dwell aware=0.804 vs blind=0.814, HMM aware=0.713 vs blind=0.814. HMM %81.8 doğrulukla bile aware geride — 'düşük detection accuracy' açıklaması elendi.
Etki	Detector robustness full run başlatıldı (120 model). Argüman güçlendi: null result detection kalitesinden bağımsız, signal redundancy temel açıklama.

WP5	#24 Detector robustness full run'ı başlatmak: pilot yeterli mi?
İkilem	3-seed pilot null result'ı tüm detectorlarda gösterdi. Full 120-model run'a gerek var mı?
Seçenekler	A) Pilot (3 seed) yeterli, null result kabul et B) Full run: 3 detector x 20 seed x 2 strateji = 120 model
Karar	B — Full run başlatıldı. Config: w5_detector_full.json. CPU, tahmini ~70-80 saat.
Neden	Pilot'ta sadece 3 seed var — istatistiksel güç yetersiz. Paired t-test için her detector'da 20 seed gerekiyor. HMM %81.8 ile bile null result çıkıyorsa çok güçlü bir argüman ama 20 seed olmadan savunmak zor.
Etki	Full sonuçlar gelince her detector için ayrı paired t-test yapılacak. 'Detection quality değil, signal redundancy' argümanı istatistiksel olarak sağlamlaşacak (veya çürüyecek).

Genel Proje Kararları

Genel	#25 Yazmaya hemen başlayalım mı, yoksa önce araştırmayı derinleştirelim mi?
İkilem	Mezun olmak için tez yeterli mi, yoksa paper hedefiyle daha derinlemesine mi gidilmeli?
Seçenekler	A) Erken yaz, mezun ol B) Önce hikayeyi netleştir, karar/deney öncelikli yürüt
Karar	B — Araştırma derinleştirildi; yazım ikincil tutuldu.

Neden	Supervisor ile paper hedefi konuşulmuştu. Null result'ı güçlü kılmak (detector robustness, action analysis, regime-wise) önce tamamlandı.
Etki	Tez hem MSc tezi hem paper taslağı olarak konumlandı. Uzun vadeli plan: A, k parametrelerini regime'e bağlamak.

WP5 — Ablasyon ve İleri Analizler

WP5	#26 Ablasyon tasarımı: kaç varyant yeterli?
İkilem	aware vs blind ikili karşılaştırması yeterliydi, ama danışman "o her ikisinde de var, bu confounded" dedi. Kaç varyant tasarlayalım?
Seçenekler	A) 2 varyant: aware vs blind B) 5 varyant: sigma_only, regime_only, combined, oracle_pure, oracle_full
Karar	B — 5 varyant tasarlandı ve 20 seed ile eğitildi.
Neden	Danışmanın confounding eleştirisini doğrudan yanıtlamak için o'yi tamamen çıkaran (regime_only, oracle_pure) ve mükemmel rejim bilgisi veren (oracle_pure, oracle_full) varyantlar gerekiyordu.
Etki	Oracle paradoksu ortaya çıktı: oracle_full (Sharpe: 0.722), sigma_only'yi (Sharpe: 0.753) geçemedi. Bu, null result'ın en güçlü kanıtı oldu.

WP5	#27 Oracle paradoksu: anomali mi, bulgu mu?
İkilem	oracle_full sigma_only'den daha düşük Sharpe aldı. Bu bir bug mı yoksa gerçek bir akademik bulgu mu?
Seçenekler	A) Kodu kontrol et, bug ara B) Bulgu olarak kabul et, istatistiksel olarak doğrula
Karar	B — Önce kod doğrulandı (bug yok), sonra paired t-test ile sigma_only vs oracle_full: p=0.115 (Sharpe) bulundu — istatistiksel olarak anlamlı fark yok.
Neden	Mükemmel rejim bilgisi bile sigma_only'yi geçemiyorsa bu signal redundancy'nin doğrudan kanıtı. Anomali değil, tezin temel argümanının en sert testi.
Etki	"Oracle paradoksu" tezin kritik bulgularından biri olarak konumlandırıldı. Danışmanın confounding eleştirisine nihai yanıt verildi.

WP5	#28 Detector robustness full run tamamlandı: sonuç ne?
İkilem	Full run (3 detector × 20 seed × 2 strateji = 120 model) tamamlandı. Sonuçlar pilot ile tutarlı mı?
Seçenekler	A) Pilot yeterliydi, full run gereksizdi B) Full run null result'ı istatistiksel olarak güçlendirdi
Karar	B — rv_baseline p=0.114, rv_dwell p=0.110, HMM p=0.082 (hepsi anlamlı değil). ANOVA: F=0.003, p=0.997.
Neden	%81.8 doğruluklu HMM ile dahi null result korunuyor. "Detection kalitesi düşük olduğu için null çıktı" itirazı tamamen elendi.
Etki	Null result üç bağımsız dedektörde tutarlı — signal redundancy argümanı istatistiksel olarak sağlam.

Genel Proje Kararları — Tez Yazım Süreci

Not: Aşağıdaki kararlar thesis_16 yazım sürecine aittir.

Genel	#29 Bonferroni düzeltmesi: kaç karşılaştırma sayacağız?
-------	---

İkilem	Ablasyon tablosunda 10 satır var ama script başlangıçta $\alpha=0.01/12=0.00083$ kullanıyordu. Doğru payda ne?
Seçenekler	A) 12 kullan (6 karşılaştırma $\times$ 2 metrik) B) 10 kullan (gerçek satır sayısı)
Karar	A — $\alpha=0.01/12=0.00083$ olarak düzeltildi.
Neden	Tabloda fiilen 12 karşılaştırma var (6 karşılaştırma $\times$ 2 metrik); payda gerçek test sayısı ile eşleşmeli. Pratik etki ihmal edilebilir (tüm "EVET" kararları aynı kaldı) ama iç tutarlılık zorunlu.
Etki	thesis_15 $\rightarrow$ thesis_16 geçişinde düzeltildi. İstatistiksel doğruluk sağlandı.

Genel	#30 "Kanıtlamaktadır" dili: çok güçlü mü?
İkilem	Tezde "rejim etiketinin bilgiyi yedekli sunduğunu kanıtlamaktadır" gibi ifadeler vardı. Sentetik ortamda bu kadar kesin dil uygun mu?
Seçenekler	A) Güçlü dili koru, bulgunun ağırlığını vurgula B) "Tutarlıdır", "güçlü kanıt sunar" gibi epistemik açıdan daha doğru ifadeler kullan
Karar	B — Tüm "kanıtlamaktadır" ifadeleri yumuşatıldı.
Neden	Ampirik çalışmalarda "kanıtlar" yerine "destekler/ile tutarlıdır" akademik standarttır. Danışman ve hakem yorumunda bu fark kritik olabilir.
Etki	thesis_16'da dil tutarlı ve savunulabilir hale geldi.

Genel	#31 Şekil numaraları kaydı: nasıl önleriz?
İkilem	PNG dosyaları (fig3_regime_sharpe, fig4_detector_robustness, fig5_action_analysis) yanlış şekil açıklamalarına eşleştirilmişti.
Seçenekler	A) Manuel kontrol her sürümde B) Script'te şekil-açıklama eşleşmesini yorumla belgele
Karar	B — gen_thesis scripti her add_picture() çağrısına açıklayıcı yorum eklendi. thesis_16'da düzeltme yapıldı.
Neden	Şekil kayması okuyucuya "tez acele toparlanmış" izlenimi verir. Akademik belgede görsel-metin tutarlılığı zorunlu.
Etki	thesis_16 ile tüm 5 şekil doğru yerleşti. Versiyon kontrol yorumları eklendi.

WP5	#32 Rejime koşullu envanter cezası: deneyelim mi?
İkilem	Danışman rejime koşullu ödül tasarımını önerdi. $\eta H = 5 \times \eta L$ ile ppo_combined, sigma_only'yi geçer mi?
Seçenekler	A) Sabit $\eta=0.001$ ile devam et B) $\eta L=0.0005$, $\eta M=0.001$, $\eta H=0.0025$ konfigürasyonu ile 20 seed full run
Karar	B — Full run tamamlandı. Config: w5_eta_regime.json.
Neden	Danışmanın dört önerisinden sonuncusuydu. Pilot (3 seed) null result korudu. Full run ile istatistiksel teyit gerekiyordu.
Etki	ppo_combined vs ppo_sigma_only — Sharpe $p=0.0016$, Equity $p=0.008$, her iki metrikte sigma_only lehine anlamlı fark. Rejime koşullu η performansı artırmak yerine düşürdü. Signal redundancy argümanı ödül tasarımı boyutunda da teyit edildi. thesis_17'ye Section 4.7 olarak eklendi.

WP5	#33 Model Misspecification Deney Tasarımı
İkilem	Gerçek piyasalarda fill parametreleri rejime göre değişebilir. Sabit A, k varsayımı altındaki null result ne kadar sağlam?
Seçenekler	A) Sabit $A=5.0$, $k=1.5$ ile devam et B) Rejime bağlı A, k ile misspecification deneyi kur
Karar	B — Fill model parametreleri A ve k rejime bağlanmıştır. MMSimulator generic kalır; env.py step() içinde regime_true'ya göre ExecParams override edilir. Mild parametreler: $L(A=4.0, k=1.8)$, $M(A=5.0, k=1.5)$, $H(A=6.0, k=1.2)$.
Neden	sim.py'a dokunmadan çevresel misspecification eklenmesi mimari temizliği korur. ExecParams dataclass frozen=True kısıtı kaldırılarak mutable hale getirildi (yalnızca ExecParams; MarketParams frozen kaldı).
Etki	20 tohum, 1M timestep, 5-varyant full run tamamlandı. ppo_sigma_only vs ppo_oracle_full: $p=0.881$. Null result korundu.

WP5	#34 Strong Variant Çalıştırılmaması
İkilem	Mild misspecification null result verdi. Strong variant (L: $A=3.0/k=2.0$, H: $A=8.0/k=1.0$) çalıştırılmalı mı?
Seçenekler	A) Strong variant çalıştır B) Mild sonuçlarla yetinip danışman toplantısına hazırlan
Karar	B — Strong variant çalıştırılmamıştır.
Neden	Mild misspecification sonuçları (ppo_sigma_only vs ppo_oracle_full: $p=0.881$; vs ppo_combined: $p=0.217$) null result'ın bu ortamda da geçerli olduğunu açıkça göstermiştir. $p=0.88$ gibi güçlü bir null result varlığında strong variant'ın anlamlı ek katkı sağlaması beklenmemekte; danışman toplantısı yaklaşmaktadır.
Etki	Strong variant gelecek çalışmalar listesine eklendi. Mevcut bulgular danışman sunumu için yeterlidir.

WP5	#35 Oracle Deneyi $\geq 90\%$ Dedektör Hedefini Karşılıyor
-----	--

İkilem	Danışman $\geq 90\%$ doğruluklu dedektör hedefi belirtmişti. HMM %81.8'de kaldı. Yeterli mi?
Seçenekler	A) Daha iyi dedektör geliştir B) Oracle deneyi ile %100 doğruluğun bile fark yaratmadığını göster
Karar	B — Oracle deneyi (ppo_oracle_full, ppo_oracle_pure) %100 doğrulukla eşdeğerdir; agent gerçek rejim etiketini (regime_true) doğrudan gözlemlemektedir.
Neden	oracle_full sigma_only'yi geçememiştir ($p=0.115$). Bu bulgu $\geq 90\%$ hedefini aşan, daha güçlü bir testtir — mükemmel rejim bilgisi bile katkı sağlamamaktadır.
Etki	Dedektör kalitesi itirazı güçlü bir üst-sınır testiyle yanıtlanmıştır. Oracle deneyi, mükemmel rejim bilgisinin bile sigma_only'yi geçemediğini göstermektedir.

WP5	#36 thesis_19 — Birim Hatası ve p-Değeri Düzeltmesi
İkilem	thesis_18'de iki faktüel hata tespit edildi: inv_p99 birimi 'tick' olarak yazılmış (doğrusu 'lot'), oracle paradox p-değeri sigma_only vs oracle_full için 0.301 olarak etiketlenmiş (doğrusu 0.115; 0.301 oracle_full vs combined'a aittir).
Seçenekler	A) Errata notu ekle B) Yeni sürüm (thesis_19) oluştur
Karar	B — thesis_19 oluşturuldu. inv_p99 birimi tick → lot olarak düzeltildi. sigma_only vs oracle_full p-değeri 0.301 → 0.115 olarak düzeltildi (stats_ablation.txt: ppo_sigma_only vs ppo_oracle_full sharpe_like $p=1.15e-01$).
Neden	inv_p99 envanter pozisyon büyüklüğünü ölçer — birimi lot/kontrat, tick değil. $p=0.301$, oracle_full vs combined karşılaştırmasına aittir; sigma_only vs oracle_full Sharpe p-değeri 0.115'tir.
Etki	İki faktüel hata giderildi; tez argümanı değişmedi, yalnızca raporlama doğruluğu artırıldı.

WP5	#37 thesis_20 — Tablo 3 Bonferroni Düzeltmesi
İkilem	thesis_19 Tablo 3'te 10 karşılaştırma rapor edilmiş ancak combined vs AS ve combined vs naive equity satırları eksikti. Bonferroni $\alpha = 0.01/10 = 0.001$ olarak yazılmıştı.
Seçenekler	A) Sadece metin düzelt, tabloyu 10 satır bırak B) Eksik 2 equity satırını ekle, Bonferroni'yi 12'ye güncelle
Karar	B — Tablo 3'e combined vs AS (final_equity, $t=-1.064$, $p=3.01e-01$) ve combined vs naive (final_equity, $t=-0.728$, $p=4.76e-01$) satırları eklendi. Bonferroni düzeltmesi 10→12 karşılaştırma, $\alpha = 0.01/12 = 0.00083$ olarak güncellendi.
Neden	stats_ablation.txt'te 12 karşılaştırma mevcuttur; tablo ile kaynak arasındaki tutarsızlık giderildi. Yeni equity satırları 'Hayır' (anlamsız) olduğundan sonuçlar değişmedi, yalnızca raporlama bütünlüğü sağlandı.
Etki	Tablo 3 artık stats_ablation.txt ile birebir uyumlu; Bonferroni eşiği daha muhafazakâr hale geldi ($0.001 \rightarrow 0.00083$).

WP5	#38 thesis_21 — Sec 4.7 Varyant, Tablo 7 Sütun, Oracle Paradox Güncelleme
------------	--

İkilem	thesis_20'de üç sorun tespit edildi: (1) Section 4.7'de 'üç varyant' yazılmış, doğrusu beş varyant; (2) Tablo 7'de 'Std Sharpe' sütunu tüm değerleri '—' iken gereksiz; (3) Abstract ve Conclusion'da oracle paradox, oracle_full vs combined p=0.301 üzerinden ifade edilmiş — daha doğrudan kanıt sigma_only vs oracle_full p=0.115'tir.
Seçenekler	A) Küçük düzeltmeleri atla B) Üçünü birden düzelt, thesis_21 oluştur
Karar	B — (1) 'üç varyant' → 'beş varyant'; (2) Tablo 7'den Std Sharpe sütunu kaldırıldı; (3) Abstract ve Conclusion'da oracle paradox cümlesi sigma_only vs oracle_full p=0.115 ifadesiyle güncellendi.
Neden	Beş varyant fiilen eğitilmiştir (sigma_only, combined, oracle_full, oracle_pure, regime_only). Std Sharpe sütunu bilgi taşııyordu. p=0.115 doğrudan sigma_only vs oracle_full karşılaştırmasını yansıtır ve oracle paradox argümanını daha güçlü destekler.
Etki	Faktüel tutarlılık artırıldı; ana argüman değişmedi.

WP5	#39 Null result: t-test "fark yok" mu, TOST "fark ihmal edilebilir" mi?
İkilem	Null result "fark yok" mu yoksa "fark ihmal edilebilir" mi olarak sunulmalı?
Seçenekler	A) Klasik t-test ile " $p > 0.05$, fark bulunamadı" demek B) TOST equivalence test ile "fark pratik olarak ihmal edilebilir aralıkta" kanıtlamak
Karar	B — TOST eklendi.
Neden	"Absence of evidence is not evidence of absence" eleştirisini önlemek için. TOST, null result'ı pasif bir bulgu olmaktan çıkarıp aktif bir kanıta dönüştürür.
Etki	Ana ablasyon: TOST ± 0.10 eşdeğer ($p=0.0005$), 95% CI $[-0.007, +0.068]$. thesis_24'te ilgili bölümlere eklendi.

WP5	#40 TOST eşiği (equivalence bound) nasıl belirlenmeli?
İkilem	TOST eşiği (equivalence bound) nasıl belirlenmeli?
Seçenekler	A) ± 0.05 (çok sıkı) B) ± 0.10 (orta, pratik anlamlılık için makul) C) ± 0.15 (çok gevşek)
Karar	B — ± 0.10 birincil eşik olarak seçildi.
Neden	Ortalama Sharpe ~ 0.75 seviyesinde; 0.10 fark %13'lük görelî sapma demek. Bu, market making bağlamında pratik olarak ihmal edilebilir bir fark. Misspec ortamında ± 0.05 bile eşdeğerlik sağlandı ($p=0.039$).
Etki	İki deney için tutarlı eşik. Paper'da savunulabilir metodolojik seçim.

WP5	#41 thesis_25 — TOST değerleri birincil CSV recompute'a göre güncellendi
İkilem	Codex denetimi, thesis_24'teki TOST p-değerleri ve CI sınırlarının birincil CSV recompute'a birebir uymadığını tespit etti (normal $p=0.0005$ vs gerçek 0.00067; misspec $p=0.039$ vs gerçek 0.042). Ayrıca TOST $\alpha=0.05$ konvansiyonunun 90% CI'a karşılık geldiği tezde açık değildi.
Seçenekler	A) Eski değerleri bırak B) Birincil CSV'den recompute değerleri ile güncelle ve 90% CI konvansiyonunu netleştir
Karar	B — Her iki bölümde p ve 95% CI recompute değerlerine güncellendi; ek olarak 90% CI (TOST $\alpha=0.05$ 'e karşılık gelen aralık) eklendi. Normal: 90%

Neden	CI [-0.001, +0.063] ± 0.10 içinde. Misspec: 90% CI [-0.040, +0.048] ± 0.05 içinde.
Etki	Reproducibility (independently verified, 6-decimal match). TOST metodolojik şeffaflığı artırıldı.
Etki	Null result argümanı değişmedi, aksine güçlendi — misspec'te 90% CI ± 0.05 'in *içinde*, yani eşdeğerlik sıkı sınırdaki destekleniyor.

WP2/WP5	#42 Rejim parametrelerinin retrospektif gözden geçirilmesi (sigma_mult, warmup)
İkilem	Farklı iş paketlerinde kullanılan rejim parametreleri arasında tarihsel bir sapma tespit edildi: thesis §3.1 [0.6, 1.0, 1.8] / warmup=1000 olarak yazılı iken misspec-mild deneyi [0.5, 1.0, 2.0] / warmup=400 ile yürütülmüş. WP5.5 sinyal denetim konfigürasyonunda ise dt=1.0 / sigma_mid_ticks=0.5 drift'i yakalandı. Bu sapmaların ya geriye dönük homogenize edilmesi ya da açıkça belgelenmesi gerekiyordu.
Seçenekler	A) Tüm geçmiş koşulları yeni (kanonik) parametrelerle yeniden eğit; büyük hesaplama maliyeti B) Canonical operating point'i sabitle, yeni denetim/denemeler buna uysun, geçmiş deneyler olduğu gibi kalsın ve sapmalar tezde/log'da açıkça belirtilsin
Karar	B — Kanonik nokta: dt=0.2, sigma_mid_ticks=0.8, sigma_mult=[0.6,1.0,1.8], warmup_steps=1000, rv_window=50, n_steps=8000, exec={A=5.0, k=1.5, fee_bps=0.2, latency_steps=1}, sticky 3x3 trans_matrix. Misspec-mild varyantının [0.5,1.0,2.0]/warmup=400 ile yürütüldüğü tezde açıkça not edildi; geçmiş koşullar yeniden üretilmedi.
Neden	Yeniden eğitim maliyeti (5 varyant $\times$ 20 tohum $\times$ 1M timestep) ana bulguya ek bilgi sağlamadan zaman ve enerji harcar. Kanonik noktanın yazılı hâle getirilmesi, ileride her yeni deneyin aynı referansı paylaşmasını garanti ediyor. Şeffaflık > retrospektif temizlik.
Etki	Yeni eklenen denemeler (WP5.5 sinyal denetimi dâhil) kanonik noktayı kullanıyor. Misspec sonuçlarının bu farkla birlikte yorumlanması için tezin §4.8'ine uyarı paragrafı eklendi.

WP5.5	#43 WP5.5 öncesi canonical operating point sanity-check zorunlu kılındı
İkilem	WP5.5 (sinyal manipülasyon denetimi) doğrudan mevcut konfigürasyon dosyaları üzerinden koşturulacaktı. Ancak config dosyaları zaman içinde farklı iş paketleri için özelleştirilmiş; kanonik referansla birebir örtüşme kontrol edilmemişti. Sonuçların anlamlı kabul edilebilmesi için kullanılan parametrelerin tez metninde açıklanan ortamla uyumlu olması gerekliydi.
Seçenekler	A) Config'i olduğu gibi kullan, sonuçları yorumlarken uyar B) Önce yalnızca-okuma bir sanity-check yaparak kanonik noktayı resmen belirle, sapmaları raporla, sonra WP5.5 konfigürasyonunu buna göre hizala
Karar	B — WP5.5 audit koşulmadan önce tez metni, config dosyaları ve önceki koşu snapshot'ları taranarak kanonik operating point resmen tespit edildi (Karar #42). İki mevcut sapma (WP5.5 audit config, misspec-mild config) açıkça dokümanate edildi. WP5.5 koşusu ancak bundan sonra yürütüldü.
Neden	Sanity-check, sonuçların yanlış baz çizgisine göre raporlanıp geri çekilmesinden çok daha ucuz. Kanonik noktanın yazılı hâle getirilmesi sonraki tüm çalışmalar için tek referans noktası sağlıyor.
Etki	WP5.5 audit'i kanonik parametrelerle yeniden koşuldu; önceki drift'li iki koşu (20260419-214718, 20260419-221930) arşiv notuyla aynen saklandı. Karar izlenebilirliği korundu.

WP5.5	#44 WP5.5 audit drift düzeltildi; 'none' rejiminde yapısal metrikler ungated
İkilem	İlk WP5.5 koşusu dt=1.0 ve sigma_mid_ticks=0.5 ile yürütülmüş; clean classification accuracy ≈ 0.40 ve L-ağırlıklı rejim dağılımı üretmiş, direction/monotonicity gate'lerini yanıltıcı şekilde FAIL göstermişti. Ek olarak 'none' (sabit fill_value=0.0) koşulunda classification accuracy ve threshold_overlap metrikleri, eşik kalibrasyonu ile fill değeri arasındaki ilişkiyi yansıtıyor — bilgi içeriğine dair sinyal taşıyor.
Seçenekler	A) Drift'li koşuyu gerçek sonuç olarak raporla B) Kanonik noktaya yeniden koştur, 'none' koşulunda yapısal olarak tanımsız metrikleri PASS/FAIL değerlendirmesinden çıkar (reported-but-not-gated) ve bu politikayı audit özetinde belgele
Karar	B — config/w55_audit.json kanonik noktaya hizalandı (dt=0.2, sigma_mid_ticks=0.8, sigma_mult=[0.6,1.0,1.8], warmup=1000, trans_matrix tam, exec bloğu açıkça yazılı); noise_std için 'auto' modu eklendi (0.5 $\times$ clean_sigma_std). Audit job'ı, 'none' koşulunda classification accuracy ve threshold_overlap metriklerini raporlamaya devam ediyor ama direction/monotonicity gate'lerinde dışlıyor.
Neden	Sabit input altında bu iki metrik bilgi içeriğini değil fill/threshold ilişkisini ölçer; gating mantiken yanlış. Yeni koşu (20260422-170037): direction PASS, separation PASS, coarsen_safety PASS, monotonicity FAIL — genel öneri REVIEW. Monotonicity FAIL, ölçüt tasarımına dair bir gözlem olarak ayrıca tartışılıyor; üç degradasyon (noisy/lagged/coarsened) tek bir şiddet eksenine yerleştirilemiyor.
Etki	Tez §4'e 'Manipülasyon Geçerlilik Denetimi' alt bölümü eklendi; eski iki drift'li koşu 'results/runs/wp55_audit_archive_note.md' ile kalıcı şekilde süpersed edildi. Audit reproducibility için commit'e alındı; yeni baseline açık.

WP5	#45 Misspec-mild ortam farkı tezde açık uyarı paragrafı olarak not edildi
İkilem	Misspec-mild koşuları [0.5, 1.0, 2.0] / warmup=400 ile yürütülmüştü; §3.1'de tanımlanan kanonik [0.6, 1.0, 1.8] / warmup=1000 ortamından farklıydı. Aynı 20-tohumluk koşuyu kanonik parametrelerle yeniden üretmek $\approx 4-5$ saat GPU maliyetiydi. Ya bu yeniden üretim yapılmalı ya da fark tez metninde açıkça belgelenmeliydi.
Seçenekler	A) Kanonik parametrelerle 100 modeli baştan eğit, eski sonuçları değiştir B) Mevcut misspec sonuçlarını koru, §4.8'e tasarım-farkı uyarı paragrafı ekle; sonucu 'kanonik ortamda yeniden üretilmemiştir' notuyla sun
Karar	B — Misspec-mild tablosu ve yorumu olduğu gibi kalıyor; §4.8 Tasarım paragrafının başına ortam sapmasını açıkça belirten bir uyarı eklendi. Gelecek çalışmalar listesine kanonik parametrelerle yeniden üretim maddesi yazılı olarak bulunuyor.
Neden	Ana null bulgusu ([sigma_only $\approx$ oracle_full, p=0.881]) misspec-mild altında bile güçleniyor; ortam farkına rağmen argümanın yönü değişmiyor. Yeniden eğitim maliyeti, bulgunun yeniden üretilebilirlik gücüne ek bilgi sağlamıyor. Şeffaflık > saf temizlik.
Etki	§4.8 Tasarım paragrafı, okuyucunun sonucu doğru bağlamda yorumlamasını sağlayacak şekilde kanonik ortam farkını açıkça not ediyor. Log #42'deki kanonik nokta kararıyla bu karar çapraz referans veriyor.

WP5.5	#46 Signal Informativeness Sweep için noisy ve lagged koşullarının parametre kalibrasyonu ($\alpha = 0.40$, $k = 20$)
Karar	Yaklaşan Signal Informativeness Sweep'inde noisy koşulu için noise standard deviation çarpanı $\alpha = 0.40$ ve lagged koşulu için lag $k = 20$ step olarak sabitlendi.
Seçenekler	(a) $\alpha = 0.20$, $k = 10$ — konservatif, hafif degradation (b) $\alpha = 0.40$, $k = 20$ — orta-üst degradation, NRMSE bakımından yaklaşık eşleşmiş (c) $\alpha = 0.80$, $k = 50$ — agresif, none koşuluna yakın
Neden	Offline calibration audit'i (run 20260425-184732_seed42_wp55-calibration_1e806ff, 7 $\alpha \times 5$ seed + 7 $k \times 5$ seed = 70 ölçüm) seçimi yönlendirdi. Seçim kriterleri: (i) noisy ve lagged koşulları clean'den anlamlı biçimde ayrılmalı ama none'a çökmemeli, (ii) iki koşul birbirine yakın informational degradation şiddetinde olmalı ki sweep'te "noise mı lag mı daha bozucu" sorusu temiz cevaplanabilsin. $\alpha = 0.40$ (Pearson 0.929, NRMSE 0.40, accuracy_drop 0.053) ve $k = 20$ (Pearson 0.937, NRMSE 0.35, accuracy_drop 0.042) bu iki kriteri karşılayan eşleştirilmiş çift olarak öne çıktı. Konservatif (a) seçeneği "degradation var ama neredeyse yok" bölgesinde kalarak sweep'i düzleştirme riski taşıyordu; agresif (c) seçeneği none koşuluna fazla yaklaşıyordu.
Etki	Sweep ana çalışması $\alpha = 0.40$ ve $k = 20$ ile yürütülecek. Sensitivity analizi olarak $\alpha = 0.20$ ve $k = 10$ appendix'te raporlanacak. Calibration audit CSV'leri (metrics_calibration_per_seed.csv, metrics_calibration_aggregated.csv) docs/internal/calibration_audit/ altında saklı; thesis Methods bölümünde bu kalibrasyona atıf yapılacak.
Not	Kalibrasyon detayı olarak konumlandırıldığı için hocaya sweep öncesi ayrı bir mail atılmadı; sweep tamamlandığında ilerleme güncellemesinde raporlanacak.

WP6	#47 Signal degradation hypothesis reversal
Karar	WP6 Signal Informativeness Sweep'in yorumu, Plot 1-3 sonuçları sonrası informativeness-threshold çerçevesinden encoding-interference çerçevesine geçirildi. Plot 4 (per-regime breakdown / action analysis) bu sürümde takip edilmedi.
Seçenekler	(a) Orijinal informativeness-threshold çerçevesini korumak ve null result olarak raporlamak (b) Encoding-interference çerçevesine geçmek ve daha güçlü ampirik deseni öne çıkarmak (c) Plot 4'ü ekleyip per-regime / action analyses ile mekanizma tanımlamaya çalışmak
Neden	Plot 1 (monotonic-gap): sigma_only condition-invariant kaldı (0.756-0.783); beklenen monotonik daralma gözlenmedi — orijinal hipotez tutmadı. Plot 2 (paired-seed combined vs sigma_only): combined < sigma_only direction her 4 informative koşulda (paired t $p < 0.05$, Cohen's d_z -0.57 ila -0.91); pratik (TOST $\delta = 0.05$) yalnızca lagged'de (mean_diff = -0.101, $d_z = -0.91$). Plot 3 (paired-seed combined vs regime_only): mean diff null ama variance heterojen (std_diff > std_regime_only 3/4 koşulda); TOST equivalence $n = 20$ 'de underpowered (observed std_diff ≈ 0.13 -0.16, minimum detectable equivalence band $\approx \pm 0.07$ -0.08, $\delta = 0.05$ 'in altında değil).
Etki	Chapter 5 yeniden çerçevelendi: orijinal hipotez reddedildi, daha güçlü ampirik desen (encoding-interference: combined sistematik olarak sigma_only altında, regime_only seviyesine yakın) öne çıkarıldı, mekanizma (interference vs crowd-out vs optimization noise) bu deneyden tanımlanamaz olarak açıkça not edildi. Plot 4 takip edilmedi — üç plot beraber chapter spine'ı kuruyor; ek analiz core sweep sorusuna ortogonal yeni cepheler (per-regime breakdown, action analysis) açacaktı.

Not	Metodolojik simetri: WP5'te TOST equivalence'ı kanıtlamak için kullanılmıştı (ppo_aware $\approx$ ppo_blind, max-p kuralı). WP6 Plot 2'de ters yönde non-equivalence için kullanıldı (combined $\neq$ sigma_only, min-p kuralı); Plot 3 WP5 yönüne döndü. Bu simetri thesis chapter intro'sunda açıkça belirtilecek. "encoding-interference" mekanizma değil betimleyici etiket olarak kullanılıyor; mekanizma tanımlamasına gitmemek bilinçli bir kısıtlama.
------------	---

Audit	#48 Lane A audit response scope
Karar	Lane A bulguları thesis_28 içinde metodolojik caveat olarak yanıtlandı: C1 dwell filter look-ahead ana sonuç boru hattını etkilemeyen yardımcı detector comparison kapsamına alındı; C2 WP4 same-series train/eval yalnızca pilot/infrastructure olarak çerçevelendi; C3 WP6 noisy sigma calibration küçük noisy-only ölçek sorunu olarak caveat edildi.
Seçenekler	(a) Tüm Lane A bulguları için deneyleri yeniden koşturmak (b) Boru hattı kapsamını ayırıp ana numerik iddiaları WP5 70/30 OOS ve WP6 sweep çıktıları üzerinden korumak (c) Bulguları görmezden gelmek
Neden	C1 için main WP4/WP5/WP6 pipeline'ları causal rv_baseline kullanıyor; dwell filter offline auxiliary robustness comparison ile sınırlı. C2 için raporlanan PPO performans sayıları WP4'ten değil WP5'in 70/30 OOS split sonuçlarından geliyor; WP4 eğitim/infrastructure pilot statüsünde. C3 için WP6 noisy sigma calibration etkisi noisy-only küçük ölçek kayması olarak sınıflandı; directional bulgular değişmediği için rerun yapılmadı.
Etki	Thesis_28 sayısal iddiaları korunurken metodolojik sınırlar açık hale getirildi. Ana sonuçlar yeniden üretilmedi; caveat yaklaşımı kanıt hiyerarşisini netleştirdi: auxiliary detector analizi ayrı, reported PPO OOS sonuçları ayrı, noisy calibration sınırlaması ayrı.
Not	Prosedürel ders: audit bulgusunun hangi evidence layer'a ait olduğu belirlenmeden apply yapılmadı. Bu ayırım yanlış audit mapping ve gereksiz rerun riskini düşürdü.

Infrastructure	#49 Lane B engineering guardrails
Karar	Lane B kapsamında üç mühendislik güvence düzeltmesi kabul edildi: CSVMetricLogger schema consistency enforcement, resume sırasında config snapshot validation, ve CSV/TXT audit stability için .gitattributes + LF materialization.
Seçenekler	(a) Logger ve resume davranışını olduğu gibi bırakmak (b) Sadece dokümantasyonla riski not etmek (c) Küçük, local guardrail düzeltmeleriyle sessiz veri/konfigürasyon drift riskini azaltmak
Neden	CSVMetricLogger daha önce sessiz kolon uyumsuzluğu üretebilecek bir append pattern'ine açıktı; 26beecd ile explicit fieldnames schema check eklendi. Resume path'i yanlış config ile devam etme riskini taşıyordu; a63e640 ile snapshot mismatch default olarak reddedildi. Cross-platform hash/audit stabilitesi için ffe8d90 ile .gitattributes eklendi ve CSV/TXT line-ending davranışı sabitlendi.
Etki	Bu değişiklikler mevcut numerik evidence artifact'larını yeniden üretmedi; gelecekteki koşulların izlenebilirliğini ve audit tekrarlanabilirliğini güçlendirdi. Hata yüzeyi runtime veya I/O guardrail seviyesinde daraltıldı.
Not	Commit zinciri: 26beecd (B8 CSVMetricLogger), a63e640 (B9 resume validation), ffe8d90 (.gitattributes/LF audit stability).

Codebase	#50 Lane C active-code remediation
-----------------	---

Karar	Lane C kapsamındaki aktif kod ve provenance düzeltmeleri ayrı küçük commit'lere bölündü: ANOVA framing netleştirildi; thesis figure ownership header'ları ayrıştırıldı; tarihsel generator'lar legacy alanına taşındı; aktif scriptlerde hardcoded run path'ler argparse default'larıyla parametrize edildi; WP2 per-run provenance artifact adı standardize edildi.
Seçenekler	(a) Tek büyük cleanup commit'i yapmak (b) Sadece doküman notu eklemek (c) Davranış yüzeyini koruyan, audit edilebilir küçük remediation commit'leri yapmak
Neden	0ed125e ile stats_detector_robustness.py ANOVA design framing'i açıklandı. 43ad288 ile figure_thesis.py ve figure_thesis_23.py ownership scope'u Fig 1-5 / Fig 6-9 olarak ayrıldı. 5ac5bcb ile historical thesis ve decisions-log generators scripts/legacy altına README ile taşındı. dca37b6 ile src/wp5/figure_thesis.py, src/wp5/figure_thesis_23.py ve scripts/eval_only_seed1to7.py hardcoded run path'leri byte-identical argparse defaults ile parametrize edildi. e0c47c5 ile src/wp2/synth_regime.py run-dir provenance artifact'ı ctx.run_dir/wp2_synth.csv olarak standardize edildi.
Etki	No-arg davranışlar korunarak bakım yapılabilirlik ve provenance netliği artırıldı. thesis_28, CSV evidence ve PNG result artifacts değiştirilmedi; aktif downstream sayısal iddialar etkilenmedi.
Not	C3 parametrize edilen aktif scriptler: src/wp5/figure_thesis.py, src/wp5/figure_thesis_23.py, scripts/eval_only_seed1to7.py. C4 WP2 global data/processed/wp2_synth.csv'yi latest convenience snapshot olarak korudu; run_dir/wp2_synth.csv specific-run provenance artifact oldu.

Process	#51 Audit procedure and protected evidence
Karar	Audit-remediation sürecinde discovery-before-apply protokolü benimsendi; deney rerun yapılmadı; canonical Lane C protected SHA check her commit sonrası 4/4 MATCH kaldı; protected CSV evidence artifact'ları değiştirilmedi.
Seçenekler	(a) Hızlı apply ile tahmini düzeltmeler yapmak (b) Discovery raporu, scoped apply, static verification ve protected hash check sırasını izlemek (c) Rerun ile bütün evidence setini yeniden üretmek
Neden	Discovery adımı, ilk yanlış protected-file mapping riskini görünür kıldı ve canonical Lane C Rule dosyalarının doğru setini sabitledi: results/metrics_detector_compare.csv, docs/internal/wp6_sweep_full/summary_condition_variant.csv, docs/internal/wp6_sweep_full/summary_paired_combined_vs_sigma.csv, docs/internal/wp6_sweep_full/summary_paired_combined_vs_regime.csv. Her apply adımı bu set üzerinde post-commit 4/4 MATCH doğrulaması ile kapatıldı.
Etki	Düzeltilmeler evidence-preserving olarak kaldı: protected CSV artifact'ları, PNG result artifact'ları ve thesis_28 dokümanı değişmedi. Rerun yapılmadığı için sayısal iddialarda yeni stochastic variance veya artifact drift oluşmadı.
Not	Bu karar, audit sürecinin kendisini reproducibility artifact olarak kayda geçirir. Ana ders: önce kapsam ve consumer/writer ilişkisi kanıtlanır, sonra küçük scoped apply yapılır, ardından canonical hash check ile evidence dokunulmazlığı doğrulanır.

Özet: En Kritik 31 Karar

ChatGPT ve Claude'un ortak değerlendirmesine göre tezin seyrini en çok etkileyen kararlar:

#	Karar	WP
1	Research-grade pipeline kurmak	WP0
2	Naive + AS baseline'larını zorunlu kılmak	WP1
3	Synthetic controlled market seçmek	WP2
4	Rolling RV + no-look-ahead rejim tespiti	WP2
5	Aksiyonu spread + skew olarak tanımlamak	WP3
6	Reward'ı PnL - $\eta \cdot \text{inv}^2$ yapmak	WP3
7	Aware vs blind'i adil observation ablation olarak kurmak	WP3/WP5
8	OOS + çoklu seed + eta tuning + null result sahiplenmek	WP5
9	Detector robustness full run (120 model) — signal redundancy argümanını desteklemek ve null result'ı istatistiksel olarak teyit etmek	WP5
10	5 varyantlı ablasyon + oracle paradoksu	WP5
11	Dil yumuşatma + istatistiksel iç tutarlılık (Bonferroni, şekil sırası)	Yazım
12	Rejime koşullu envanter cezası deneyi — signal redundancy'yi ödül tasarımı boyutunda da teyit etmek (p=0.0016)	WP5
13	Model misspecification deney tasarımı — rejime bağlı A, k ile null result sağlamlığını test etmek (p=0.881)	WP5
14	Strong variant çalıştırılmaması — mild sonuçların yeterliliği ve zaman kısıtı	WP5
15	Oracle deneyi $\geq 90\%$ dedektör hedefini karşılıyor — %100 doğruluk bile sigma_only'yi geçemedi (p=0.115)	WP5
16	thesis_19 — inv_p99 birim hatası (tick→lot) ve oracle paradox p-değeri etiketi (0.301→0.115) düzeltildi	WP5
17	thesis_20 — Tablo 3 Bonferroni 10→12 karşılaştırma ($\alpha=0.001 \rightarrow 0.00083$); combined vs AS/naive equity eklendi	WP5
18	thesis_21 — Sec 4.7 üç→beş varyant, Tablo 7 Std Sharpe kaldırıldı, oracle paradox p=0.115 güncellendi	WP5
19	TOST equivalence test — null result'ı pasif bulgudan aktif kanıta çevirmek	WP5
20	TOST eşiği ± 0.10 seçimi — pratik anlamlılık için makul bound	WP5
21	thesis_25 TOST recompute — p/CI değerleri birincil CSV'ye göre düzeltildi, 90% CI eklendi	WP5
22	Rejim parametre retrospektifi — kanonik operating point yazılı hâle getirildi; misspec-mild sapması belgelendi	WP2/WP5
23	WP5.5 öncesi canonical operating point sanity-check zorunlu — sapmalar WP5.5 öncesi raporlandı	WP5.5
24	WP5.5 audit drift düzeltildi ve 'none' rejiminde yapısal metrikler ungated — reported-but-not-gated politikası	WP5.5
25	Misspec-mild ortam farkı §4.8'de açık uyarı paragrafıyla not edildi — yeniden üretim yapılmadı, şeffaflık tercih edildi	WP5
26	Signal Informativeness Sweep noisy/lagged parametre kalibrasyonu — $\alpha=0.40$, k=20 sabitlendi (offline audit dayanağı)	WP5.5
27	WP6 Signal Informativeness Sweep — hipotez çevirimi (informativeness-threshold → encoding-interference); Plot 4 takip edilmedi	WP6

28	Lane A audit response — C1 dwell auxiliary-only, C2 WP4 pilot-only, C3 WP6 noisy sigma calibration caveat; no rerun	Audit
29	Lane B engineering guardrails — CSVMetricLogger schema, resume config validation, .gitattributes/LF audit stability	Infrastructure
30	Lane C remediation — ANOVA framing, figure ownership, legacy generator archive, argparse path defaults, WP2 provenance artifact naming	Codebase
31	Audit procedure — discovery before apply, no reruns, canonical Lane C protected SHA stayed 4/4 MATCH	Process