Karlsruhe Institute of Technology
Financial Engineering MSc Programı

Yüksek Lisans Tez Taslağı

Farklı Volatilite Rejimleri Altında Pekiştirmeli Öğrenme ile Yüksek Frekanslı Piyasa Yapıcılığı

Onur Emiroğlu
Financial Engineering MSc Programı

1. ÖZET

Bu çalışmada, volatilite rejim bilgisinin (Düşük/Orta/Yüksek) pekiştirmeli öğrenme tabanlı piyasa yapıcı ajanların performansına katkısı araştırılmaktadır. Proximal Policy Optimization (PPO) algoritması kullanılarak iki ajan eğitilmiştir: rejim bilgisine sahip (ppo_aware) ve rejim bilgisinden yoksun (ppo_blind). Ajanlar, Poisson varış süreçli yoğunluk tabanlı dolum modeli ve Markov zinciri rejim geçişleri içeren tamamen sentetik bir piyasa ortamında değerlendirilmiştir.

Yürütülen out-of-sample deney (20 bağımsız tohum, 1 milyon zaman adımı eğitim, %70/%30 walk-forward bölünmesi), her iki PPO varyantının da Sharpe oranı açısından klasik referans stratejilerini (Avellaneda-Stoikov ve naif sabit-spread) yaklaşık 6–7 kat geçtiğini ortaya koymaktadır. Buna karşın, rejim bilgisinin PPO performansına net bir katkı sağladığı hipotezi istatistiksel olarak desteklenmemiştir: ppo_aware, Sharpe bazında 20 tohumun 11'inde, equity bazında ise 9'unda ppo_blind'ı geride bırakmıştır.

Davranışsal analiz, ppo_aware ajanının rejimler arasında sınırlı eylem farklılaşması sergilediğini göstermektedir; gözlemlenen farklar performans avantajına dönüşmemektedir. Çalışma, sentetik veri ile kontrollü ortam tasarımının değerini, PPO'nun envanter risk yönetimindeki üstünlüğünü ve rejim farkındalığı hipotezi için "null result"ın yayınlanabilir bir akademik bulgu oluşturduğunu göstermektedir. Detector robustness deneyi — rv_baseline (%60.7), rv_dwell (%60.4) ve HMM (%81.8) dedektörleri ile 20 tohumda yinelenen analiz — null sonucun dedektör seçiminden bağımsız olduğunu doğrulamıştır (tüm dedektörler için Sharpe bazlı $p > 0.08$).

Anahtar kelimeler: piyasa yapıcılığı, pekiştirmeli öğrenme, PPO, volatilite rejimleri, Avellaneda-Stoikov, Poisson dolum modeli, out-of-sample değerlendirme

SEMBOLLER VE KISALTMALAR

Bu bölümde çalışma boyunca kullanılan matematiksel semboller, Yunan harfleri ve kısaltmalar tanımlanmaktadır.

Matematiksel Semboller

Sembol	Açıklama
M_t	t anındaki mid-price (orta fiyat) [para birimi]
σ	Volatilite parametresi — mid-price'ın birim zamandaki standart sapması [tick/√saniye]
σ_base	Temel volatilite parametresi; Orta (M) rejim için referans değer (0.8 tick/√saniye)
σ_L, σ_M, σ_H	Düşük, Orta ve Yüksek rejimlere karşılık gelen volatilite değerleri
Δt	Simülasyon zaman adımı büyüklüğü (0.2 saniye)
z	Standart normal rassal değişken; z ~ N(0,1)
λ(δ)	δ tick uzaklığındaki kotasyon için Poisson dolum yoğunluğu [dolum/saniye]
A	Sıfır uzaklıkta (δ=0) temel dolum yoğunluğu (5.0 dolum/saniye)
k	Dolum yoğunluğunun uzaklıkla üstel azalma hızı (1.5 tick başına)
δ	Kotasyon uzaklığı — bid veya ask fiyatının mid-price'tan tick cinsinden sapması
δ_bid	Bid (alış) kotasyonunun mid-price'tan uzaklığı [tick]
δ_ask	Ask (satış) kotasyonunun mid-price'tan uzaklığı [tick]
P_fill	Bir zaman adımında en az bir dolumun gerçekleşme olasılığı
h	Half-spread — kotasyon yarı-aralığı [tick]; h ∈ {1, 2, 3, 4, 5}
m	Skew — asimetrik kotasyon kayması [tick]; m ∈ {−2, −1, 0, +1, +2}
q	Envanter (inventory) — anda tutulan net pozisyon miktarı [lot]
q_norm	Normalize edilmiş envanter; q_norm = q / inv_max_clip ∈ [−1, +1]
inv_max_clip	Envanter kırpma sınırı (50 lot)
τ	Kalan zaman fraksiyonu; τ = (T − t) / T ∈ [0, 1]
T	Episode toplam adım sayısı (8000 adım)
R_t	t adımındaki ödül (reward)
η	Envanter ceza katsayısı; η = 0.001
γ	Avellaneda-Stoikov risk aversion parametresi; γ = 0.01
r	Avellaneda-Stoikov rezervasyon fiyatı
d	Avellaneda-Stoikov optimal yarı-spread
k_price	Fiyat cinsinden ifade edilen yoğunluk azalma parametresi; k_price = k / tick_size
P	Markov zinciri geçiş matrisi (3×3)
p_ii	i. rejimin kendi kendine geçiş olasılığı (köşegen eleman)
Sharpe	Sharpe oranı — risk-düzeltmeli getiri ölçütü; Sharpe = (μ/σ) × √(1/Δt)
inv_p99	Mutlak envanter değerinin 99. persantili [lot]
equity	Toplam varlık değeri; equity = cash + q × M_t

Yunan Harfleri

Sembol	Açıklama
γ (gamma)	Risk aversion parametresi (Avellaneda-Stoikov modelinde)
η (eta)	Envanter ceza katsayısı (ödül fonksiyonunda)
σ (sigma)	Volatilite — fiyat değişiminin standart sapması
τ (tau)	Kalan zaman fraksiyonu
λ (lambda)	Poisson dolum yoğunluğu
δ (delta)	Kotasyon uzaklığı (mid-price'tan tick cinsinden sapma)
μ (mu)	Ortalama adım başına PnL (Sharpe hesabında)

Kısaltmalar

Kısaltma	Açıklama
PPO	Proximal Policy Optimization — yakınsak politika optimizasyonu algoritması
RL	Reinforcement Learning — pekiştirmeli öğrenme
AS	Avellaneda-Stoikov — klasik stokastik kontrol tabanlı piyasa yapıcılığı modeli
HFT	High-Frequency Trading — yüksek frekanslı alım-satım
OOS	Out-of-Sample — modelin eğitilmediği veri üzerinde değerlendirme
WP	Work Package — iş paketi (proje aşaması)
ABM	Arithmetic Brownian Motion — aritmetik Brownian hareketi
RV	Realized Volatility — gerçekleşmiş volatilite (kayan pencere ile hesaplanan)
PnL	Profit and Loss — kar ve zarar
CUDA	Compute Unified Device Architecture — NVIDIA GPU hesaplama mimarisi
SB3	Stable-Baselines3 — PPO implementasyonu için kullanılan Python kütüphanesi
MlpPolicy	Multi-Layer Perceptron Policy — çok katmanlı algılayıcı politika ağı
GAE	Generalized Advantage Estimation — genelleştirilmiş avantaj tahmini (PPO bileşeni)
L / M / H	Low / Medium / High — Düşük / Orta / Yüksek volatilite rejimleri

TERİMLER SÖZLÜĞÜ

Bu sözlük, çalışmada kullanılan teknik terimleri konuya aşina olmayan okuyucular için tanımlamaktadır. Terimler alfabetik sıraya göre düzenlemiştir.

Terim	Tanım
Ablation (Ablasyon)	Bir modelin belirli bir bileşeninin çıkarılarak ya da devre dışı bırakılarak etkisinin ölçülmesi amacıyla yapılan kontrollü deney. Bu çalışmada, rejim bilgisinin (use_regime=False) ve envanter ceza katsayısının (η) etkisi ablasyon deneyleriyle ölçülmüştür.
Action Space (Eylem Uzayı)	Bir pekiştirmeli öğrenme ajanının her adımda seçebileceği tüm olası eylemlerin kümesi. Bu çalışmada eylem uzayı, half-spread (h) ve skew (m) değerlerinden oluşan ayrık bir yapıdadır.
Adverse Selection (Ters Seçim)	Piyasa yapıcının bilgili yatırımcılara karşı dezavantajlı konuma düşmesi durumu. Örneğin, fiyat hızla değişirken eski kotasyon fiyatından doldurulma riski.
Agent (Ajan)	Pekiştirmeli öğrenmede, bir ortamda gözlem yaparak karar veren ve ödül sinyaline göre davranışını güncelleyen öğrenen sistem.
Ask (Satış Fiyatı)	Piyasa yapıcının satmaya hazır olduğu fiyat. Her zaman bid fiyatının üzerindedir.
Bid (Alış Fiyatı)	Piyasa yapıcının almaya hazır olduğu fiyat. Her zaman ask fiyatının altındadır.
Bid-Ask Spread	Alış ve satış fiyatı arasındaki fark. Piyasa yapıcının temel gelir kaynağıdır. Bu çalışmada tick cinsinden ifade edilmektedir.
Brownian Motion (Brownian Hareketi)	Rastlantısal yürüyüş modellerinin sürekli-zaman limiti. Aritmetik Brownian Hareketi'nde (ABM) fiyat değişimleri sabit ortalama ve volatilite parametrelerine sahip normal dağılımdan çekilmektedir.
Clip (Kırpma)	Bir değerin belirli bir aralıkla sınırlandırılması işlemi. Bu çalışmada envanter ±50 lot ile kırpılmaktadır.
Convergence (Yakınsama)	Pekiştirmeli öğrenme eğitiminde politi kanın optimal ya da kararlı bir çözüe ulaşması süreci.
Entropy Coefficient (Entropi Katsayısı)	PPO'da keşif-sömürü dengesini ayarlayan hiperparametre. Yüksek değer daha fazla rassal eylem anlamına gelir. Bu çalışmada ent_coef=0.01 kullanılmıştır.
Episode	Pekiştirmeli öğrenmede başlangıçtan bitiş koşuluna kadar süren bir tam simülasyon koşusu. Bu çalışmada bir episode 8000 zaman adımından oluşmaktadır.
Exogenous Series (Dışsal Seri)	Modelin dışında önceden üretilmiş ve tüm stratejilere aynı biçimde sunulan fiyat/volatilite serisi. Adil karşılaştırma için kullanılır.
Fill (Dolum)	Piyasa yapıcının kotasyon verdiği fiyattan gerçekleşen emir eşleşmesi. Bid tarafından dolum, piyasa yapıcının envanterini artırır; ask tarafından dolum azaltır.
Fill Rate (Dolum Oranı)	Toplam adım sayısına bölünen dolum sayısı. Piyasa yapıcının ne kadar aktif işlem yaptığının göstergesi.
Gymnasium	OpenAI tarafından geliştirilen, pekiştirmeli öğrenme ortamları için standart Python arayüzü. reset() ve step() metodlarını tanımlar.
Half-Spread (Yarı-Aralık)	Bid veya ask fiyatının mid-price'tan uzaklığı. Tam spread'in yarısı. Bu çalışmada h sembolüyle gösterilir.
Hyperparameter (Hiperparametre)	Eğitim sürecinden önce kullanıcı tarafından belirlenen ve modelin nasıl öğreneçeğini kontrol eden parametre. Örnek: learning rate, batch size, γ.

Terim	Tanım
Inventory (Envanter)	Piyasa yapıcının anda elinde bulundurduğu net pozisyon miktarı. Pozitif değer net uzun (long), negatif değer net kısa (short) pozisyonu ifade eder.
Inventory Risk (Envanter Riski)	Piyasa yapıcının büyük envanter pozisyonu tutarken fiyat hareketleri nedeniyle maruz kaldığı zarar riski.
Latency (Gecikme)	Piyasa yapıcının kotasyon güncellemesi ile piyasanın bu güncellemeyi işlemesi arasındaki zaman farkı. Bu çalışmada latency_steps=1 ile modellenmektedir.
Limit Order Book	Bekleme sırasındaki tüm alış ve satış emirlerinin fiyat-miktar listesi. Piyasa yapıcılar bu kitaba likidite sağlar.
Lot	Alım-satım işlemlerinde standart birim miktar. Bu çalışmada envanter lot cinsinden ifade edilmektedir.
Markov Chain (Markov Zinciri)	Gelecekteki durumun yalnızca mevcut duruma bağlı olduğu (geçmişten bağımsız) olasılıksal süreç. Bu çalışmada rejim geçişleri için kullanılmaktadır.
Market Making (Piyasa Yapıcılığı)	Finansal piyasalarda sürekli alış ve satış kotasyonu vererek likidite sağlama faaliyeti. Piyasa yapıcı, spread geliri karşılığında envanter ve adverse selection riskini üstlenir.
Mid-Price	Anlık alış (bid) ve satış (ask) fiyatlarının ortalaması. Piyasanın gerçek değerine en yakın fiyat tahmini.
Model Misspecification (Model Yanlış Belirleme)	Kullanılan modelin gerçek veri üretim sürecini tam olarak yansıtmaması durumu. Örneğin, AS modelinin sabit volatilite varsayıması.
Null Result	Araştırma hipotezinin verilerce desteklenmediği bulgu. İstatistiksel olarak anlamlı bir fark gözlemlenmemesi durumu. Bu çalışmada rejim farkındalığı hipotezi null result ile sonuçlanmıştır.
Observation Space (Gözlem Uzayı)	Ajanın her adımda çevreden aldığı bilginin vektör temsili. Bu çalışmada 6 boyutludur: [q_norm, $\hat{\sigma}$, τ, r_L, r_M, r_H].
One-Hot Encoding	Kategorik bir değişkeni ikili vektörle temsil etme yöntemi. Örneğin, H rejimi için [0, 0, 1] vektörü kullanılır.
Out-of-Sample (OOS)	Modelin eğitilmediği, bağımsız bir veri kümesi üzerinde yapılan değerlendirme. Overfitting'i önlemek için kullanılır.
Overfitting	Modelin eğitim verisine aşırı uyum sağlayarak yeni veride düşük performans göstermesi.
Percentile (Persantil)	Veri setinin belirli bir yüzdesinin altında kaldığı değer. Örneğin inv_p99, envanterin %99'unun bu değerin altında olduğunu ifade eder.
Policy (Politika)	Pekiştirmeli öğrenmede ajanın gözleme göre eylem seçme stratejisi. PPO, politikayı sinir ağı parametreleri ile temsil eder.
Poisson Process (Poisson Süreci)	Olayların bağımsız ve sabit ortalama hızda rastlantısal gerçekleştiği olasılıksal süreç. Bu çalışmada emir dolumları Poisson süreci ile modellenmektedir.
PPO (Proximal Policy Optimization)	John Schulman ve ark. (2017) tarafından geliştirilen politika gradyanı tabanlı RL algoritması. Politika güncellemelerini sınırlı adımlarla kısıtlayarak kararlı eğitim sağlar.
Regime (Rejim)	Piyasanın belirli bir volatilite seviyesinde bulunduğu dönem. Bu çalışmada L (Düşük), M (Orta) ve H (Yüksek) olmak üzere üç rejim tanımlanmıştır.
Reservation Price (Rezervasyon Fiyatı)	Avellaneda-Stoikov modelinde envanter riskini içselleştiren düzeltilmiş mid-price tahmini.
Reward (Ödül)	Pekiştirmeli öğrenmede ajanın her adımda çevreden aldığı sayısal sinyal. Bu çalışmada $R_t = \Delta Equity - \eta \cdot q^2$ formülü kullanılmaktadır.

Terim	Tanım
Risk-Adjusted Return (Risk-Düzeltmeli Getiri)	Getirinin, üstlenilen risk miktarına bölünmesiyle elde edilen performans ölçütü. Sharpe oranı en yaygın örneğtir.
Seed (Tohum)	Rastlantısal sayı üretecinin başlangıç değeri. Aynı seed ile aynı sonuçlar elde edilir; tekrarlanabilirlik için kullanılır.
Sharpe Ratio (Sharpe Oranı)	Birim risk başına elde edilen fazla getiriyi ölçen performans metriği. Sharpe = $(\mu/\sigma) \times \sqrt{(1/\Delta t)}$ formülüyle hesaplanır.
Skew (Asimetrik Kotasyon)	Bid ve ask kotasyonlarının mid-price'a göre eşit olmayan biçimde kaydırılması. Pozitif skew, ask tarafını yaklaştırır; negatif skew bid tarafını yaklaştırır.
Stable-Baselines3 (SB3)	PPO dahil çeşitli RL algoritmalarının güvenilir PyTorch implementasyonlarını içeren Python kütüphanesi.
State (Durum)	Pekiştirmeli öğrenmede çevrenin belirli bir andaki tam gözlemlenebilir temsili. Observation space ile eşanlamlı kullanılmaktadır.
Sticky Transition Matrix	Köşegen elemanları yüksek (öz-geçiş olasılığı büyük) Markov geçiş matrisi. Rejimlerin uzun süre devam etmesini sağlar.
Stochastic Control (Stokastik Kontrol)	Rassal süreçler içeren sistemlerde optimal karar verme teorisi. Avellaneda-Stoikov modeli bu çerçeveye dayanmaktadır.
Tick	Finansal piyasalarda fiyatın alabileceği en küçük artış birimi. Bu çalışmada tick_size = 0.01 para birimi olarak tanımlanmıştır.
Timestep (Zaman Adımı)	Simülasyonun bir sonraki duruma geçtiği en küçük zaman birimi. Bu çalışmada $\Delta t = 0.2$ saniyedir.
Training (Eğitim)	Pekiştirmeli öğrenmede ajanın politikasını ödül sinyallerine göre iteratif biçimde güncellemesi süreci.
Variance (Varyans)	Bir değişkenin ortalama etrafındaki yayılımının karesi. Yüksek varyans, sonuçların tutarsız olduğuna işaret eder.
Walk-Forward Validation	Zaman serisi verisini geçmişten geleceğe doğru bölerek eğitim ve test kümelerini oluşturan değerlendirme yöntemi. Look-ahead bias'ı önler.

2. GİRİŞ

Piyasa yapıcılığı (market making), finansal piyasalarda likidite sağlayan ve sürekli olarak hem alış (bid) hem de satış (ask) kotasyonu veren ajanların stratejik davranışını inceleyen bir alandır. Piyasa yapıcılar, spread geliri elde etmeye çalışırken olumsuz fiyat hareketlerine maruz kalan envanter riskini de yönetmek zorundadır. Bu denge, özellikle volatilitenin değişken olduğu yüksek frekanslı piyasalarda kritik önem taşımaktadır.

Klasik yaklaşımlar arasında Avellaneda ve Stoikov (2008) tarafından geliştirilen stokastik kontrol çerçevesi öne çıkmaktadır. Bu model, envanter riskini rezervasyon fiyatı kavramıyla içselleştirerek optimal bid-ask spread'ini analitik olarak türetmektedir. Ancak bu yaklaşım, sabit bir volatilite varsayımına dayanmakta ve piyasa rejimlerindeki değişimlere uyum sağlayamamaktadır.

Son yıllarda pekiştirmeli öğrenme (RL) yöntemleri, dinamik piyasa koşullarına uyum sağlayabilen ajan tasarımı için umut verici bir alternatif olarak öne çıkmıştır. PPO gibi politika gradyanı algoritmalharı, özellikle sürekli durum uzayları ve karmaşık ödül yapılarına sahip finansal ortamlarda başarıyla uygulanmıştır.

Bu çalışmanın temel araştırma sorusu şudur: Volatilite rejim bilgisine (Düşük/Orta/Yüksek) erişimi olan bir PPO ajanı, bu bilgiden yoksun olan eşdegerine kıyasla daha iyi performans sergiler mi?

Bu soruyu yanıtlamak için aşağıdaki katkılar sunulmaktadır:

- (1) Markov zinciri rejim geçişleri ve Poisson tabanlı dolum modeli içeren kontrollü bir sentetik piyasa ortamı tasarlanmıştır.
- (2) Rejim farkındalığı ablasyonu gerçekleştirilmiş; ppo_aware ve ppo_blind ajanları 20 bağımsız tohum ve walk-forward out-of-sample protokolü ile karşılaştırılmıştır.
- (3) Eylem dağılımı analizi ile ajanların rejime özgü davranışsal farklılaşması incelenmiştir.

3. TEORİ VE METODOLOJİ

3.1 Piyasa Modeli

Piyasa fiyatı, ayrık zamanlı aritmetik Brownian hareketi (ABM) ile modellenmektedir:

$$M_{t+1} = M_t + \sigma_r \cdot \sqrt{\Delta t} \cdot z, \quad z \sim N(0,1)$$

Burada M_t mid-price, σ_r rejime bağlı volatilite parametresi (ticks/√saniye cinsinden), $\Delta t = 0.2$ saniye zaman adımı büyüklüğüdür. Başlangıç fiyatı $M_0 = 100.0$, tick büyüklüğü 0.01'dir.

Temel volatilite parametresi $\sigma_{base} = 0.8$ tick olarak belirlenmiş; üç rejim için çarpanlar [0.6, 1.0, 1.8] olarak tanımlanmıştır. Buna göre $\sigma_L = 0.48$, $\sigma_M = 0.80$, $\sigma_H = 1.44$ tick/√saniye değerleri elde edilmektedir.

3.2 Dolum Modeli

Emir dolumları, yoğunluk tabanlı Poisson süreci ile modellenmektedir. Delta tick cinsinden ifade edildiğinde, dolum yoğunluğu:

$$\lambda(\delta) = A \cdot \exp(-k \cdot \delta)$$

formülüyle hesaplanmaktadır. Burada $A = 5.0$ (delta=0'daki temel yoğunluk, dolum/saniye) ve $k = 1.5$ (tick başına üstel azalma) parametreleridir. Bir zaman adımında en az bir dolumun gerçekleşme olasılığı:

$$P_{fill} = 1 - \exp(-\lambda \cdot \Delta t)$$

olarak verilmektedir. Hem bid hem ask tarafı için bağımsız Bernoulli denemeleri gerçekleştirilmektedir.

Gecikme modeli (latency_steps = 1), ajanın kotasyon hesaplamasında bir önceki adımın mid-price değerini kullanmasına yol açmaktadır; bu durum ters seçim (adverse selection) riskini içselleştirmektedir. Komisyon ücreti her işlem için 0.2 baz puan olarak uygulanmaktadır.

3.3 Rejim Modeli

Volatilite rejimleri, üç durumlu (L: Düşük, M: Orta, H: Yüksek) birinci derece Markov zinciri ile üretilmektedir. Geçiş matrisi yapışkan (sticky) olacak şekilde tasarlanmıştır:

$$P = [[0.9967, 0.0023, 0.0010], [0.0042, 0.9917, 0.0041], [0.0010, 0.0030, 0.9960]]$$

Beklenen rejim süreleri sırasıyla L: ~300, M: ~120, H: ~250 zaman adımıdır. Bu yapışkanlık, kayan gerçekleşmiş volatilite (rolling realized volatility — RV) ile rejim tespitinin mümkün olmasını sağlamaktadır.

Rejim tespiti için RV pencere boyutu 50 adım, ısınma süresi (warmup) 1000 adım olarak belirlenmiştir. Eşik değerleri ısınma döneminin 33. ve 66. persentillerinden kalibre edilmektedir. Gerçek zamanlı tespitte look-ahead bias engellenmiştir; regime_hat yalnızca geçmiş veriden hesaplanmaktadır. Elde edilen tespit doğruluğu %60.7'dir (rastgele sınır: %33.3).

Detector robustness analizi kapsamında iki ek tespit yöntemi karşılaştırılmıştır: (i) dwell filtreli RV (rv_dwell): kısa süreli (<5 adım) rejim geçişlerini düzelten filtre uygulanmış, tespit doğruluğu %60.4 olarak elde edilmiştir; (ii) Gaussian HMM (hmm): sigma_hat serisi üzerinde eğitilen üç durumlu Gaussian gizli Markov modeli, %81.8 doğruluk ile en yüksek tespit kalitesini sağlamıştır.

3.4 Gymnasium Ortamı

OpenAI Gymnasium uyumlu MMEnv ortamı oluşturulmuştur. Gözlem uzayı 6 boyutludur:

$$obs = [q_{norm}, \hat{\sigma}_t, \tau, r_L, r_M, r_H]$$

Burada $q_{norm} = \text{clip}(\text{inv}, -50, 50) / \text{inv}_{max_clip}$ envanter normalizasyonu, $\hat{\sigma}_t$ kayan gerçekleşmiş volatilite, $\tau = (T-t)/T$ kalan zaman fraksiyonu, $r_L/r_M/r_H$ ise rejim one-hot kodlamasıdır (ppo_blind için hepsi sıfır).

Eylem uzayı MultiDiscrete([5, 5]) şeklinde tanımlanmıştır:

$$h_{idx} \in \{0,1,2,3,4\} \rightarrow h = h_{idx} + 1 \text{ tick (half-spread)}$$

$$m_idx \in \{0,1,2,3,4\} \rightarrow m = m_idx - 2 \text{ tick } (skew)$$
$$\delta_bid = max(1, h + m)$$
$$\delta_ask = max(1, h - m)$$

Ödül fonksiyonu şu şekilde tanımlanmıştır:

$$R_t = (equity_t - equity_\{t-1\}) - \eta \cdot inv_t^2$$

Burada $\eta = 0.001$ envanter ceza katsayısıdır (η ablasyonu ile optimize edilmiştir). (Kodda ek bir skew cezası terimi ($c \cdot |m|$) bulunmakla birlikte, ana deneylerde c=0 olarak sabitlenmiş ve bu terim etkisiz bırakılmıştır; skew ablasyonu §3.5'te ele alınmaktadır.)

3.5 Referans Stratejiler

3.5.1 Naif Sabit-Spread Stratejisi

Her zaman adımında simetrik sabit half-spread uygulanmaktadır: $\delta_bid = \delta_ask = h = 2$ tick. Envanter farkındalığı veya skew mekanizması içermemektedir.

3.5.2 Avellaneda-Stoikov Stratejisi

Rezervasyon fiyatı ve yarı-spread şu formüllerle hesaplanmaktadır:

$$r = mid - q \cdot \gamma \cdot \sigma^2 \cdot \tau$$
$$d = \tfrac{1}{2} \cdot \gamma \cdot \sigma^2 \cdot \tau + (1/\gamma) \cdot ln(1 + \gamma/k_price)$$

Burada $\gamma = 0.01$ risk aversion parametresi, k_price = k_ticks / tick_size fiyat cinsinden yoğunluk azalma parametresidir. Delta değerleri [1, 25] tick aralığında kırpılmaktadır.

3.6 PPO Eğitimi ve Değerlendirme Protokolü

Stable-Baselines3 kütüphanesi kullanılarak PPO eğitimi gerçekleştirilmiştir. Hiperparametreler:

Parametre	Değer
total_timesteps	1.000.000
learning_rate	0.0003
n_steps	2048
batch_size	256
n_epochs	10
gamma	0.999
gae_lambda	0.95
clip_range	0.2
ent_coef	0.01

Her seed için episode uzunluğu 8000 adım olup walk-forward bölünmesi %70/%30 (train: 5600, test: 2400 adım) şeklinde uygulanmıştır. Değerlendirme yalnızca test bölümünden gerçekleştirilmektedir. Toplam 20 bağımsız tohum kullanılmıştır (seeds: 1–20). Eğitim GPU üzerinde gerçekleştirilmiştir (NVIDIA CUDA, PyTorch 2.6.0+cu124).

4. SONUÇLAR VE TARTIŞMA

4.1 Ana Deney Sonuçları (20 Tohum, OOS)

Tablo 1. Out-of-Sample Performans Özeti (20 Tohum, Ortalama ± Std)

Strateji	Ort. Equity	Std	Ort. Sharpe	inv_p99	Fill Rate
AS	5.05	4.72	0.105	29.95	0.444
Naif	4.49	3.49	0.126	21.20	0.119
ppo_aware	4.10	0.78	0.715	2.00	0.236
ppo_blind	4.42	0.71	0.740	2.05	0.232

Birinci bulgu — PPO'nun Sharpe Üstünlüğü: Her iki PPO varyantı da Sharpe oranı açısından klasik referans stratejileri karşısında belirgin üstünlük sergilemiştir. ppo_aware ortalama Sharpe = 0.715, ppo_blind ise 0.740 değeri elde ederken, AS için bu değer 0.105, naif strateji için ise 0.126 olarak ölçülmüştür. Bu fark yaklaşık 6–7 kat büyüklüğündedir ve temel mekanizması envanter kontroldür: PPO varyantları inv_p99 ≈ 2 tick düzeyinde çalışırken, AS ve naif stratejiler sırasıyla 29.95 ve 21.20 değerlerine ulaşmaktadır. Yüksek envanter, kümülatif değerleme volatilitesini artırarak Sharpe oranını düşürmektedir.

İkinci bulgu — Null Sonuç: Rejim Farkındalığı Hipotezi Desteklenmedi: ppo_aware, Sharpe bazında 20 tohumun 11'inde, equity bazında ise 9'unda ppo_blind'ı geride bırakmıştır. Wilcoxon işaretli sıra testi sonuçlarına göre, Sharpe oranı açısından iki ajan arasında istatistiksel olarak anlamlı bir fark bulunamamıştır (p=0.261). Bununla birlikte, nihai öz sermaye (equity) açısından gerçekleştirilen eşleştirilmiş t-testi, PPO-blind lehine anlamlı bir fark ortaya koymuştur (t=−2.47, p=0.023). Bu bulgu, rejim farkındalığının tek başına performans üstünlüğü sağlamadığını ve birincil değerlendirme metriği olan Sharpe oranı açısından iki strateji arasında anlamlı bir farkın gözlemlenmediğini göstermektedir.

Üçüncü bulgu — PPO Varyans Avantajı: PPO varyantlarının equity std değerleri (0.71–0.78) AS (4.72) ve naif (3.49) stratejilerine kıyasla belirgin biçimde düşükdür. Bu durum, PPO'nun yalnızca daha yüksek Sharpe oranı değil, aynı zamanda daha tutarlı ve güvenilir bir performans profili sunduğuna işaret etmektedir.

Bu null sonuç için üç açıklayıcı hipotez öne sürürlmektedir:

- (a) Gözlem uzayında $\hat{\sigma}_t$ değeri hali hazırda mevcut olduğundan, one-hot rejim kodlaması $\hat{\sigma}_t$'den türetilmiş bilgiyi yedekli biçimde sunmakta ve marjinal katkı sağlamamaktadır.
- (b) Ödül fonksiyonu rejime özgü davranışı doğrudan teşvik etmediğinden, rejim bilgisini performansa dönüştürmek için sinyal yetersiz kalmaktadır.
- (c) Detector robustness deneyi bu hipotezi geçersiz kılmaktadır: %81.8 doğruluklu HMM dedektörü ile dahi null sonuç korunmaktadır (p=0.082). Dolayısıyla tespit kalitesi belirleyici değildir; açıklayıcı güç (a) hipotezinde yoğunlaşmaktadır.

4.2 Eylem Analizi (Davranışsal Farklılaşma)

Tablo 2. Rejim Bazında Eylem Dağılımı (Ortalama ± Std, 20 Tohum)

Strateji	Rejim	Ort. h	Std h	Ort. m	Std m	P(h=5)
AS	L	1.00	0.00	-0.01	0.02	0.000
AS	M	1.00	0.00	-0.02	0.03	0.000
AS	H	1.00	0.00	-0.02	0.03	0.000
Naif	L	2.00	0.00	0.00	0.00	0.000
Naif	M	2.00	0.00	0.00	0.00	0.000
Naif	H	2.00	0.00	0.00	0.00	0.000

Strateji	Rejim	Ort. h	Std h	Ort. m	Std m	P(h=5)
ppo_aware	L	1.43	0.63	-0.05	0.22	0.000
ppo_aware	M	1.68	0.72	-0.01	0.25	0.008
ppo_aware	H	1.74	0.71	+0.00	0.22	0.000
ppo_blind	L	1.39	0.47	-0.03	0.24	0.000
ppo_blind	M	1.42	0.41	-0.00	0.23	0.000
ppo_blind	H	1.60	0.42	-0.00	0.17	0.000

ppo_aware ajanı, rejimler arasında sınırlı davranışsal farklılaşma sergilemektedir. Tüm rejimlerde ortalama half-spread h ≈ 1.4–1.8 tick aralığında seyretmekte, skew değerleri ise m ≈ 0 civarında kalmaktadır. ppo_blind ile karşılaştırıldığında anlamlı bir politika ayrışması gözlemlenmemektedir. Bu bulgu, performans düzeyindeki null result ile tutarlıdır.

ppo_blind ise tüm rejimlerde m ≈ 0 civarında tekdüze bir politika sergilemektedir. Her iki ajan da rejimler arasında anlamlı bir politika ayrışması göstermemekte olup bu bulgu performans düzeyindeki null result ile tutarlıdır.

4.3 Rejim Bazlı Performans Analizi

Tablo 3, test döneminde üç volatilite rejiminde (L, M, H) elde edilen strateji performanslarını özetlemektedir. PPO ajanlarının her üç rejimde de AS ve naive baseline'larına kıyasla çok daha düşük envanter riski (inv_p99 ≈ 2 vs. 20–28) sergilediği görülmektedir. PPO-aware ve PPO-blind ajanları rejimler arasında benzer Sharpe oranları göstermiş; bu durum, rejim etiketinin ek bir performans avantajı sağlamadığını desteklemektedir. Dikkat çekici bir gözlem olarak, her iki PPO ajanı da düşük volatilite (L) rejiminde en yüksek Sharpe değerlerini kaydetmiştir.

Tablo 3: Rejim Bazlı OOS Performansı (20 Tohum Ortalaması)

Strateji	Rejim	Sharpe	inv_p99	Fill Rate
AS	L	0.330	22.26	0.404
AS	M	0.197	27.49	0.438
AS	H	0.038	27.66	0.497
naive	L	0.269	16.35	0.105
naive	M	0.150	18.87	0.115
naive	H	0.143	19.20	0.143
PPO-aware	L	0.927	1.85	0.226
PPO-aware	M	0.799	1.60	0.225
PPO-aware	H	0.464	1.79	0.250
PPO-blind	L	0.924	2.00	0.220
PPO-blind	M	0.814	1.88	0.229
PPO-blind	H	0.526	1.91	0.252

4.4 Detector Robustness Analizi

Null sonucun rejim tespit kalitesine duyarlılığını değerlendirmek amacıyla üç farklı dedektör ile 20 tohumda yeniden analiz gerçekleştirilmiştir.

Tablo 4: Detector Robustness — Ortalama Sharpe (20 Tohum)

Dedektör	**Doğruluk**	**ppo_aware**	**ppo_blind**
rv_baseline	%60.7	0.718	0.753
rv_dwell	%60.4	0.716	0.753
HMM	%81.8	0.719	0.753

Bulgular üç temel gözlemi ortaya koymaktadır. Birincisi, ppo_blind tüm dedektörlerde identik performans sergilemiştir (Sharpe = 0.753); bu beklenen bir sonuçtur, zira blind ajan rejim etiketlerini gözlem uzayına almamaktadır. İkincisi, ppo_aware tüm dedektörlerde ppo_blind'ın hafifçe altında kalmıştır; %81.8 doğruluklu HMM ile dahi bu örüntü değişmemiştir. Üçüncüsü, paired t-test sonuçları Sharpe metriğinde hiçbir dedektör için istatistiksel anlamlılık eşiğine ulaşmamıştır (rv_baseline: $p=0.114$, rv_dwell: $p=0.110$, HMM: $p=0.082$). Equity metriğinde ise tüm dedektörlerde ppo_blind lehine anlamlı fark gözlemlenmiştir ($p < 0.05$). One-way ANOVA analizi, ppo_aware performansının dedektör seçimine göre anlamlı biçimde değişmediğini doğrulamaktadır ($F=0.003$, $p=0.997$).

Bu bulgular, null sonucun zayıf tespit kalitesinden kaynaklanmadığını güçlü biçimde desteklemektedir. Gözlem uzayında hâlihazırda mevcut olan sigma_hat değişkeni, açık rejim etiketinin sağladığı bilgiyi örtük olarak içermektedir.

5. SONUÇ

Bu çalışma, volatilite rejimleri altında pekiştirmeli öğrenme tabanlı piyasa yapıcılığını araştırmaktadır. Temel bulgular şu şekilde özetlenebilir:

Birincisi, her iki PPO varyantı da Sharpe oranı açısından Avellaneda-Stoikov ve naif referans stratejilerini yaklaşık 6–7 kat geçmiştir. Bu üstünlüğün temel kaynağı, PPO'nun envanter riskini etkin biçimde yönetmesi ve inv_p99 ≈ 2 tick düzeyinde tutmasıdır.

İkincisi, rejim farkındalığı hipotezi istatistiksel olarak desteklenmemiştir. ppo_aware, Sharpe bazında 20 tohumun 11'inde, equity bazında ise 9'unda ppo_blind'ı geride bırakmış; ortalama performans farkı ihmal edilebilir düzeyde kalmıştır. Bu null sonuç için en güçlü açıklama, gözlem uzayında hali hazırda bulunan $\hat{\sigma}_t$ değerinin rejim bilgisini örtük olarak içermesi ve one-hot rejim kodlamasının yedekli bilgi sunmasıdır. Detector robustness deneyi bu yorumu desteklemektedir: rv_baseline (%60.7), rv_dwell (%60.4) ve HMM (%81.8) dedektörleri ile yinelenen analizde null sonuç tutarlı biçimde korunmuş; ANOVA testi dedektör seçiminin ppo_aware performansını anlamlı ölçüde etkilemediğini doğrulamıştır ($F=0.003$, $p=0.997$).

Üçüncüsü, ppo_aware davranışsal düzeyde sınırlı rejim farklılaşması göstermesine karşın bu farklılaşma performans avantajına dönüşmemiştir. Bu bulgu, davranışsal analizi performans metriklerinden bağımsız değerlendirmenin önemini vurgulamaktadır.

Gelecek çalışmalar kapsamında şu yönler önerilmektedir:

- (1) Rejim parametrelerini gözlem uzayından çıkararak bilgi fazlalığını giderme ve pure ablation tasarımı.
- (2) Rejime koşullu ödül tasarımı — yüksek volatilite rejiminde envanter cezasının artırılması gibi mekanizmalar.
- (3) Skew penalty ablasyonu ($c=0$ kontrol grubu dahil) ile eylem düzeyinde düzenlileştirmenin sistematik değerlendirmesi.
- (4) Model yanlış belirleme (model misspecification) benchmark'ı — AS parametrelerinin rejime bağlı kılınması.

KAYNAKLAR

[1] Avellaneda, M., & Stoikov, S. (2008). High-frequency trading in a limit order book. Quantitative Finance, 8(3), 217-224.

[2] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347.

[3] Spooner, T., Fearnley, J., Savani, R., & Koukorinis, A. (2018). Market making via reinforcement learning. In Proceedings of the 17th International Conference on Autonomous Agents and MultiAgent Systems (pp. 434-442).

[4] Raffin, A., Hill, A., Gleave, A., Kanervisto, A., Ernestus, M., & Dormann, N. (2021). Stable-baselines3: Reliable reinforcement learning implementations. Journal of Machine Learning Research, 22(268), 1-8.

[5] Cont, R. (2001). Empirical characteristics of asset returns: Stylized facts. Quantitative Finance, 1(2), 223-236.

[6] Hamilton, J. D. (1989). A new approach to the economic analysis of nonstationary time series and the business cycle. Econometrica, 57(2), 357-384.