Karlsruhe Institute of Technology

Financial Engineering MSc Programı

Yüksek Lisans Tez Taslağı

Farklı Volatilite Rejimleri Altında Pekiştirmeli Öğrenme ile Yüksek Frekanslı Piyasa Yapıcılığı

Onur Emiroğlu

Financial Engineering MSc Programı

Mart 2026 — Sürüm 14

1. ÖZET

Bu çalışmada, volatilite rejim bilgisinin (Düşük/Orta/Yüksek) pekiştirmeli öğrenme tabanlı piyasa yapıcı ajanların performansına katkısı araştırılmaktadır. Proximal Policy Optimization (PPO) algoritması kullanılarak beş varyant ajan eğitilmiştir: yalnızca $\hat{\sigma}$ gözlemleyen (sigma_only), yalnızca rejim etiketi alan (regime_only), her ikisini birden alan (combined), mükemmel rejim bilgisine sahip (oracle_pure ve oracle_full). Ajanlar, Poisson variş süreçli yoğunluk tabanlı dolum modeli ve Markov zinciri rejim geçişleri içeren tamamen sentetik bir piyasa ortamında değerlendirilmiştir.

Yürütülen out-of-sample deney (20 bağımsız tohum, 1 milyon zaman adımı eğitim, %70/%30 kronolojik eğitim/test bölünmesi), tüm PPO varyantlarının Sharpe oranı açısından klasik referans stratejilerini (Avellaneda-Stoikov ve naif sabit-spread) yaklaşık 6–7 kat geçtiğini ortaya koymaktadır. En yüksek Sharpe değerini elde eden varyant ppo_sigma_only (0.753) olmuştur; bu sonuç, $\hat{\sigma}$'nin rejim bilgisini örtük olarak içerdiğini ve açık rejim etiketinin marjinal bilgi taşımadığını deneysel olarak kanıtlamaktadır.

Ana Bulgu (Ablasyon): oracle_full ajanı ($\hat{\sigma} + regime_{true}, Sharpe = 0.722$), mükemmel rejim bilgisine sahip olmasına karşın ppo_sigma_only'yi (0.753) geçememiştir. oracle_full ile combined arasındaki fark istatistiksel olarak anlamsızdır $(p = 0.301)$. Bu sonuç, rejim bilgisinin geriçlılığını kanala bağımsız biçimde doğrulamaktadır.

Detector robustness deneyi — $rv_{baseline}$ $(\%60.7)$, rv_{dwell} $(\%60.4)$ ve HMM $(\%81.8)$ dedektörleri ile 20 tohumda yinelenen analiz — null sonucun dedektör seçiminden bağımsız olduğunu doğrulamaktadır (tüm dedektörler için Sharpe bazlı $p > 0.08$).

Anahtar kelimeler: *piyasa yapıcılığı, pekiştirmeli öğrenme, PPO, volatilite rejimleri, Avellaneda-Stoikov, ablasyon, oracle agent, sinyal yedekliliği*

2. GİRİŞ

Piyasa yapıcılığı (market making), finansal piyasalarda likidite sağlayan ve sürekli olarak hem alış (bid) hem de satış (ask) kotasyonu veren ajanların stratejik davranışını inceleyen bir alandır. Piyasa yapıcılar, spread geliri elde etmeye çalışırken olumsuz fiyat hareketlerine maruz kalan envanter riskini de yönetmek zorundadır.

Klasik yaklaşımlar arasında Avellaneda ve Stoikov (2008) tarafından geliştirilen stokastik kontrol çerçevesi öne çıkmaktadır. Bu model, envanter riskini rezervasyon fiyatı kavramıyla içselleistirerek optimal bid-ask spread'ini analitik olarak türetmektedir. Ancak bu yaklaşım, sabit bir volatilite varsayımına dayanmakta ve piyasa rejimlerindeki değişimlere uyum sağlayamamaktadır.

Bu çalışmanın temel araştırma sorusu şudur: Volatilite rejim bilgisine erişimi olan bir PPO ajanı, bu bilgiden yoksun olan eşdäğerine kıyasla daha iyi performans sergiler mi? Bu soruyu yanıtlamak için aşağıdaki katkılar sunulmaktadır:

- (1) Markov zinciri rejim geçişleri ve Poisson tabanlı dolum modeli içeren kontrollü sentetik bir piyasa ortamı tasarlanmıştır.
- (2) Rejim farkındalığı ablasyonu gerçekleştirilmiş; 5 PPO varyantı 20 bağımsız tohum ile OOS protokolüyle karşılaştırılmıştır.
- (3) Oracle agent deneyi ile mükemmel rejim bilgisinin üst sınır değeri ölçülmüştür.
- (4) Detector robustness analizi gerçekleştirilmiş; null sonucun dedektör seçiminden bağımsızlığı doğrulanmıştır.

3. TEORİ VE METODOLOJİ

3.1 Piyasa Modeli

Piyasa fiyatı, ayrık zamanlı aritmetik Brownian hareketi (ABM) ile modellenmektedir. Rejime bağlı volatilite parametresi σ_r kullanılarak:

$$M_{\{t+1\}} = M_t + \sigma_r \cdot \sqrt{\Delta t} \cdot z, z \sim N(0,1)$$

Başlangıç fiyatı $M_0 = 100.0$, tick büyüklüğü 0.01'dir. Temel volatilite $\sigma_{base} = 0.8\, tick$, rejim çarpanları $[0.6, 1.0, 1.8]$ olup $\sigma_L = 0.48, \sigma_M = 0.80, \sigma_H = 1.44\, tick/\sqrt{saniye}$ değerleri elde edilmektedir.

3.2 Dolum Modeli

Emir dolumları, yoğunluk tabanlı Poisson süreci ile modellenmektedir:

$$\lambda(\delta) = A \cdot exp(-k \cdot \delta), A = 5.0, k = 1.5$$

Bir zaman adımında dolum olasılığı:

$$P_{fill} = 1 - exp(-\lambda \cdot \Delta t)$$

Gecikme modeli $(latency_steps = 1)$ ters seçim riskini içselleistirmektedir.

3.3 Rejim Modeli

Volatilite rejimleri, üç durumlu birinci derece Markov zinciri ile üretilmektedir. Geçiş matrisi yapışkan (sticky) olacak şekilde tasarlanmıştır: köşegen elemanlar [0.9967, 0.9917, 0.9960]. Beklenen rejim süreleri sırasıyla L: ~300, M: ~120, H: ~250 zaman adımıdır.

3.4 Gozlem Uzayı ve Ablasyon Tasarımı

Gözlem uzayı 6 boyutlu ve sabit mimariyle tasarlanmıştır: obs = [q_norm, σ̂, τ, r_L, r_M, r_H]. Beş PPO varyantı, use_sigma ve regime_source parametreleriyle kontrol edilmektedir:

Varyant	use_sigma	regime_source	Gözlemlediği Bilgi
$sigma_{only}$	True	none	$\hat{\sigma}$ — $baseline\ blind$
$regime_{only}$	False	hat	$Yalnızca\ regime_hat$
$combined$	True	hat	$\hat{\sigma} + regime_hat\ (eski\ aware)$
$oracle_{pure}$	False	true	$Yalnızca\ regime_true$
$oracle_{full}$	True	true	$\hat{\sigma} + regime_true$ — $üst\ sınır$

Tüm varyantlar 20 seed, 1M timestep ile eğitilmiş ve OOS test seti üzerinde değerlendirilmiştir.

3.5 Ödül Fonksiyonu

$R_t = (\Delta Equity_t) - \eta \cdot inv_t^2$, $\eta = 0.001$ envanter ceza katsayısı (η ablasyonu ile optimize edilmiştir).

3.6 PPO Eğitimi ve Değerlendirme Protokolü

Stable-Baselines3 kütüphanesi, MlpPolicy mimarisi kullanılmıştır. Eğitim hiperparametreleri: $total_{timesteps} = 1.000.000, learning_{rate} = 0.0003, n_{steps} = 2048,\ batch_{size} = 256,$ $n_{epochs} = 10,\ gamma = 0.999$. Her seed için $\%70$ eğitim, $\%30$ test (kronolojik) bölünmesi. 20 bağımsız tohum.

4. SONUÇLAR VE TARTIŞMA

4.1 Ana Deney Sonuçları (20 Tohum, OOS)

Tablo 1, orijinal WP5 deneyinin (ppo_aware vs ppo_blind) out-of-sample sonuçlarını özetlemektedir.

Strateji	Ort. Equity	Std	Ort. Sharpe	inv_p99	Fill Rate
AS	5.05	4.72	0.105	29.95	0.444
$Naif$	4.49	3.49	0.126	21.20	0.119
ppo_{aware}	4.10	0.78	0.715	2.00	0.236
ppo_{blind}	4.42	0.71	0.740	2.05	0.232

Birinci bulgu — PPO'nun Sharpe Üstünlüğü: Her iki PPO varyantı da Sharpe oranı açısından klasik referans stratejilerini belirgin biçimde aşmaktadır (~6–7×). Bu üstünlüğün temel mekanizması envanter kontroldür: PPO varyantları inv_p99 ≈ 2 tick düzeyinde çalışırken klasik stratejiler 21–30 değerlerine ulaşmaktadır.

Ikinci bulgu — Null Sonuç: ppo_aware, Sharpe bazında 20 tohumun 11'inde ppo_blind'ı geride bırakmıştır. Wilcoxon işaretli sıra testi: p = 0.261 (anlamlı değil). Eşleştirilmiş t-testi (equity): p = 0.023, ppo_blind lehine.

4.2 Pure Ablation Deneyi (Sinyal Yedekliliği Testi)

Motivasyon: Danışmanın temel eleştirisi, σ'nin her iki ajanda da gözlem uzayında mevcut olması nedeniyle aware-blind karşılaştırmasının confounded olduğuydu. Bu deneyle, σ'nin çıkarıldığı ve rejim etiketinin tek bilgi kanalı olduğu kontrollü ablasyon gerçekleştirildi.

Tablo 2, 5 varyantın 20 seed ortalamasını göstermektedir.

Varyant	Sharpe (ort. ± std)	Final Equity (ort. ± std)	inv_p99 (ort. ± std)
ppo_sigma_only	0.753 ± 0.111	4.55 ± 0.65	1.9 ± 0.7
ppo_oracle_full	0.722 ± 0.130	4.07 ± 0.61	2.0 ± 0.5
ppo_regime_only	0.698 ± 0.145	4.01 ± 0.68	2.1 ± 1.5
ppo_combined	0.696 ± 0.134	3.91 ± 0.72	1.8 ± 0.5

ppo_oracle_pure	0.684 ± 0.111	3.93 ± 0.60	1.9 ± 0.6
naive	0.127 ± 0.092	4.49 ± 3.49	21.2 ± 12.2
AS	0.105 ± 0.082	5.05 ± 4.72	29.9 ± 12.6

Kritik Bulgu: ppo_sigma_only en yüksek Sharpe değerini (0.753) elde etmiştir — oracle_full'ı ($\hat{\sigma}$ + regime_true, Sharpe = 0.722) ve combined'ı ($\hat{\sigma}$ + regime_hat, Sharpe = 0.696) geçmektedir. Mükemmel rejim bilgisi bile $\hat{\sigma}$'nin üstüne anlamlı katkı sağlamamaktadır.

4.3 İstatistiksel Testler (Ablasyon)

Tablo 3, 6 temel karşılaştırmanın eşleştirilmiş t-testi sonuçlarını göstermektedir (n=20 seed, Bonferroni düzeltmesi: α = 0.01/12 = 0.00083).

Karşılaştırma	Metrik	t	p-değeri	Cohen's d	Anlamlı?
$sigma_{only}\ vs\ combined$	$Sharpe$	2.014	0.058	0.450	$Hayır$
$sigma_{only}\ vs\ combined$	$Equity$	3.334	0.003	0.746	$Hayır$
$sigma_{only}\ vs\ oracle_{full}$	$Sharpe$	1.651	0.115	0.369	$Hayır$
$sigma_{only}\ vs\ oracle_{full}$	$Equity$	3.789	0.001	0.847	$Hayır$
$oracle_{full}\ vs\ combined$	$Sharpe$	1.062	0.301	0.238	$Hayır$
$oracle_{full}\ vs\ combined$	$Equity$	0.939	0.360	0.210	$Hayır$
$sigma_{only}\ vs\ regime_{only}$	$Equity$	4.510	$2.4e-4$	1.008	$EVET$
$combined\ vs\ AS$	$Sharpe$	16.615	$9.0e-13$	3.715	$EVET$
$combined\ vs\ naive$	$Sharpe$	17.878	$2.4e-13$	3.998	$EVET$

Oracle Paradoksu Özeti: oracle_full vs combined farkı Sharpe'ta p = 0.301, equity'de p = 0.360 — istatistiksel olarak hiçbir anlamlılık yok. Mükemmel etiket, tahmini etiketten ayrt edilemez.

4.4 Eylem Analizi

ppo_aware ajanı, rejimler arasında sınırlı davranışsal farklılaşma sergilemektedir. Tüm rejimlerde ortalama half-spread $h \approx 1.4\text{–}1.8\,tick$, skew $m \approx 0$ civarında kalmaktadır. Bu bulgu, performans düzeyindeki null result ile tutarlıdır.

4.5 Rejim Bazlı Performans Analizi

Her üç rejimde (L, M, H) PPO varyantları AS ve naive baseline'lara kıyasla çok daha düşük envanter riski $(inv_{p99} \approx 2\ vs.\ 20\text{–}28)$ sergilemiştir. Her iki PPO ajanı da düşük volatilite (L) rejiminde en yüksek Sharpe değerlerini kaydetmiştir.

4.6 Detector Robustness Analizi

Detekör	Doğruluk	ppo_aware Sharpe	ppo_blind Sharpe	Sharpe p-değeri
rv_baseline	%60.7	0.718	0.753	0.114
rv_dwell	%60.4	0.716	0.753	0.110
HMM	%81.8	0.719	0.753	0.082

ANOVA testi: F = 0.003, p = 0.997 — ppo_aware performansı dedektör seçimine göre anlamlı biçimde değişmemektedir. Null sonuç, zayıf tespit kalitesinden kaynaklanmamaktadır.

5. SONUÇ

Bu çalışma, volatilite rejimleri altında pekiştirmeli öğrenme tabanlı piyasa yapıcılığını araştırmaktadır. Temel bulgular:

Bulgu 1 — PPO üstünlüğü: Tüm PPO varyantları Sharpe oranı açısından AvellanedaStoikov ve naif referans stratejilerini yaklaşık $6–7\,kat$ geçmiştir. Bu üstünlüğün temel kaynağı envanter yonetimi verimlidir: PPO ajanları $inv_{p99} \approx 2\,tick$ düzeyinde çalışırken klasik stratejiler 21–30 değerlerine ulaşmaktadır.

Bulgu 2 — Null Sonuç (rejim farkındalığı hipotezi reddedilmedi): Rejim bilgisinin ilave edilmesi anlamlı performans artışı sağlamamaktadır. Bu null sonuç, gözlem uzayında hali hazırda bulunan σ̂_t'nin rejim bilgisini örtük olarak içermesinden kaynaklanmaktadır.

Bulgu 3 — Pure Ablation (Sinyal Yedekliliği Kanıtı): ppo_sigma_only $(Sharpe = 0.753)$ en yüksek performansı elde etmiştir — oracle_full'ı $(\hat{\sigma} + regime_{true}, Sharpe = 0.722)$ bile geçmektedir. oracle_full ile combined arasındaki fark istatistiksel olarak anlamsızdır $(p = 0.301)$. Bu sonuç, sinyal yedekliliği argümanını deneysel olarak kanıtlamaktadır.

Bulgu 4 — Detekör Bağımsızlığı: Null sonuç, $\%60.7$'dan $\%81.8$'e kadar üç farklı dedektör performansında tutarlı biçimde korunmuştur $(ANOVA: F = 0.003, p = 0.997)$.

Gelecek Çalışmalar

- (1) Rejime koşullu ödül tasarımı $(\eta_H > \eta_L)$.
- (2) Model yanlış belirleme (model misspecification) benchmark'ı — AS parametrelerinin (A, k) rejime bağlı kılınması.
- (3) Paper yayını: iyi nitelendrilmiş null result ile kontrollü RL vs. klasik piyasa yapıcılığı kıyaslaşması.

KAYNAKLAR

[1] Avellaneda, M., & Stoikov, S. (2008). High-frequency trading in a limit order book. Quantitative Finance, 8(3), 217-224.

[2] Schulman, J., et al. (2017). Proximal policy optimization algorithms. arXiv:1707.06347.

[3] Spooner, T., et al. (2018). Market making via reinforcement learning. AAMAS.

[4] Raffin, A., et al. (2021). Stable-baselines3. Journal of Machine Learning Research, 22(268).

[5] Cont, R. (2001). Empirical characteristics of asset returns. Quantitative Finance, 1(2).

[6] Hamilton, J. D. (1989). A new approach to the economic analysis of nonstationary time series. Econometrica, 57(2).