

Karlsruhe Institute of Technology

Financial Engineering MSc Programı

Yüksek Lisans Tez Taslağı

Farklı Volatilité Rejimleri Altında Pekiştirmeli Öğrenme ile Yüksek Frekanslı Piyasa Yapıcılığı

Onur Emiroğlu

Financial Engineering MSc Programı

Mayıs 2026 — Sürüm 30

1. ÖZET

Bu çalışmada, volatilité rejim bilgisinin (Düşük/Orta/Yüksek) pekiştirmeli öğrenme tabanlı piyasa yapıcı ajanların performansına katkısı araştırılmaktadır. Proximal Policy Optimization (PPO) algoritması kullanılarak beş ajan varyantı eğitilmiştir: yalnızca sigma (ppo_sigma_only), yalnızca rejim (ppo_regime_only), sigma + tahmini rejim (ppo_combined), yalnızca gerçek rejim (ppo_oracle_pure) ve sigma + gerçek rejim (ppo_oracle_full). Ajanlar, Poisson varış süreçli yoğunluk tabanlı dolum modeli ve Markov zinciri rejim geçişleri içeren tamamen sentetik bir piyasa ortamında değerlendirilmiştir.

Yürütülen out-of-sample deney (20 bağımsız tohum, 1 milyon zaman adımı eğitim, %70/%30 kronolojik eğitim/test bölünmesi), tüm PPO varyantlarının Sharpe oranı açısından klasik referans stratejilerini (Avellaneda-Stoikov ve naif sabit-spread) yaklaşık 6-7 kat geçtiğini ortaya koymaktadır. Buna karşın, rejim bilgisinin PPO performansına net bir katkı sağladığı hipotezi yalnızca istatistiksel olarak desteklenmemekle kalmamış; ppo_sigma_only ile ppo_oracle_full'un Sharpe performansları TOST eşdeğerlik testi ile pratik olarak eşdeğer bulunmuştur (TOST $p < 0.05$, ± 0.10 sınır).

Ana Bulgu (Ablasyon): oracle_full ajanı (sigma + regime_true), mükemmel rejim etiketlerine sahip olmasına karşın ppo_sigma_only'yi istatistiksel olarak anlamlı biçimde geçememiştir (Sharpe: 0.753 vs 0.722, $p = 0.115$). Bu sonuç, rejim etiketinin — gerçek ya da tahmini — sigma_hat'in zaten taşıdığı bilginin üzerine anlamlı katkı sağlamadığı hipoteziyle güçlü biçimde tutarlıdır.

Detector robustness deneyi — rv_baseline (%60.7), rv_dwell (%60.4) ve HMM (%81.8) dedektörleri ile 20 tohumda yinelenen analiz — null sonucun dedektör seçiminden bağımsız olduğunu doğrulamaktadır (tüm dedektörler için Sharpe bazlı $p > 0.08$). Oracle deneyi ise %100 doğrulukla eşdeğer bir test sunmaktadır: ppo_oracle_full mükemmel rejim bilgisiyle dahi sigma_only'yi geçememiştir ($p=0.115$).

Model misspecification robustness deneyi kapsamında fill model parametreleri A ve k rejime bağlı kılınmış (L: $A=4.0/k=1.8$, M: $A=5.0/k=1.5$, H: $A=6.0/k=1.2$) ve 5-varyant değerlendirmesi bu zorlaştırılmış ortamda yinelenmiştir. ppo_sigma_only yine en yüksek Sharpe değerini elde etmiş (0.686); oracle_full ile aradaki fark istatistiksel olarak anlamsız kalmıştır ($p=0.881$). Bu bulgu, signal redundancy argümanının çevresel koşullara karşı da sağlam olduğunu göstermektedir.

Sinyal informativeness sweep'i (WP6), kategorik regime label'larının sigma_hat sürekli sinyali zayıfladığında dahi performansı iyileştirmediğini, hatta birlikte kullanıldığında yönsel olarak düşürdüğünü göstermiştir. Buna eklenen post-hoc tanı analizleri, observed categorical labels'ın source-calibrated sigma_hat'ten yüksek doğrulukla recover edilebildiğini ve sigma_hat gözlemlendikten sonra sınırlı incremental predictive value sunduğunu göstererek sinyal-yedekliliği yorumunu daha da desteklemektedir.

Anahtar kelimeler: piyasa yapıcılığı, pekiştirmeli öğrenme, PPO, volatilité rejimleri, Avellaneda-Stoikov, ablasyon, oracle agent, sinyal yedekliliği, post-hoc tanı analizleri, model yanlış belirleme

SEMBOLLER VE KISALTMALAR

Bu bölümde çalışma boyunca kullanılan matematiksel semboller, Yunan harfleri ve kısaltmalar tanımlanmaktadır.

Matematiksel Semboller

Sembol	Açıklama
M_t	t anındaki mid-price (orta fiyat) [para birimi]
σ	Volatilité parametresi — mid-price'ın birim zamandaki standart sapması [tick/ $\sqrt{\text{saniye}}$]
σ_{base}	Temel volatilité parametresi; Orta (M) rejim için referans değer (0.8 tick/ $\sqrt{\text{saniye}}$)
$\sigma_L, \sigma_M, \sigma_H$	Düşük, Orta ve Yüksek rejimlere karşılık gelen volatilité değerleri
Δt	Simülasyon zaman adımı büyüklüğü (0.2 saniye)
z	Standart normal rassal değişken; $z \sim N(0,1)$
$\lambda(\delta)$	δ tick uzaklığındaki kotasyon için Poisson dolum yoğunluğu [dolum/saniye]
A	Sıfır uzaklıkta ($\delta=0$) temel dolum yoğunluğu (5.0 dolum/saniye)

k	Dolum yoğunluğunun uzaklıkla üstel azalma hızı (1.5 tick başına)
δ	Kotasyon uzaklığı — bid veya ask fiyatının mid-price'tan tick cinsinden sapması
δ_{bid}	Bid (alış) kotasyonunun mid-price'tan uzaklığı [tick]
δ_{ask}	Ask (satış) kotasyonunun mid-price'tan uzaklığı [tick]
P_fill	Bir zaman adımında en az bir dolumun gerçekleşme olasılığı
h	Half-spread — kotasyon yarı-aralığı [tick]; $h \in \{1, 2, 3, 4, 5\}$
m	Skew — asimetrik kotasyon kayması [tick]; $m \in \{-2, -1, 0, +1, +2\}$
q	Envanter (inventory) — anda tutulan net pozisyon miktarı [lot]
q_norm	Normalize edilmiş envanter; $q_{norm} = q / inv_max_clip \in [-1, +1]$
inv_max_clip	Envanter kırma sınırı (50 lot)
τ	Kalan zaman fraksiyonu; $\tau = (T - t) / T \in [0, 1]$
T	Episode toplam adım sayısı (8000 adım)
R_t	t adımıdaki ödül (reward)
η	Envanter ceza katsayısı; $\eta = 0.001$
γ	Avellaneda-Stoikov risk aversion parametresi; $\gamma = 0.01$
r	Avellaneda-Stoikov rezervasyon fiyatı
d	Avellaneda-Stoikov optimal yarı-spread
k_price	Fiyat cinsinden ifade edilen yoğunluk azalma parametresi; $k_price = k / tick_size$
P	Markov zinciri geçiş matrisi (3×3)
Sharpe	Sharpe oranı — risk-düzeltilmeli getiri ölçütü; $Sharpe = (\mu/\sigma) \times \sqrt{1/\Delta t}$
inv_p99	Mutlak envanter değerinin 99. persantili [lot]
equity	Toplam varlık değeri; $equity = cash + q \times M_t$

Yunan Harfleri

Sembol	Açıklama
γ (gamma)	Risk aversion parametresi (Avellaneda-Stoikov modelinde)
η (eta)	Envanter ceza katsayısı (ödül fonksiyonunda)
σ (sigma)	Volatilite — fiyat değişiminin standart sapması
τ (tau)	Kalan zaman fraksiyonu
λ (lambda)	Poisson dolum yoğunluğu

δ (delta)	Kotasyon uzaklığı (mid-price'tan tick cinsinden sapma)
μ (mu)	Ortalama adım başına PnL (Sharpe hesabında)

Kısaltmalar

Kısaltma	Açıklama
PPO	Proximal Policy Optimization — yakınsak politika optimizasyonu algoritması
RL	Reinforcement Learning — pekiştirmeli öğrenme
AS	Avellaneda-Stoikov — klasik stokastik kontrol tabanlı piyasa yapıcılığı modeli
HFT	High-Frequency Trading — yüksek frekanslı alım-satım
OOS	Out-of-Sample — modelin eğitilmediği veri üzerinde değerlendirme
WP	Work Package — iş paketi (proje aşaması)
ABM	Arithmetic Brownian Motion — aritmetik Brownian hareketi
RV	Realized Volatility — gerçekleşmiş volatilité (kayan pencere ile hesaplanan)
PnL	Profit and Loss — kar ve zarar
CUDA	Compute Unified Device Architecture — NVIDIA GPU hesaplama mimarisi
SB3	Stable-Baselines3 — PPO implementasyonu için kullanılan Python kütüphanesi
MlpPolicy	Multi-Layer Perceptron Policy — çok katmanlı algılayıcı politika ağı
GAE	Generalized Advantage Estimation — genelleştirilmiş avantaj tahmini (PPO bileşeni)
L / M / H	Low / Medium / High — Düşük / Orta / Yüksek volatilité rejimleri

TERİMLER SÖZLÜĞÜ

Bu sözlük, çalışmada kullanılan teknik terimleri konuya aşina olmayan okuyucular için tanımlamaktadır. Terimler alfabetik sıraya göre düzenlenmiştir.

Terim	Tanım
Ablation (Ablasyon)	Bir modelin belirli bir bileşeninin çıkarılarak ya da devre dışı bırakılarak etkisinin ölçülmesi amacıyla yapılan kontrollü deney.
Action Space (Eylem Uzayı)	Bir pekiştirmeli öğrenme ajanının her adımda seçebileceği tüm olası eylemlerin

	kümesi. Bu çalışmada half-spread (h) ve skew (m) değerlerinden oluşan ayırık bir yapıdadır.
Adverse Selection (Ters Seçim)	Piyasa yapıcının bilgili yatırımcılara karşı dezavantajlı konuma düşmesi durumu.
Agent (Ajan)	Pekiştirmeli öğrenmede, bir ortamda gözlem yaparak karar veren ve ödül sinyaline göre davranışını güncelleyen öğrenen sistem.
Ask (Satış Fiyatı)	Piyasa yapıcının satmaya hazır olduğu fiyat. Her zaman bid fiyatının üzerindedir.
Bid (Alış Fiyatı)	Piyasa yapıcının almaya hazır olduğu fiyat. Her zaman ask fiyatının altındadır.
Bid-Ask Spread	Alış ve satış fiyatı arasındaki fark. Piyasa yapıcının temel gelir kaynağıdır.
Brownian Motion	Rastlantısal yürüyüş modellerinin sürekli-zaman limiti. ABM'de fiyat değişimleri normal dağılımdan çekilmektedir.
Clip (Kırpma)	Bir değer belirlenir bir aralıkla sınırlandırılması işlemi. Bu çalışmada envanter ± 50 lot ile kırılmaktadır.
Convergence (Yakınsama)	Pekiştirmeli öğrenme eğitiminde politikanın optimal ya da kararlı bir çözüme ulaşması süreci.
Entropy Coefficient	PPO'da keşif-sömürü dengesini ayarlayan hiperparametre. Bu çalışmada ent_coef=0.01 kullanılmıştır.
Episode	Pekiştirmeli öğrenmede başlangıçtan bitiş koşuluna kadar süren bir tam simülasyon koşusu. Bu çalışmada 8000 zaman adımından oluşmaktadır.
Exogenous Series (Dışsal Seri)	Modelin dışında önceden üretilmiş ve tüm stratejilere aynı biçimde sunulan fiyat/volatilité serisi.
Fill (Dolum)	Piyasa yapıcının kotasyon verdiği fiyattan gerçekleşen emir eşleşmesi.
Fill Rate (Dolum Oranı)	Toplam adım sayısına bölünen dolum sayısı.
Gymnasium	OpenAI tarafından geliştirilen, pekiştirmeli öğrenme ortamları için standart Python arayüzü.
Half-Spread (Yarı-Aralık)	Bid veya ask fiyatının mid-price'tan uzaklığı. Bu çalışmada h sembolüyle gösterilir.
Inventory (Envanter)	Piyasa yapıcının anda elinde bulundurduğu net pozisyon miktarı.
Inventory Risk (Envanter Riski)	Piyasa yapıcının büyük envanter pozisyonu tutarken fiyat hareketleri nedeniyle maruz kaldığı zarar riski.

Latency (Gecikme)	Piyasa yapıcının kotasyon güncellemesi ile piyasanın bu güncellemeyi işlemesi arasındaki zaman farkı.
Limit Order Book	Bekleme sırasındaki tüm alış ve satış emirlerinin fiyat-miktar listesi.
Markov Chain	Gelecekteki durumun yalnızca mevcut duruma bağlı olduğu olasılıksal süreç.
Market Making (Piyasa Yapıcılığı)	Finansal piyasalarda sürekli alış ve satış kotasyonu vererek likidite sağlama faaliyeti.
Mid-Price	Anlık alış (bid) ve satış (ask) fiyatlarının ortalaması.
Model Misspecification (Model Yanlış Belirleme)	Modelin varsayımlarının gerçek veri üretim sürecinden sapması durumu. Bu çalışmada fill parametrelerinin rejime bağlı kılınmasıyla test edilmiştir.
Null Result	Araştırma hipotezinin verilerce desteklenmediği bulgu.
Observation Space (Gözlem Uzayı)	Ajanın her adımda çevreden aldığı bilginin vektör temsili. Bu çalışmada 6 boyutludur: $[q_norm, \hat{o}, \tau, r_L, r_M, r_H]$.
One-Hot Encoding	Kategorik bir değişkeni ikili vektörle temsil etme yöntemi.
Out-of-Sample (OOS)	Modelin eğitilmediği, bağımsız bir veri kümesi üzerinde yapılan değerlendirme.
Percentile (Persantil)	Veri setinin belirli bir yüzdesinin altında kaldığı değer.
Policy (Politika)	Pekiştirmeli öğrenmede ajanın gözleme göre eylem seçme stratejisi.
Poisson Process	Olayların bağımsız ve sabit ortalama hızda rastlantısal gerçekleştiği olasılıksal süreç.
PPO	John Schulman ve ark. (2017) tarafından geliştirilen politika gradyanı tabanlı RL algoritması.
Regime (Rejim)	Piyasanın belirli bir volatilité seviyesinde bulunduğu dönem. Bu çalışmada L/M/H.
Risk-Adjusted Return	Getirinin, üstlenilen risk miktarına bölünmesiyle elde edilen performans ölçütü.
Seed (Tohum)	Rastlantısal sayı üreticinin başlangıç değeri. Tekrarlanabilirlik için kullanılır.
Sharpe Ratio	Birim risk başına elde edilen fazla getiriye ölçen performans metriği.
Skew (Asimetrik Kotasyon)	Bid ve ask kotasyonlarının mid-price'a göre eşit olmayan biçimde kaydırılması.
Stable-Baselines3 (SB3)	PPO dahil çeşitli RL algoritmalarının güvenilir PyTorch implementasyonlarını içeren Python kütüphanesi.
Sticky Transition Matrix	Köşegen elemanları yüksek Markov geçiş

	matrisi. Rejimlerin uzun süre devam etmesini sağlar.
Tick	Finansal piyasalarda fiyatın alabileceği en küçük artış birimi. Bu çalışmada tick_size = 0.01.
Timestep (Zaman Adımı)	Simülasyonun bir sonraki duruma geçtiği en küçük zaman birimi. $\Delta t = 0.2$ saniye.
Chronological Train/Test Split	Zaman serisi verisinin kronolojik sıraya göre eğitim (%70) ve test (%30) kümelerine bölünmesi.

2. GİRİŞ

Piyasa yapıcılığı (market making), finansal piyasalarda likidite sağlayan ve sürekli olarak hem alıř (bid) hem de satıř (ask) kotasyonu veren ajanların stratejik davranıřını inceleyen bir alandır. Piyasa yapıcılar, spread geliri elde etmeye çalışırken olumsuz fiyat hareketlerine maruz kalan envanter riskini de yönetmek zorundadır. Bu denge, özellikle volatilitenin deęiřken olduęu yüksek frekanslı piyasalarda kritik önem taşımaktadır.

Klasik piyasa yapıcılığı literatürü, özellikle Avellaneda-Stoikov çerçevesi, envanter riski ve volatilitenin kotasyon kararlarındaki merkezi rolünü göstermektedir. Bu tez bu geleneęi analitik bir referans strateji olarak korurken, asıl olarak öğrenilmiř PPO politikalarında volatilitenin nasıl temsil edildięini sınamaktadır.

Bu çalışmanın temel araştırma sorusu řudur: PPO politikasının gözleminde sürekli bir gerçekteřmiř volatilitenin vekili olan σ_{hat} zaten mevcutken, açık kategorik volatilitenin rejim etiketi sağlam ve ek performans deęeri üretir mi? Bu soruyu yanıtlamak için ařaęıdaki katkılar sunulmaktadır:

- (1) Markov zinciri rejim geçiřleri ve Poisson tabanlı dolum modeli ieren kontrollü sentetik bir piyasa ortamı tasarlanmıřtır.
- (2) Gözlem uzayı ablasyonu gerçekteřtirilmiř; σ_{hat} , tahmini rejim etiketi, gerçekte rejim etiketi ve bunların birleřimlerini kullanan 5 PPO varyantı 20 bağımsız tohum ile OOS protokolüyle karřılařtırılmıřtır.
- (3) Oracle agent deneyi ile mükemmel rejim bilgisinin üst sınır deęeri ölçölmüřtür.
- (4) Detector robustness, rejime kořullu ödöl, model misspecification ve sinyal bilgilendiricilięi analizleriyle bulgunun duyarlılıęı deęerlendirilmiřtir.

Elde edilen kanıtlar, test edilen sentetik HFMM ortamında açık kategorik rejim etiketlerinin σ_{hat} 'in ötesinde sağlam bir ek performans deęeri sağlamadıęı ve bulguların sinyal yedeklilięi yorumu ile tutarlı olduęu yönündedir. Bu sonuç volatilitenin rejimlerinin önemsiz olduęu anlamına gelmez; yalnızca bu kontrollü gözlem tasarımıyla kategorik etiketin ek deęerini sınırlar.

3. LİTERATÜR TARAMASI / RELATED WORK

3.1 Classical Market Making and Inventory Risk

The modern theoretical foundation for high-frequency market making is closely linked to inventory-aware stochastic control. A market maker earns spread income by continuously posting bid and ask quotes, but this activity exposes the agent to inventory risk: if buy and sell executions are imbalanced, the agent accumulates a position whose value fluctuates with the mid-price. The central control problem is therefore to trade off spread capture, adverse price movements, execution probability, and inventory control.

Avellaneda and Stoikov (2008) provide the canonical analytical framework for this trade-off. Their model derives a reservation price that shifts with inventory and a spread component that depends on risk aversion, volatility, horizon, and order-arrival intensity. In this thesis, the Avellaneda-Stoikov framework is important for two reasons. First, it gives a principled baseline against which learned policies can be compared. Second, it clarifies why volatility and inventory are natural state variables in a market-making problem: volatility affects the risk of carrying inventory, while inventory affects the desired direction and aggressiveness of quoting.

Guéant, Lehalle and Fernandez-Tapia (2013) extend this line of work by developing tractable solutions for inventory-risk management in market making. Their contribution strengthens the stochastic-control interpretation of quote placement and provides a bridge between the original Avellaneda-Stoikov formulation and more implementable inventory-aware quoting rules. For the present thesis, this work supports the use of an analytical benchmark and reinforces the role of inventory aversion. The reward design used here, which penalizes squared inventory through an inventory penalty parameter, follows the same economic logic: market-making performance should not be evaluated only by gross spread capture, but also by the risk created by accumulated positions.

Fodra and Labadie (2012) further broaden the classical market-making view by considering inventory constraints and directional bets. Although their work is a preprint and should be cited with that status made explicit, it is useful for motivating the idea that market makers may condition quotes on more than inventory alone. Fodra and Labadie (2013), also a preprint, extend market making to multi-dimensional Markov processes, including state variables such as spread, stochastic volatility, and order intensities. This is especially relevant because it frames market making as a state-dependent control problem rather than a fixed-parameter optimization problem.

The thesis adopts a deliberately controlled version of this tradition. The simulator uses a Poisson-arrival fill model in which execution intensity decays with quote distance, echoing the exponential-intensity structure common in analytical market-making models. The Avellaneda-Stoikov strategy is retained as an interpretable classical baseline. At the same time, the thesis departs from the closed-form setting by training PPO agents in a Gymnasium environment and by exposing them to inventory, remaining horizon, a

continuous realized-volatility proxy $\hat{\sigma}$, and optional categorical regime labels. The classical literature therefore motivates the state and reward design, but it does not answer the thesis's central incremental-value question: whether a categorical volatility-regime label adds robust performance value once $\hat{\sigma}$ is already observed.

3.2 Reinforcement Learning for Market Making

Reinforcement learning provides a natural extension of classical market-making models because quote placement is sequential, stochastic, and reward-driven. Rather than deriving a closed-form quote rule under restrictive assumptions, an RL agent can learn a policy from simulated market interaction. The agent observes a state, chooses bid and ask quote parameters, receives executions and price movements, and updates its policy according to a reward signal. This setup is well aligned with high-frequency market making, where inventory, execution risk, and changing market conditions interact over many short time steps.

Spooner et al. (2018) are a central reference for reinforcement learning applied to market making. Their study demonstrates that an RL agent can learn market-making behavior in a limit-order-book simulation and that reward specification is crucial for the learned strategy. This is directly relevant to the thesis, which uses PPO to learn quoting decisions and evaluates policies through risk-adjusted metrics and inventory behavior. The reward formulation follows this logic by combining mark-to-market performance with an explicit inventory penalty, so that learned policies are not rewarded for accumulating excessive directional exposure. However, the focus here is narrower. The thesis uses PPO as a controlled testbed for a specific state-representation question.

Spooner and Savani (2020) extend the RL market-making discussion toward robustness by introducing adversarial reinforcement learning. Their work is useful because market-making policies can be sensitive to market conditions, simulator assumptions, and reward design. In this thesis, robustness is considered through out-of-sample evaluation, multiple random seeds, detector comparisons, oracle-label variants, model-misspecification checks, and signal-informativeness sweeps. The thesis's robustness question, however, is not adversarial training. It is whether the observed conclusion about regime labels remains stable when the regime signal is estimated, perfect, degraded, or compared with a continuous volatility proxy.

Gašperov and Kostanjčar (2021) are especially relevant because they study market making with signals through deep reinforcement learning. Their work supports the broader idea that external or derived signals can be incorporated into the state representation of a market-making agent. This is close to the conceptual motivation of the thesis: volatility-regime labels are a form of state information that might help an agent adapt quotes across changing conditions. The distinction is that the thesis asks whether a categorical volatility-regime signal adds incremental value when a related continuous signal, $\hat{\sigma}$, is already included in the observation.

Gašperov et al. (2021) provide a broader review and discussion of reinforcement-learning approaches to optimal market making. Their work helps situate design choices such as the state vector, action representation, reward function, evaluation protocol, and comparison to baselines. The thesis fits within this family of RL market-making studies, but it contributes a focused ablation design: variants that observe $\hat{\sigma}$, categorical regime labels, both, or oracle regime labels are compared under the same synthetic market-generation process.

Gašperov and Kostanjčar (2022) introduce a Hawkes-process-based limit-order-book simulator for deep reinforcement learning in market making. This study is important because it illustrates how richer event-dynamics models can make the simulated environment more detailed. By contrast, the present thesis intentionally uses a simpler Poisson-arrival fill model and a synthetic Markov volatility-regime process. This simplification allows the thesis to isolate the incremental informational role of the regime label under controlled conditions.

Taken together, the RL and DRL market-making literature motivates learned quoting policies, careful reward design, signal-rich observations, and robustness checks. The remaining gap is not whether RL can be used for market making, nor whether market states can matter. The gap is whether a particular form of state representation, an explicit categorical volatility-regime label, provides additional performance value beyond an already observed continuous volatility proxy.

3.3 Volatility Regimes, Non-Stationarity, and State Representation

Volatility regimes and non-stationarity are central to market-making problems. When volatility increases, inventory risk rises, execution probabilities may change, and quote placement should often become more conservative. When volatility decreases, narrower spreads may become more attractive.

The literature on state-dependent market making provides a useful way to frame this issue. Fodra and Labadie (2013) model market making under multi-dimensional Markov processes, allowing relevant market variables to enter the control problem explicitly. This supports the idea that state representation is not a cosmetic modeling choice: the variables made available to the policy determine what adaptations are possible. In this thesis, volatility is represented in two related ways. The first is continuous, through $\hat{\sigma}$, a rolling realized-volatility proxy available directly to the policy. The second is categorical, through low, medium, and high labels that discretize volatility-regime information.

Zimmer and Costa (2025), a recent preprint, also connect reinforcement-learning market making with non-stationary limit-order-book dynamics. Their work is useful as recent context because it emphasizes that market-making agents may need to adapt to changing order-book regimes rather than operate under one stationary environment. The thesis shares the broad concern with non-stationarity, but it does not pursue a broad non-stationary LOB model. Instead, it creates a controlled synthetic environment in which volatility regimes are generated by a Markov chain and detected through realized-volatility methods. This design makes the source of non-stationarity explicit and testable.

The key point is that the importance of regimes does not automatically imply that categorical regime labels improve a learned policy. If the continuous volatility proxy already contains the relevant information, then a label derived from related volatility information may be redundant. Conversely, if the label summarizes information not captured by $\hat{\sigma}$, it could improve performance. The question is how market conditions should be represented in the policy state and whether the categorical representation adds incremental value in the tested synthetic environment.

3.4 Signal Redundancy and the Thesis Gap

Existing market-making studies often enrich the agent's state with signals, market states, or non-stationary features. This is a natural modeling direction: more informative observations can, in principle, allow a policy to adapt better. However, adding a signal does not by itself imply improved performance. If the signal is noisy, delayed, coarsened, highly correlated with another state variable, or difficult for the policy to exploit, it may provide little practical benefit.

This creates the exact thesis gap. The literature motivates volatility, regimes, and signals, but it usually does not isolate whether a categorical volatility-regime label adds incremental value once a continuous realized-volatility proxy is already observed. A categorical label may appear informative when considered alone, but its incremental contribution depends on what the policy already knows. If $\hat{\sigma}$ already tracks the volatility state sufficiently for quote adaptation, then a low/medium/high label may not improve out-of-sample performance.

The thesis is designed around this incremental-value question. It does not reject the economic relevance of volatility regimes, and it does not identify the internal computation learned by PPO. Instead, it tests a narrower proposition: in a controlled synthetic high-frequency market-making environment, do explicit categorical volatility-regime labels add robust performance value beyond $\hat{\sigma}$?

The empirical conclusion should be stated carefully. In the tested synthetic environment, the evidence is consistent with signal redundancy: explicit labels do not provide robust additional performance beyond the continuous volatility signal. This wording matters. "Consistent with signal redundancy" is an interpretation supported by the ablations and diagnostics; it does not establish the internal PPO decision mechanism. The thesis's contribution is therefore a bounded empirical finding: in this controlled design, categorical regime labels should be evaluated for incremental value rather than assumed to improve performance.

3.5 Equivalence Testing and Null-Result Interpretation

A final methodological issue is how to interpret the absence of an observed improvement. In many empirical studies, a result with $p > 0.05$ is treated informally as "no effect." This is not sufficient for the present thesis. Failure to reject a null hypothesis does not show that

two strategies are practically similar; it may simply reflect limited power, noisy estimates, or an imprecise experimental design.

Lakens (2017) provides a practical introduction to equivalence testing and explains why researchers should distinguish between "not statistically significant" and "statistically equivalent within a meaningful range." Lakens, Scheel and Isager (2018) further develop this logic through a tutorial treatment of equivalence testing and the two one-sided tests procedure. These methodological sources are directly relevant to the thesis's interpretation of null results.

The thesis uses this logic to avoid relying only on conventional significance tests. When comparing PPO variants, the relevant question is not only whether one variant significantly outperforms another. It is also whether the observed difference is small enough to be treated as practically negligible under a pre-specified equivalence bound. In plain terms, TOST asks whether the entire plausible range of the observed difference is small enough to fall within a pre-specified practical-equivalence band.

This framing is especially important for the regime-label result. If a regime-aware variant does not significantly outperform ``sigma_only``, that alone would be weak evidence. But if the difference is also compatible with practical equivalence under a stated margin, the conclusion becomes stronger and more precise: the thesis finds no robust incremental value from explicit regime labels in the tested synthetic environment. This remains a bounded claim. It means that, under the thesis design and evaluation protocol, the categorical regime channel does not deliver reliable additional performance once ``sigma_hat`` is already observed.

4. TEORİ VE METODOLOJİ

4.1 Piyasa Modeli

Piyasa fiyatı, ayrık zamanlı aritmetik Brownian hareketi (ABM) ile modellenmektedir:

$$M_{t+1} = M_t + \sigma_r \cdot \sqrt{\Delta t} \cdot z, \quad z \sim N(0,1)$$

Burada M_t mid-price, σ_r rejime bağlı volatilité parametresi (ticks/ $\sqrt{\text{saniye}}$ cinsinden), $\Delta t = 0.2$ saniye zaman adımı büyüklüğüdür. Başlangıç fiyatı $M_0 = 100.0$, tick büyüklüğü 0.01'dir.

Temel volatilité parametresi $\sigma_{\text{base}} = 0.8$ tick olarak belirlenmiş; üç rejim için çarpanlar $[0.6, 1.0, 1.8]$ olarak tanımlanmıştır. Buna göre $\sigma_L = 0.48$, $\sigma_M = 0.80$, $\sigma_H = 1.44$ tick/ $\sqrt{\text{saniye}}$ değerleri elde edilmektedir.

4.2 Dolum Modeli

Emir dolumları, yoğunluk tabanlı Poisson süreci ile modellenmektedir. Delta tick cinsinden ifade edildiğinde, dolum yoğunluğu:

$$\lambda(\delta) = A \cdot \exp(-k \cdot \delta)$$

formülüyle hesaplanmaktadır. Burada $A = 5.0$ ($\Delta t=0$ 'daki temel yoğunluk, dolum/saniye) ve $k = 1.5$ (tick başına üstel azalma) parametreleridir. Bir zaman adımında en az bir dolumun gerçekleşme olasılığı:

$$P_{\text{fill}} = 1 - \exp(-\lambda \cdot \Delta t)$$

olarak verilmektedir. Hem bid hem ask tarafı için bağımsız Bernoulli denemeleri gerçekleştirilmektedir.

Gecikme modeli ($\text{latency_steps} = 1$), ajanın kotasyon hesaplamasında bir önceki adımın mid-price değerini kullanmasına yol açmaktadır; bu durum ters seçim (adverse selection) riskini içselleştirmektedir. Komisyon ücreti her işlem için 0.2 baz puan olarak uygulanmaktadır.

4.3 Rejim Modeli

Volatilité rejimleri, üç durumlu (L: Düşük, M: Orta, H: Yüksek) birinci derece Markov zinciri ile üretilmektedir. Geçiş matrisi yapışkan (sticky) olacak şekilde tasarlanmıştır:

$$P = \begin{bmatrix} 0.9967 & 0.0023 & 0.0010 \\ 0.0042 & 0.9917 & 0.0041 \\ 0.0010 & 0.0030 & 0.9960 \end{bmatrix}$$

Beklenen rejim süreleri sırasıyla L: ~300, M: ~120, H: ~250 zaman adımındır. Bu yapışkanlık, kayan gerçekleşmiş volatilité (rolling realized volatility — RV) ile rejim tespiti için mümkün olmasını sağlamaktadır.

Rejim tespiti için RV pencere boyutu 50 adım, ısınma süresi (warmup) 1000 adım olarak belirlenmiştir. Eşik değerleri ısınma döneminin 33. ve 66. persentillerinden kalibre edilmektedir. Gerçek zamanlı tespitte look-ahead bias engellenmiştir; regime_hat yalnızca geçmiş veriden hesaplanmaktadır. Elde edilen tespit doğruluğu %60.7'dir (rastgele sınır: %33.3).

Detector robustness analizi kapsamında iki ek tespit yöntemi karşılaştırılmıştır: (i) dwell filtreli RV (rv_dwell): kısa süreli (< 5 adım) rejim geçişlerini düzelterek filtre uygulanmış, tespit doğruluğu %60.4 olarak elde edilmiştir; (ii) Gaussian HMM (hmm): sigma_hat serisi üzerinde eğitilen üç durumlu Gaussian gizli Markov modeli, %81.8 doğruluk ile en yüksek tespit kalitesini sağlamıştır.

Not: rv_dwell offline bir dwell smoothing kullanır ve etiket kararı verilirken sınırlı bir ileri tarama içerir (en fazla min_dwell adım); bu nedenle rv_dwell doğruluk değeri kausal bir üst sınır olarak okunmalıdır. Bu sınırlama yalnızca §4.3 ve §5.6'da raporlanan rv_dwell metriklerini etkiler; tezde raporlanan tüm ana boru hatları — WP4 pilot, WP5 OOS değerlendirmesi ve WP6 sweep — kausal rv_baseline detector'ı kullandığından, Bulgu 1-7 bu sınırlamadan etkilenmemiştir.

4.4 Gymnasium Ortamı

OpenAI Gymnasium uyumlu MMEnv ortamı oluşturulmuştur. Gözlem uzayı 6 boyutludur:

obs = [q_norm, $\hat{\sigma}_t$, τ , r_L, r_M, r_H]

Burada q_norm = clip(inv, -50, 50) / inv_max_clip envanter normalizasyonu, $\hat{\sigma}_t$ kayan gerçekleşmiş volatilité, $\tau = (T-t)/T$ kalan zaman fraksiyonu, r_L/r_M/r_H ise rejim one-hot kodlamasıdır (ppo_blind için hepsi sıfır).

Eylem uzayı MultiDiscrete([5, 5]) olarak tanımlanmıştır:

$h_idx \in \{0,1,2,3,4\} \rightarrow h = h_idx + 1$ tick (half-spread)

$m_idx \in \{0,1,2,3,4\} \rightarrow m = m_idx - 2$ tick (skew)

$\delta_bid = \max(1, h + m)$

$\delta_ask = \max(1, h - m)$

4.5 Referans Stratejiler

4.5.1 Naif Sabit-Spread Stratejisi

Her zaman adımında simetrik sabit half-spread uygulanmaktadır: $\delta_bid = \delta_ask = h = 2$ tick. Envanter farkındalığı veya skew mekanizması içermemektedir.

4.5.2 Avellaneda-Stoikov Stratejisi

Rezervasyon fiyatı ve yarı-spread şu formüllerle hesaplanmaktadır:

$$r = \text{mid} - q \cdot \gamma \cdot \sigma^2 \cdot \tau$$

$$d = \frac{1}{2} \cdot \gamma \cdot \sigma^2 \cdot \tau + (1/\gamma) \cdot \ln(1 + \gamma/k_price)$$

Burada $\gamma = 0.01$ risk aversion parametresi, $k_price = k_ticks / \text{tick_size}$ fiyat cinsinden yoğunluk azalma parametresidir. Delta değerleri [1, 25] tick aralığında kırılmaktadır.

4.6 Ödül Fonksiyonu

$$R_t = (\text{equity}_t - \text{equity}_{\{t-1\}}) - \eta \cdot \text{inv}_t^2$$

Burada $\eta = 0.001$ envanter ceza katsayısıdır (η ablasyonu ile optimize edilmiştir). Kodda ek bir skew cezası terimi ($c \cdot |m|$) bulunmakla birlikte, ana deneylerde $c = 0$ olarak sabitlenmiş ve bu terim etkisiz bırakılmıştır.

Ek olarak, η 'nın rejime bağlı kılındığı bir varyant denenmiştir: $\eta_L = 0.0005$, $\eta_M = 0.001$, $\eta_H = 0.0025$ ($\eta_H = 5 \times \eta_L$). Bu konfigürasyonda ajan, yüksek volatilité rejimlerinde daha ağır envanter cezasıyla karşılaşmakta; böylece rejime özgü davranış ödül kanalı aracılığıyla doğrudan teşvik edilmektedir. Sonuçlar Section 5.7'de sunulmaktadır.

4.7 Gözlem Uzayı ve Ablasyon Tasarımı

Gözlem uzayı 6 boyutlu ve sabit mimariyle tasarlanmıştır: $obs = [q_norm, \hat{o}, \tau, r_L, r_M, r_H]$. Beş PPO varyantı, `use_sigma` ve `regime_source` parametreleriyle kontrol edilmektedir:

Varyant	use_sigma	regime_source	Gözlemlediği Bilgi
ppo_sigma_only	True	none	$\hat{o}$ + sıfır rejim
ppo_regime_only	False	hat	rejim_hat + sıfır $\hat{o}$
ppo_combined	True	hat	$\hat{o}$ + rejim_hat
ppo_oracle_pure	False	true	rejim_true + sıfır $\hat{o}$
ppo_oracle_full	True	true	$\hat{o}$ + rejim_true

Tüm varyantlar 20 seed, 1M timestep ile eğitilmiş ve OOS test seti üzerinde değerlendirilmiştir.

4.8 PPO Eğitimi ve Değerlendirme Protokolü

Stable-Baselines3 kütüphanesi kullanılarak PPO eğitimi gerçekleştirilmiştir. Hiperparametreler:

Parametre	Değer
total_timesteps	1.000.000
learning_rate	0.0003
n_steps	2048
batch_size	256
n_epochs	10
gamma	0.999
gae_lambda	0.95
clip_range	0.2
ent_coef	0.01

Her seed için episode uzunluğu 8000 adım olup kronolojik eğitim/test bölünmesi %70/%30 (train: 5600, test: 2400 adım) şeklinde uygulanmıştır. Değerlendirme yalnızca test bölümünden gerçekleştirilmektedir. Toplam 20 bağımsız tohum kullanılmıştır (seeds: 1-20). Tezde raporlanan tüm PPO performans değerleri, kronolojik 70/30 eğitim/test bölünmesi ($n_train=5600$, $n_test=2400$) ile çalışan WP5 OOS değerlendirme boru hattından (`src/wp5/job_w5_eval.py`) elde edilmiştir. WP4 yalnızca PPO eğitim altyapısı için bir pilot olarak hizmet etmiştir ve raporlanan sonuçların kaynağı değildir.

4.9 Post-hoc Signal Redundancy Diagnostics

WP5 ve WP6 ana deneylerinden sonra, sinyal yedekliliği yorumunu desteklemek için hafif post-hoc tanı analizleri yürütülmüştür. Bu analizler yeni bir RL projesi veya yeni bir eğitim aşaması değildir: yalnızca donmuş WP2/WP5/WP6 artifact'ları ve `docs/internal/posthoc_signal_analysis/` altındaki yeni özet çıktıları kullanılmıştır. PPO yeniden eğitilmemiş, WP5/WP6 yeniden koşturulmamış ve korumalı evidence CSV/figure artifact'ları değiştirilmemiştir.

Amaç, 'sigma_hat explicit kategorik rejim etiketlerinin ekonomik olarak ilgili bilgisinin çoğunu zaten taşıyor olabilir' yorumuna mekanik destek sağlamaktır; bu analizler birincil keşif deneyi veya causal PPO iç-mekanizma kanıtı olarak tasarlanmamıştır.

source_manifest.csv, kullanılan 11 benzersiz WP2-style sentetik kaynağı listeler; action_curve_alignment.csv ise yalnızca donmuş curve/snapshot hizalaması doğrulanmış action curve'lerinin kullanıldığını kayda geçirir.

Üç tanı bloğu uygulanmıştır: (A) regime_hat etiketinin yalnızca sigma_hat ile tahmin edilebilirliği; (B) sigma_hat gözlemlendikten sonra regime_hat'in gelecek mutlak mid-return için ek tahmin değeri; (C) PPO'nun seçtiği half-spread h ve skew m eylemlerinde, sigma_hat'e eklenen explicit label değişkenlerinin açıklayıcı katkısı. Tüm split'ler kronolojik train/test mantığını korur ve geleceğe bilgi sızıntısı yaratmayacak şekilde kurulmuştur.

Blok	Girdi / Hedef	Yorum
A	sigma_hat -> regime_hat	Observed kategorik etiketin continuous volatility signal'dan ne ölçüde recover edilebildiği.
B	target ~ sigma_hat vs target ~ sigma_hat + regime_hat	Explicit label'in sigma_hat sonrası held-out predictive contribution ölçümü.
C	action ~ sigma_hat vs action ~ sigma_hat + regime_hat	Eylem düzeyinde incremental explanatory gain; causal PPO mechanism proof değildir.

5. SONUÇLAR VE TARTIŞMA

5.1 Ana Deney Sonuçları (20 Tohum, OOS)

Tablo 1, orijinal WP5 deneyinin (ppo_aware vs ppo_blind) out-of-sample sonuçlarını özetlemektedir.


Strateji	Ort. Equity	Std	Ort. Sharpe	inv_p99	Fill Rate
AS	5.05	4.72	0.105	29.95	0.444
Naif	4.49	3.49	0.126	21.20	0.119
ppo_aware	4.10	0.78	0.715	2.00	0.236
ppo_blind	4.42	0.71	0.740	2.05	0.232

Birinci bulgu — PPO'nun Sharpe Üstünlüğü: Her iki PPO varyantı da Sharpe oranı açısından klasik referans stratejilerini belirgin biçimde aşmaktadır ($\sim 6-7\times$). Bu üstünlüğün temel mekanizması envanter kontroldür: PPO varyantları $inv_p99 \approx 2$ lot düzeyinde çalışırken, AS ve naif stratejiler sırasıyla 29.95 ve 21.20 değerlerine ulaşmaktadır. Mutlak equity açısından AS (5.05) ve naif (4.49) stratejilerin PPO varyantlarından (4.10-4.42) yüksek görünmesi, bu stratejilerin geniş spreadlerden yüksek brüt gelir elde etmesinden kaynaklanmaktadır; ancak söz konusu gelir yüksek envanter riski pahasına elde edilmektedir.

İkinci bulgu — Null Sonuç: ppo_aware, Sharpe bazında 20 tohumun 11'inde ppo_blind'i geride bırakmıştır. Sharpe bazında istatistiksel olarak anlamlı fark gözlemlenmemiştir (paired t-test $p = 0.261$); ancak equity metriğinde ppo_blind lehine anlamlı fark mevcuttur

($p = 0.023$). Bu çalışmada risk-adjusted performans ölçütü olarak Sharpe oranı esas alınmaktadır.


Üçüncü bulgu — PPO Varyans Avantajı: PPO varyantlarının equity std değerleri (0.71-0.78) AS (4.72) ve naif (3.49) stratejilerine kıyasla belirgin biçimde düşüktür.



Şekil 1. Out-of-sample performans özeti (20 tohum, ortalama $\pm$ std). Sol: Sharpe oranı. Sağ: envanter riski (inv_p99). Şekil, PPO'nun üstünlüğünün kaynağını görsel olarak ortaya koymaktadır. Sol panelde her iki PPO varyantının Sharpe oranı AS ve Naive stratejileri belirgin biçimde aşmaktadır. Sağ panelde PPO ajanları inv_p99 $\approx$ 2 lot düzeyinde çalışırken klasik stratejiler 20-30 lot envanter taşımaktadır.

Bu null sonuç için üç açıklayıcı hipotez öne sürülmektedir:

- (a) Gözlem uzayında $\hat{\sigma}_t$ değeri hali hazırda mevcut olduğundan, one-hot rejim kodlaması $\hat{\sigma}_t$ 'den türetilmiş bilgiyi yedekli biçimde sunmakta ve marjinal katkı sağlamamaktadır.
- (b) Ödül fonksiyonu rejime özgü davranışı doğrudan teşvik etmediğinden, rejim bilgisini performansa dönüştürmek için sinyal yetersiz kalmaktadır.
- (c) Detector robustness deneyi bu hipotezi geçersiz kılmaktadır: %81.8 doğruluklu HMM dedektörü ile dahi null sonuç korunmaktadır ($p = 0.082$). Dolayısıyla tespit kalitesi belirleyici değildir; açıklayıcı güç (a) hipotezinde yoğunlaşmaktadır.




Şekil 2. Seed bazında PPO-aware ve PPO-blind karşılaştırması (her nokta bir seed, $n=20$). Kesikli çizgi $y=x$ referansıdır. Sol: Sharpe (paired t-test $p=0.261$). Sağ: Final equity (paired t-test $p=0.023$). Sol panelde noktaların $y=x$ çizgisi etrafında simetrik dağılımı Sharpe bazında istatistiksel anlamlılık eşiğine ulaşılmadığını göstermektedir. Sağ panelde ise noktaların çoğunluğunun $y=x$ çizgisinin altında kalması, equity metriğinde PPO-blind'in sistematik avantajına işaret etmektedir.

5.2 Pure Ablation Deneyi (Sinyal Yedekliliği Testi)

Motivasyon: Danışmanın temel eleştirisi, δ 'nin her iki ajanda da gözlem uzayında mevcut olması nedeniyle aware-blind karşılaştırmasının confounded olduğuydı. Bu deneyle, δ 'nin çıkarıldığı ve rejim etiketinin tek başına test edildiği pure ablation gerçekleştirilmiştir.

Tablo 2, 5 varyantın 20 seed ortalamasını göstermektedir.

Varyant	Sharpe (ort. $\pm$ std)	Final Equity (ort. $\pm$ std)	inv_p99 (ort. $\pm$ std)
ppo_sigma_only	0.753 ± 0.111	4.55 ± 0.65	1.9 ± 0.7
ppo_oracle_full	0.722 ± 0.130	4.07 ± 0.61	2.0 ± 0.5
ppo_regime_only	0.698 ± 0.145	4.01 ± 0.68	2.1 ± 1.5
ppo_combined	0.696 ± 0.134	3.91 ± 0.72	1.8 ± 0.5
ppo_oracle_pure	0.684 ± 0.111	3.93 ± 0.60	1.9 ± 0.6
naive	0.127 ± 0.092	4.49 ± 3.49	21.2 ± 12.2
AS	0.105 ± 0.082	5.05 ± 4.72	29.9 ± 12.6



Şekil 3. Beş PPO varyantı için pure ablation özeti (20 tohum, ortalama $\pm$ std). Sol panel Sharpe, orta panel final equity, sağ panel inv_p99 değerlerini göstermektedir. AS ve naive referansları bu görsele dahil edilmemiştir; amaç explicit rejim etiketi, oracle rejim etiketi ve sigma_hat sinyalinin marjinal katkısını PPO varyantları içinde doğrudan karşılaştırmaktır.

Bu görsel, Tablo 2'deki ana örüntüyü özetlemektedir: sigma_only en yüksek Sharpe ortalamasına sahiptir ve oracle_full ya da combined varyantlarının üzerinde anlamlı bir iyileşme gözlenmemektedir. Bu desen, explicit rejim etiketinin sigma_hat üzerinde ek risk-adjusted bilgi taşımadığı yönündeki signal redundancy yorumuyla uyumludur.

Kritik Bulgu: ppo_sigma_only en yüksek Sharpe değerini (0.753) elde etmiştir — oracle_full'ı ($\hat{\sigma} + \text{regime_true}$, Sharpe = 0.722) ve combined'ı ($\hat{\sigma} + \text{regime_hat}$, Sharpe = 0.696) geçmektedir. Mükemmel rejim bilgisi bile $\hat{\sigma}$ 'nin sağladığı bilginin üzerine anlamlı katkı sağlamamaktadır.

5.3 İstatistiksel Testler (Ablasyon)


Tablo 3, 12 karşılaştırmanın eşleştirilmiş t-testi sonuçlarını göstermektedir (n=20 seed, Bonferroni düzeltmesi: $\alpha = 0.01/12 = 0.00083$).

Karşılaştırma	Metrik	t	p-değeri	Cohen's d	Anlamlı?
sigma_only vs combined	sharpe	2.014	5.83e-02	0.450	Hayır
sigma_only vs combined	equity	3.334	3.49e-03	0.746	Hayır
sigma_only vs oracle_full	sharpe	1.651	1.15e-01	0.369	Hayır
sigma_only vs oracle_full	equity	3.789	1.24e-03	0.847	Hayır
oracle_full vs combined	sharpe	1.062	3.01e-01	0.238	Hayır
oracle_full vs combined	equity	0.939	3.60e-01	0.210	Hayır
sigma_only vs regime_only	sharpe	2.283	3.41e-02	0.510	Hayır
sigma_only vs regime_only	equity	4.510	2.40e-04	1.008	EVET
combined vs	sharpe	16.615	8.99e-13	3.715	EVET

AS					
combined vs AS	final_equity	-1.064	3.01e-01	-0.238	Hayır
combined vs naive	sharpe	17.878	2.42e-13	3.998	EVET
combined vs naive	final_equity	-0.728	4.76e-01	-0.163	Hayır

Oracle Paradoksu Özeti: oracle_full vs combined farkı Sharpe'ta $p = 0.301$, equity'de $p = 0.360$ — istatistiksel olarak hiçbir anlamlılık yok. Mükemmel etiket, tahmini etiketten ayırt edilemez.

TOST equivalence test (bounds ± 0.10) confirms practical equivalence between ppo_sigma_only and ppo_oracle_full ($p=0.00067$). The 90% confidence interval for the Sharpe difference is $[-0.001, +0.063]$ — this is the CI that corresponds to the TOST procedure at $\alpha=0.05$ and it lies entirely within the ± 0.10 equivalence bound. The wider 95% CI $[-0.008, +0.069]$ is also contained within the bound. This provides positive evidence that the performance difference is practically negligible, not merely statistically inconclusive.



Şekil 4. Oracle paradoksunun seed bazında görselleştirilmesi. Sol panel doğrudan karşılaştırmayı gösterir: ppo_sigma_only ile ppo_oracle_full Sharpe değerleri aynı test seed'leri üzerinde eşleştirilmiştir (paired t-test $p = 0.115$). Sağ panel oracle_full ile combined varyantlarını karşılaştırır ($p = 0.301$). Kesikli çizgi $y=x$ referansıdır.


Bu şeklin birincil yorumu sol paneldir: mükemmel rejim etiketlerine sahip oracle_full, sigma_only varyantını Sharpe bazında istatistiksel olarak anlamlı biçimde geçememektedir. Dolayısıyla oracle varyantı, dedektör gürültüsü eleştirisini sınırlandıran güçlü bir üst-sınır testi sunar; ancak $p=0.115$ sonucu, kanıtı deterministik bir eşdeğerlik iddiası olarak değil, anlamlı üstünlük bulunmaması olarak yorumlanmalıdır.

5.4 Eylem Analizi (Davranışsal Farklılaşma)

Tablo 4. Rejim Bazında Eylem Dağılımı (Ortalama $\pm$ Std, 20 Tohum)

Strateji	Rejim	Ort. h	Std h	Ort. m	Std m	P(h=5)
AS	L	1.00	0.00	-0.01	0.02	0.000
AS	M	1.00	0.00	-0.02	0.03	0.000
AS	H	1.00	0.00	-0.02	0.03	0.000
Naif	L	2.00	0.00	0.00	0.00	0.000
Naif	M	2.00	0.00	0.00	0.00	0.000
Naif	H	2.00	0.00	0.00	0.00	0.000
ppo_aware	L	1.43	0.63	-0.05	0.22	0.000
ppo_aware	M	1.68	0.72	-0.01	0.25	0.008
ppo_aware	H	1.74	0.71	+0.00	0.22	0.000
ppo_blind	L	1.39	0.47	-0.03	0.24	0.000
ppo_blind	M	1.42	0.41	-0.00	0.23	0.000
ppo_blind	H	1.60	0.42	-0.00	0.17	0.000

ppo_aware ajanı, rejimler arasında sınırlı davranışsal farklılaşma sergilemektedir. Tüm rejimlerde ortalama half-spread $h \approx 1.4$ -1.8 tick aralığında seyretmekte, skew değerleri ise $m \approx 0$ civarında kalmaktadır. ppo_blind ile karşılaştırıldığında anlamlı bir politika ayrışması gözlemlenmemektedir.



Şekil 5. Rejim bazında eylem dağılımı (20 tohum, ortalama $\pm$ std). Üst: half-spread h . Alt: skew m . Sol sütun: PPO-aware. Sağ sütun: PPO-blind. Half-spread h değerleri L'den H'ye hafif artış göstermekte; ancak yüksek varyans nedeniyle bu artış istatistiksel olarak güçlü değildir.


5.5 Rejim Bazlı Performans Analizi

Tablo 5, test döneminde üç volatilité rejiminde (L, M, H) elde edilen strateji performanslarını özetlemektedir.

Not: Rejim bazlı kırılım, gerçek rejim etiketleri (regime_true) üzerinden hesaplanmıştır; ajan ise yalnızca tahmini rejimi (regime_hat) gözlemlemektedir. Bu tablo, ex-post rejim attribution'ı sunmaktadır; ajan karar anında yalnızca regime_hat'i gözlemlemekte olup gerçek rejim bilgisine erişimi bulunmamaktadır.

Strateji	Rejim	Sharpe	inv_p99	Fill Rate
AS	L	0.330	22.26	0.404
AS	M	0.197	27.49	0.438
AS	H	0.038	27.66	0.497
naive	L	0.269	16.35	0.105
naive	M	0.150	18.87	0.115
naive	H	0.143	19.20	0.143
PPO-aware	L	0.927	1.85	0.226
PPO-aware	M	0.799	1.60	0.225
PPO-aware	H	0.464	1.79	0.250
PPO-blind	L	0.924	2.00	0.220
PPO-blind	M	0.814	1.88	0.229
PPO-blind	H	0.526	1.91	0.252

PPO ajanlarının her üç rejimde de AS ve naive baseline'larına kıyasla çok daha düşük envanter riski (inv_p99 $\approx$ 2 vs. 20-28) sergilediği görülmektedir. Her iki PPO ajanı da düşük volatilitte (L) rejiminde en yüksek Sharpe değerlerini kaydetmiştir.



Şekil 6. Volatilitte rejimine göre Sharpe oranı (20 tohum, ortalama $\pm$ std). PPO'nun üstünlüğünün tüm volatilitte rejimlerinde geçerli olduğu görülmektedir. Yüksek volatilitte (H) rejiminde tüm stratejilerin Sharpe değerleri düşmekte; ancak PPO varyantları bu rejimde dahi klasik stratejileri belirgin biçimde geride bırakmaktadır.


5.6 Detector Robustness Analizi

Dedektör	Doğruluk	ppo_aware Sharpe	ppo_blind Sharpe	Sharpe p-değeri
rv_baseline	%60.7	0.718	0.753	0.114
rv_dwell	%60.4	0.716	0.753	0.110
HMM	%81.8	0.719	0.753	0.082

Not: ppo_blind bu tabloda 0.753 Sharpe değeriyle görünmektedir; bu değer, farklı dedektörlerle yeniden eğitilen modellerin (wp5-detector-full run'ı) ortalamasını

yansıtmaktadır. Section 5.1'deki 0.740 değeri ise orijinal wp5-eval-main run'ından elde edilmiştir.

ANOVA testi: $F = 0.003$, $p = 0.997$ — ppo_aware performansı dedektör seçimine göre anlamlı biçimde değişmemektedir. Null sonuç, zayıf tespit kalitesinden kaynaklanmamaktadır.




Şekil 7. Dedektör bazında ortalama Sharpe (20 tohum). PPO-blind Sharpe değeri tüm dedektörlerde 0.753 olarak sabit kalmakta; PPO-aware ise dedektör seçiminden bağımsız olarak ~0.717-0.719 düzeyinde seyretmektedir.

5.7 Rejime Koşullu Envanter Cezası Deneyi

Danışmanın önerisi doğrultusunda, null sonucun ödül tasarımı boyutunda da sınanması amacıyla rejime koşullu envanter cezası deneyi gerçekleştirilmiştir. Sabit $\eta = 0.001$ yerine $\eta_L = 0.0005$, $\eta_M = 0.001$, $\eta_H = 0.0025$ konfigürasyonu kullanılmış; beş varyant 20 tohum, 1M timestep ile eğitilmiştir.

Tablo 6, sonuçları özetlemektedir.

Varyant	Ort. Sharpe	Std Sharpe	Ort. Equity
ppo_sigma_only	0.714	0.119	3.91
ppo_combined	0.629	0.147	3.50
ppo_oracle_full	0.638	0.158	3.38
ppo_oracle_pure	0.578	0.247	3.45
ppo_regime_only	0.513	0.238	3.07



Şekil 8. Rejime koşullu envanter cezası deneyinde PPO varyantlarının Sharpe ve final equity sonuçları (20 tohum, ortalama $\pm$ std). Görsel, sigma_only ile combined varyantları arasındaki eşleştirilmiş karşılaştırmayı özellikle vurgular: Sharpe için $p = 0.0016$, final equity için $p = 0.008$.

Bu görsel, rejime koşullu ödül tasarımının explicit rejim etiketini faydalı hale getirmediğini göstermektedir. combined varyantı hem sigma_hat hem tahmini rejim etiketini gözlemlerken, sigma_only Sharpe bazında istatistiksel olarak daha güçlü kalmaktadır. Bu sonuç ödül kanalı üzerinden yapılan rejim hassaslaştırmasının signal redundancy yorumunu ortadan kaldırmadığını destekler.

Eşleştirilmiş t-testi (ppo_combined vs ppo_sigma_only): Sharpe $p = 0.0016$, Equity $p = 0.008$ — her iki metrikte ppo_sigma_only lehine istatistiksel olarak anlamlı fark. Rejime koşullu η , ppo_combined'in performansını artırmak yerine anlamlı biçimde düşürmüştür. ppo_combined gözlem uzayında $\hat{\theta}$ aracılığıyla zaten rejim bilgisine sahipken, rejime koşullu η bu örtük sinyali gereksiz biçimde pekiştirmiş ve ajan optimizasyonunu zorlaştırmıştır. Bu bulgu, signal redundancy argümanını ödül tasarımı boyutunda da desteklemektedir.

5.8 Model Misspecification Robustness Deneyi

Motivasyon: Mevcut sentetik ortamda fill model parametreleri A ve k tüm rejimler için sabit tutulmaktadır. Bir eleştiri olarak, gerçek piyasalarda yüksek volatilité rejimlerinde likidite dinamiklerinin farklılaşabileceği öne sürülebilir. Bu deneyle, fill parametrelerinin rejime bağlı olduğu daha zorlu bir ortamda null result'ın geçerliliği test edilmektedir.


Ortam uyarısı (retrospektif not): Bu misspec-mild deneyleri tez yazım sürecinin erken bir aşamasında yürütüldüğünden, rejim parametreleri §4.1'de tanımlanan kanonik ortamlara birebir örtüşmemektedir. Misspec-mild koşulları sigma_mult = [0.5, 1.0, 2.0] ve warmup_steps = 400 ile üretilmiştir; kanonik değerler ise sigma_mult = [0.6, 1.0, 1.8] ve warmup_steps = 1000'dir. Bu sapma WP5.5 sinyal denetimi öncesinde yapılan sanity-check sırasında tespit edilmiş, hesaplama maliyeti nedeniyle kanonik parametrelerle yeniden üretim gerçekleştirilmemiştir (bkz. Decisions Log #42, #45). Okuyucunun aşağıdaki tablo ve istatistiklerin bu daha agresif rejim-oranı ortamına ait olduğunu göz önünde bulundurması

gerekir; ana null bulgusu ($\sigma_{\text{only}} \approx \text{oracle_full}$) her iki parametre setinde de aynı yönde raporlanmaktadır.

Tasarım: MMSimulator generic kalmış; env.py içinde her adımda regime_true'ya göre ExecParams override edilmiştir. Mild misspecification parametreleri: L rejimi $A=4.0$, $k=1.8$; M rejimi $A=5.0$, $k=1.5$ (baz değer); H rejimi $A=6.0$, $k=1.2$. Bu parametre konfigürasyonu, yüksek volatilitte rejiminde gerçekçi bir likidite daralmasını değil, PPO ajanlarının değişen dolum dinamiklerine karşı dayanıklılığını test etmeye yönelik adversarial bir parametre şokunu temsil etmektedir. Aynı 5-varyant (σ_{only} , regime_only, combined, oracle_pure, oracle_full), 20 tohum, 1M timestep eğitim protokolü uygulanmıştır.

Tablo 7. Model Misspecification (Mild) OOS Sonuçları (20 Tohum)

Varyant	Ort. Sharpe
ppo_sigma_only	0.685
ppo_oracle_full	0.682
ppo_combined	0.651
ppo_regime_only	0.634
ppo_oracle_pure	0.602



Şekil 9. Mild model misspecification ortamında PPO varyantlarının Sharpe karşılaştırması (20 tohum, ortalama $\pm$ std). Fill parametreleri A ve k rejime bağlı olacak şekilde değiştirilmiştir; sigma_only ile oracle_full arasındaki eşleştirilmiş Sharpe karşılaştırması $p = 0.881$ 'dir.

Bu görsel, model misspecification sonucunu özetlemektedir: rejime bağlı A/k altında sigma_only ve oracle_full neredeyse aynı Sharpe düzeyinde kalmaktadır. Bu bulgu yalnızca bu mild misspecification tasarımı için bir robustness sonucu olarak yorumlanmalıdır; tüm piyasa model yanlış belirlemeleri altında evrensel eşdeğerlik iddiası değildir.

Eşleştirilmiş t-testi sonuçları: ppo_sigma_only vs ppo_oracle_full: $p=0.881$; ppo_sigma_only vs ppo_combined: $p=0.217$; ppo_sigma_only vs ppo_oracle_pure: $p=0.098$. Hiçbir karşılaştırma istatistiksel anlamlılık eşiğine ulaşmamıştır.

TOST equivalence test (bounds ± 0.05) further confirms practical equivalence under model misspecification ($p=0.042$). The 90% confidence interval $[-0.040, +0.048]$ — the CI corresponding to the TOST procedure at $\alpha=0.05$ — lies entirely within the ± 0.05 equivalence bound. The wider 95% CI $[-0.049, +0.057]$ remains within the ± 0.10 bound. Cohen's $d = 0.034$ indicates negligible effect size, strengthening the signal redundancy interpretation across both standard and adversarial environments.

Bu bulgular, signal redundancy argümanının çevresel model parametrelerindeki değişimlere karşı sağlam olduğunu ortaya koymaktadır. Fill dinamiklerinin rejime bağlı olduğu daha zorlu bir ortamda dahi ppo_sigma_only, mükemmel rejim bilgisine sahip oracle_full'dan istatistiksel olarak ayırt edilemez performans göstermiştir ($p=0.881$).

5.9 Manipülasyon Geçerlilik Denetimi

Motivasyon: PPO ajanlarının eğitiminde kullanılan gözlem uzayı sigma_hat ve rejim one-hot bileşenlerini içermektedir. Null sonucu savunulur kılmanın gerekli koşullarından biri, bu sinyallerin taşıdığı bilginin gerçekten ajanın kullanabileceği yapıda olduğunun — ve sinyal kalitesi düşürüldüğünde metriklerin beklendiği gibi bozulduğunun — gösterilmesidir. Aksi hâlde 'rejim etiketi faydasız' ifadesi, etiketin öznitelik olarak hiç bilgi taşımadığı trivial durumdan ayırt edilemez. Bu bölüm, rejim sinyali üzerine uygulanan kontrollü manipülasyonların regresyon/sınıflandırma metriklerinde beklenen etkiyi ürettiğini raporlar.

Yöntem: Kanonik operating point ($dt = 0.2$, $\sigma_{mid_ticks} = 0.8$, $\sigma_{mult} = [0.6, 1.0, 1.8]$, $warmup_steps = 1000$, $rv_window = 50$, $n_steps = 8000$, $tohum = 123$) altında tek bir epizot üretilir. Rolling realized volatility serisi üzerinde beş koşul uygulanır: clean (manipülasyon yok), noisy ($\sigma_{std} = 0.5 \times \sigma_{std}$, yani 0.09 civarı), lagged (5 adım gecikme), coarsened (5 kuantil kovaasına indirgeme, kova ortalamasıyla değiştirme) ve none (sabit fill_value = 0.0). Her koşul için sigma_hat ile regime_true arasındaki Spearman/Pearson korelasyonu, rejim sınıflandırma doğruluğu, ayrışabilirlik (Fisher benzeri skor) ve threshold overlap oranı hesaplanır. Audit iş paketinin kaynak dosyaları: config/w55_audit.json, src/wp5_5/job_w55_audit.py, src/wp5_5/signal_degradation.py, src/wp5_5/signal_audit.py.

Yapısal metrik politikası: 'none' koşulu sabit bir fill değeriyle çalıştığı için classification_accuracy ve threshold_overlap metrikleri bu koşulda yapısal olarak tanımsızdır — değerler sinyal bilgi içeriğini değil, fill değeri ile kalibre edilmiş eşikler arasındaki ilişkiyi yansıtır. Bu iki metrik 'none' koşulunda raporlanmaya devam eder ancak PASS/FAIL değerlendirmesinden çıkarılmıştır (reported-but-not-gated).

Tablo 8. WP5.5 Sinyal Denetim Metrikleri (kanonik operating point, tohum = 123)

Koşul	Spearman	Pearson	Clas. Acc.	Ayrışab.	Thr. Overlap
clean	1.000	1.000	0.400	5093.3	0.300
noisy	0.820	0.894	0.518	4274.3	0.103
lagged	0.977	0.991	0.398	4856.8	0.300
coarsened	0.940	0.877	0.391	5114.1	0.374
none	0.000	0.000	0.548	0.000	0.000

Bulgular: (i) Direction — clean sinyali 'none' baseline'ına karşı Spearman, Pearson ve ayrışabilirlik boyutlarında PASS vermektedir; yapısal olarak tanımsız iki metrik (classification_accuracy ve threshold_overlap) 'none' koşulunda gate dışında bırakılmıştır. (ii) Separation — noisy, lagged ve coarsened koşullarının tümü clean baseline'ından belirgin biçimde sapmakta, yani rejim etiketine uygulanan kontrollü bozulmalar ölçülebilir etki üretmektedir. (iii) Coarsen safety — 5 kovalı ayrıklaştırma, metriklerin üzerinde yıkıcı bir bilgi kaybı yaratmamaktadır. (iv) Monotonicity — 'clean → noisy → lagged → coarsened → none' dizisi boyunca ölçütler yekpare (monotone) bir şiddet eğrisine oturmamaktadır (non-monotone FAIL). Bu sonuç, tek bir sıralama eksenini boyunca artan bozulmadan kaynaklanan yapısal bir başarısızlık değildir; üç degradasyon (gürültü, gecikme, kuantizasyon) sinyal yapısına farklı boyutlarda saldırdığı için ortak bir şiddet ölçütüne indirgenmeleri ölçüt tasarımı düzeyinde tartışmaya açıktır.

Yorum: Denetim, rejim sinyaline dokunan kontrollü manipülasyonların beklenen yönde ölçülebilir etki ürettiğini göstermektedir (direction PASS, separation PASS, coarsen safety PASS). Bu, sinyalin faydasız değil, *taşıdığı bilgi sigma_hat tarafından zaten yansıtıldığı için* RL performansına marjinal katkı sağladığı şeklindeki null-result yorumuyla tutarlıdır. Monotonicity FAIL'i, ayrı tipteki bozulmaların tek bir şiddet ekseninde karşılaştırılmasına dair bir ölçüt tasarımı uyarısı olarak okunmalıdır; WP5.5 run'ın genel önerisi bu nedenle REVIEW düzeyindedir. Audit çıktıları: results/runs/20260422-170037_seed123_wp55-signal-audit_66fc17e/.

Reproducibility notu: config dosyasında noise_std alanı 'auto' değerine ayarlıdır; audit iş paketi koşu sırasında gürültü standart sapmasını $0.5 \times \text{clean_sigma_std}$ (post-warmup) olarak hesaplar. Bu sayede gürültü seviyesi her zaman kanonik sinyal ölçeğine göre sabit oranda kalır ve operating point'e dair güncellemelere otomatik olarak adapte olur. WP5.5 öncesinde yapılan iki drift'li koşu (20260419-214718, 20260419-221930) süpersed edilmiş ve 'results/runs/wp55_audit_archive_note.md' altında arşivlenmiştir.

6. SİNYAL BİLGİLENDİRİCİLİK SÜPÜRMESİ


Bu bölüm, sürekli volatilité sinyalinin (δ_t) artan biçimde bozulduğu beş koşulda (full → noisy → lagged → coarsened → none) PPO ajanının beş gözlem-uzayı varyantı (sigma_only, combined, regime_only, oracle_full, oracle_pure) altında nasıl davrandığını raporlar. Kalibrasyon parametreleri Karar #46'da belirlenmiştir (noisy $\alpha = 0.40$, lagged $k = 20$, coarsened binning). Toplam 4 koşul $\times$ 5 varyant + 1 koşul $\times$ 4 varyant = 24 hücre $\times$ 20 tohum = 480 koşum eğitilmiş ve her koşumda deterministik OOS değerlendirmesi yapılmıştır.

Tarihsel şeffaflık (Karar #47): WP6 başlangıçta, sürekli volatilité sinyali $\hat{\sigma}_t$ bozuldukça explicit kategorik rejim etiketlerinin değeri kazandığı bir rejimi tespit etmek — yani bilgilendiricilik-eşiğı hipotezini test etmek (Karar #46) — amacıyla tasarlanmıştır. Deney bunun yerine, test edilen kalibrasyon aralığı içinde böyle bir rejimin var olmadığını ortaya koymuş ve combined varyantında beklenmeyen bir bozulma örüntüsünü gün yüzüne çıkarmıştır. Bu bölüm her iki bulguyu gözlemlendiğı şekilde raporlar; deney tasarımı ve analiz planı sonuçlar görüldükten sonra değıştirilmemiştir.

Metodolojik simetri notu — TOST kullanımı: WP5, ppo_aware ile ppo_blind arasındaki pratik eşitliğı değeriendirmek amacıyla TOST'u eşitlik yönünde kullanmıştır. WP6 ise TOST'u her iki yönde kullanır: combined ile sigma_only karşılaştırmasında non-eşitlik (Şekil 11) ve combined ile regime_only karşılaştırmasında eşitlik (Şekil 12; n = 20'nin ikinci yön için underpowered olduğı kayda alınarak). Eşitlik testinde $\max(p_{\text{lower}}, p_{\text{upper}}) < \alpha$, non-eşitlik testinde $\min(p_{\text{lower}}, p_{\text{upper}}) < \alpha$ karar kuralı uygulanır.

Tablo 9, beş koşul $\times$ beş varyant matrisinde 20 tohum üzerinden OOS Sharpe ortalamasını ve %95 güven aralığını özetlemektedir (df = 19; t-kritik = 2.093). regime_only ve oracle_pure varyantları yapısı gereğı $\hat{\sigma}_t$ 'yi tüketmediğinden koşul-değışmezdir; bu tohum-bazında doğrulanmıştır (max |fark| = 0). sigma_only varyantı condition = none altında tanımsızdır ($\hat{\sigma}_t$ sıfırlanır).

Koşul	sigma_only	combined	regime_only	oracle_full	oracle_pure
full	0.763 $\pm$ 0.060	0.690 $\pm$ 0.061	0.699 $\pm$ 0.067	0.681 $\pm$ 0.070	0.663 $\pm$ 0.077
noisy	0.756 $\pm$ 0.062	0.713 $\pm$ 0.063	0.699 $\pm$ 0.067	0.674 $\pm$ 0.101	0.663 $\pm$ 0.077
lagged	0.782 $\pm$ 0.045	0.681 $\pm$ 0.054	0.699 $\pm$ 0.067	0.726 $\pm$ 0.069	0.663 $\pm$ 0.077
coarsened	0.783 $\pm$ 0.053	0.691 $\pm$ 0.083	0.699 $\pm$ 0.067	0.745 $\pm$ 0.055	0.663 $\pm$ 0.077
none	tanımsız	0.699 $\pm$ 0.067	0.699 $\pm$ 0.067	0.663 $\pm$ 0.077	0.663 $\pm$ 0.077



Şekil 10. Beş koşul boyunca beş varyantın OOS Sharpe ortalaması (20 tohum, ortalama $\pm$ %95 GA). x-ekseni sinyal bozulması eksenidir (full $\rightarrow$ noisy $\rightarrow$ lagged $\rightarrow$ coarsened $\rightarrow$ none); y-ekseni Sharpe-benzeri performans metriği. sigma_only çizgisi dört bilgilendirici koşulda (0.756–0.783) yatay seyretmektedir; regime_only ve oracle_pure çizgileri yapısal olarak sabittir.

6.1 Reddedilen Hipotez: Bilgilendiricilik-Eşiği

Pre-registered beklenti: $\hat{\sigma}_t$ aşamalı olarak bozuldukça (full $\rightarrow$ noisy $\rightarrow$ lagged $\rightarrow$ coarsened $\rightarrow$ none), sigma_only ile combined arasındaki Sharpe farkı monoton biçimde daralmalı; sigma yeterince gürültülü hale geldiğinde kategorik rejim etiketi anlamlı bilgi katmaya başlamalıdır. Bu hipotez WP5'in null sonucunu — explicit rejim etiketlerinin $\hat{\sigma}_t$ 'nin halihazırda taşıdığı bilgiyle yedekli kaldığı bulgusunu — yöntemsel olarak izleyen bir testtir (Karar #46).


Gözlem (Şekil 10, Tablo 9): sigma_only varyantı dört bilgilendirici koşulda 0.756–0.783 aralığında esasen sabit kalır; sigma_only ile combined arasındaki fark 0.06–0.10 Sharpe-benzeri bandında durur ve monoton bir daralma sergilemez. Bu, pre-registered hipotezin reddedildiği anlamına gelir: test edilen kalibrasyon aralığı içinde, sigma'nın bozulması combined varyantının sigma_only'yi yakalamasına yol açmaz.

Kalibrasyon aralığı uyarısı: Test edilen kalibrasyon aralığı içinde (Karar #46: noisy $\alpha = 0.40$, lagged $k = 20$, coarsened binning), hiçbir bozulma koşulu, explicit kategorik etiketlerin faydalı hale geldiği bir rejim üretmemiştir. Daha agresif bozulmalar (örn. $\alpha = 0.80$ veya $k = 50$) bu süpürmede test edilmemiştir ve bunlar ekarte edilemez. Dolayısıyla 'sigma_only düz' bulgusu, seçilmiş kalibrasyon bandına ilişkin bir ifadedir; tüm sigma bozulmaları için evrensel bir iddia değildir. Noisy condition'un α değeri, tüm post-warmup standart sapması kullanılarak kalibre edilmiştir; yalnızca eğitim verisi kullanılarak yeniden kalibre

edildiğinde α tahmini olarak <%10 oranında kayacaktır. Bu kayma, §5.2'de raporlanan yönsel bulguların (combined < sigma_only, Cohen's dz arası -0.57 ile -0.91) sağlam kaldığı aralık içindedir.

6.2 Beklenmeyen Bulgu: combined Varyantının Yönsel Düşüşü

Süpürme planlanmamış bir bulguyu ortaya çıkarmıştır: combined varyantı dört bilgilendirici koşulun tümünde sigma_only'nin altında yönsel olarak konumlanmaktadır. Tohum-bazında eşleştirilmiş analiz (Şekil 11, summary_paired_combined_vs_sigma.csv): her koşulda 20 tohumun 15-18'i kimlik çizgisinin ($y = x$) altında yer alır; eşleştirilmiş t-testi p-değeri her dört koşulda 0.05'in altındadır; Cohen's dz orta-büyüklikten büyüğe (-0.57'den -0.91'e) uzanır.



Şekil 11. Tohum-bazında combined vs sigma_only karşılaştırması (her panel bir koşul, her nokta bir tohum, $n = 20$). Kesikli çizgi $y = x$ referansdır. Noktaların büyük çoğunluğunun $y =$

x'in altında kalması, combined varyantının seed-by-seed temelinde sigma_only'nin altında yönsel olarak yer aldığını gösterir.

Tablo 10. combined vs sigma_only — Eşleştirilmiş Tohum İstatistikleri

Koşul	n_below	mean_diff	paired t p	Cohen's dz	TOST p (non-eşitlik)	$\delta=0.05$ 'te red
full	15/20	-0.073	0.012	-0.621	0.198	Hayır
noisy	15/20	-0.044	0.020	-0.568	0.640	Hayır
lagged	18/20	-0.101	0.00064	-0.912	0.027	Evet
coarsened	15/20	-0.092	0.0088	-0.653	0.099	Hayır


Hedge — Yönsel vs pratik karakterizasyon: Yön dört koşulda da sağlamdır (paired t < 0.05, dz orta-büyük). Ancak büyüklük yalnızca lagged koşulunda pratik anlamlılık eşliğini ($\delta = 0.05$ Sharpe-benzeri) aşar (mean_diff = -0.101, TOST non-eşitlik p = 0.027). Diğer üç koşulda farkın 90% güven aralığı eşitlik bandına temas eder. Bu nedenle bölüm boyunca 'yönsel olarak sigma_only altında' ifadesi tercih edilmiş, 'tutarlı biçimde' veya 'zararlı' gibi nitelemelerden kaçınılmıştır.

Bu örüntü pre-registered yönün tersidir: 'sigma bozuldukça rejim etiketleri faydalı hale gelir' değil, 'rejim etiketleri sigma ile birlikte sunulduğunda combined performansı yönsel olarak sigma_only'nin altına iter' biçiminde tezahür eder. Bu örüntüye bölüm boyunca ****kategorik-kanal performans bozulması**** (categorical-channel degradation) diye atıfta bulunulur. Bu, mekanizma yüklü değil, betimleyici bir etikettir.

6.3 Yorumun Hassasiyeti: Anlam-Eşitliği vs Politika-Eşitliği

İkinci bir tohum-eşleştirilmiş analiz, combined varyantının none-koşul davranışına (yani regime_only'ye) deterministik biçimde çöküp çökmediğini sınar. Cevap: hayır. Mean diff'ler dört koşulda da küçüktür ($|\text{mean_diff}| \leq 0.018$, üç tanesinde işaret negatif), ancak varyans heterojendir.

Paired-seed comparison: combined vs regime_only across conditions



Şekil 12. Tohum-bazında combined vs regime_only karşılaştırması (her panel bir koşul, her nokta bir tohum, $n = 20$). Şekil 11'in aksine noktalar $y = x$ etrafında dağılır; ortalama farklar küçüktür ancak tohum-bazında eşleşme deterministik değildir — policy'ler aynı per-tohum fonksiyonu öğrenmemektedir.

Tablo 11. combined vs regime_only — Eşleştirilmiş Tohum İstatistikleri ve Varyans Yan-Çıktısı

Koşul	mean_diff	paired t p	TOST p (eşitlik)	std_combined	std_regime_only	std_diff
full	-0.009	0.791	0.128	0.130	0.143	0.155
noisy	+0.013	0.685	0.137	0.134	0.143	0.145
lagged	-0.018	0.535	0.136	0.114	0.143	0.127
coarsened	-0.008	0.814	0.123	0.177	0.143	0.156

TOST eşitliği $\delta = 0.05$ düzeyinde $n = 20$ tohumda formel olarak kurulamamıştır** (tost_p ≈ 0.12 – 0.14 , dört koşulda da $\alpha = 0.05$ 'i geçmez). Gözlenen std_diff ≈ 0.13 – 0.16 ile bu tasarım mevcut tohum sayısında ancak yaklaşık ± 0.07 – 0.08 büyüklüğündeki minimum tespit edilebilir eşitlik bandını saptayabilir; ± 0.05 değil. Bu nedenle Şekil 12 sonucu 'underpowered, etkinin yokluğu değil' olarak okunmalıdır. Muhafazakâr ifade: 'combined ortalaması, regime_only ortalamasından yaklaşık ± 0.07 bandında ayırt edilemezdir' — ' $\delta = 0.05$ 'te eşittir' DEĞİL.

Varyans yan-çıktısı eşitlik tablosunu zenginleştirir: std_diff > std_regime_only dört koşulun üçünde (full, noisy, coarsened) gözlenir. Bu, combined ile regime_only policy'lerinin tohum-eşleşmiş düzeyde aynı fonksiyonu öğrenmediğine işaret eder; etki anlam-düzeyinde eşitliğe yakın olsa da policy-düzeyinde eşitliğe değildir. coarsened panelinde std_combined = 0.177 ile en yüksek değere ulaşır; bu, panel üzerinde görülen birkaç yüksek-Sharpe tohumdan kaynaklanmaktadır.

Mekanizma kimliklendirilmemiştir. Veri çeşitli olası mekanizmalarla (gradyan girişi, kapasite tahsisi, optimizasyon gürültüsü, veya başka faktörler) tutarlıdır; ancak bu deneyden tek başına hangi mekanizmanın işlediği saptanamaz. Bu nedenle bölüm boyunca 'kategorik-kanal performans bozulması' betimleyici etiketi kullanılmış; mekanizma yüklü terimlerden (örn. 'representation-level effect', 'encoding-interference') kaçınılmıştır. Mekanizma ayrımı, bu deneyin kapsamı dışında kalan ek deneylerle (örn. ablation study, gradient norm tracking, ya da Bayesian linear probing) ele alınmalıdır.

Kapanış: Explicit rejim etiketleri ancak rejim sinyali gözlem uzayında halihazırda örtük olarak mevcut değilse fayda sağlamaktadır — bu, WP5 ana null sonucunun ifadesidir (Bulgu 2). WP6, $\hat{\sigma}_t$ bozulduğunda dahi kategorik kanalın yarar kazanmadığını ve bu deneysel ortamda sürekli kanalın yanına eklendiğinde performansı yönsel olarak düşürdüğünü göstererek bu bulguyu genişletmektedir. 'Bu deneysel ortamda' kaydı bilinçli bir savunma kayıdır: bulgu Karar #46'da belirlenen kalibrasyon bandına ilişkindir; kategorik kanalın faydalı olabileceği daha agresif bozulma rejimleri gelecek çalışmaya bırakılmıştır.

6.4 Post-hoc Signal Redundancy Diagnostics

WP6 sonrasında yürütülen post-hoc diagnostics, sinyal-yedekliliği yorumunu ana deneyleri yeniden koşturmadan sınavan üç yardımcı test sunar. Kaynak dosyalar predictability_summary.md / predictability_metrics.csv, incremental_value_summary.md / incremental_metrics.csv / model_comparison_table.csv, action_explanation_summary.md / action_model_metrics.csv ve final_signal_redundancy_assessment.md içinde saklanmaktadır. Bu bölüm, bu çıktıları ana metin içinde destekleyici evidence olarak raporlar.

Regime recoverability sonucu çok güçlüdür: source-calibrated modelde regime_hat yalnızca sigma_hat kullanılarak neredeyse tamamen recover edilebilmektedir (balanced accuracy = 0.9998, NMI = 0.9987, macro F1 = 0.9998). Bu bulgu beklenen yöndedir: regime_hat zaten rolling-volatility temelli thresholding ile üretildiği için, kaynak-içi kalibrasyonla sigma_hat'ten yüksek doğrulukla tahmin edilebilir.

İkinci tanı, sigma_hat gözlemlendikten sonra explicit regime_hat etiketinin gelecek adım mutlak mid-return tahminine ne kattığını ölçer. Model B (sigma_hat + regime_hat), Model A'ya (sigma_hat) göre held-out R^2 'yi yalnızca +0.000159 değiştirmiştir; MAE değişimi +0.000103, RMSE değişimi -0.000031'dir. Eğitim kümesinde ek step-function terimler istatistiksel olarak seçilebilir olsa da, held-out predictive gain pratik olarak çok küçüktür.

Üçüncü tanı daha sınırlı ve daha temkinli okunmalıdır. Donmuş WP5 curve CSV'leri yalnızca run-level WP2 snapshot ile regime_hat dizisi tam hizalanabildiğinde kullanılmıştır; bu nedenle action analizi 8 hizalanmış curve ile sınırlıdır. Basit sigma-only action modelleri h için ortalama $R^2 = 0.026$, m için ortalama $R^2 = -0.102$ üretmiştir; bu, PPO action'larının özellikle skew tarafında sigma_hat tarafından tamamen açıklanmadığını gösterir. Buna karşın explicit label eklemek incremental R^2 'yi h için -0.002, m için +0.003 değiştirmiştir; yani label'ın ek açıklayıcı kazancı sınırlıdır.

Tanı	Ana sayı	Okuma
A: regime_hat recoverability	Balanced accuracy 0.9998; NMI 0.9987	Observed regime_hat source-calibrated sigma_hat'ten neredeyse tamamen recover edilebilir.
B: incremental prediction	$\Delta R^2 +0.000159$; $\Delta MAE +0.000103$; $\Delta RMSE -0.000031$	sigma_hat sonrası explicit label'ın held-out predictive contribution'ı çok küçüktür.
C: action explanation	$\Delta R^2 h -0.002$; $\Delta R^2 m +0.003$	Action-level evidence mixed; limited incremental label gain, causal mechanism proof değil.

Toplu yorum: Post-hoc diagnostics further support the signal-redundancy interpretation. In the tested synthetic setting, observed categorical regime labels are highly recoverable from source-calibrated sigma_hat and add only limited held-out predictive value once sigma_hat is observed. Action-level regressions show limited incremental explanatory gain from explicit labels, but they do not establish a causal internal PPO mechanism.

7. SONUÇ

Bu çalışma, volatilité rejimleri altında pekiştirmeli öğrenme tabanlı piyasa yapıcılığını araştırmaktadır. Temel bulgular:

Bulgu 1 — PPO üstünlüğü: Tüm PPO varyantları Sharpe oranı açısından Avellaneda-Stoikov ve naif referans stratejilerini yaklaşık 6-7 kat geçmiştir. Bu üstünlüğün temel kaynağı envanter yönetimi verimliliğidir: PPO inv_p99 ≈ 2 lot, baseline'lar 20-30 lot.

Bulgu 2 — Null Sonuç: Rejim bilgisinin performansı artırdığı hipotezi istatistiksel olarak desteklenmemiştir. Sharpe bazında istatistiksel olarak anlamlı fark gözlemlenmemiştir (paired t-test $p = 0.261$); equity metriğinde ppo_blind lehine anlamlı fark mevcuttur ($p = 0.023$). Bu null sonuç, gözlem uzayında hali hazırda bulunan $\hat{\theta}_t$ 'nin rejim bilgisini örtük olarak içermesiyle açıklanmaktadır.

Bulgu 3 — Pure Ablation (Sinyal Yedekliliği Testi): ppo_sigma_only en yüksek performansı elde etmiştir — mükemmel rejim etiketlerine sahip oracle_full ajanı dahi sigma_only'yi Sharpe bazında istatistiksel olarak anlamlı biçimde geçememiştir ($p = 0.115$). Bonferroni-düzeltilmiş eşik altında equity farkı da istatistiksel olarak anlamlı kabul edilmemiştir.

Bulgu 4 — Dedektör Bağımsızlığı: Null sonuç, %60.4'ten %81.8'e kadar üç farklı dedektör performansında tutarlı biçimde korunmuştur (ANOVA: $F = 0.003$, $p = 0.997$).

Bulgu 5 — Rejime Koşullu Envanter Cezası: Basit rejime koşullu envanter cezası ($\eta_H = 5 \times \eta_L$), explicit rejim bilgisini faydalı hale getirmemiştir; sigma_only varyantı istatistiksel olarak anlamlı biçimde güçlü kalmıştır ($p = 0.0016$).

Bulgu 6 — Model Misspecification Robustness: Fill model parametrelerinin (A, k) rejime bağlı kılındığı zorlaştırılmış ortamda da null sonuç geçerliliğini korumuştur. ppo_sigma_only yine en yüksek performansı göstermiş; oracle_full ile aradaki fark istatistiksel olarak anlamsız kalmıştır ($p=0.881$). Bu bulgu, signal redundancy argümanının çevresel koşullara karşı sağlamlığını (robustness) doğrulamaktadır.

Bulgu 7: Sinyal informativeness sweep'i (WP6), sigma_hat'in bozulduğu rejimlerde explicit kategorik regime label'larının değer kazanacağı hipotezini reddetti. Test edilen kalibrasyon aralığında, kategorik kanal sigma_only baseline'ının altına yönsel olarak çekti (tüm dört informative condition'da Cohen's d arası -0.57 ile -0.91; pratik anlamlılık $\delta=0.05$ yalnızca lagged condition'da). Kategorik ve sürekli kanalların birlikte kullanılması, bu deneysel ortamda performansı iyileştirmedi.

Bulgu 8 — Post-hoc Signal Redundancy Diagnostics: Donmuş artifact'lar üzerinde yürütülen tanı analizleri, observed regime_hat etiketinin source-calibrated sigma_hat'ten neredeyse tamamen recover edilebildiğini ve sigma_hat sonrası held-out predictive contribution'ın çok sınırlı kaldığını göstermiştir. Action-level regressions explicit label'in incremental explanatory gain'inin sınırlı olduğunu gösterse de, PPO'nun içsel causal mekanizmasını kanıtlamaz.

Sonuç olarak, test edilen sentetik HFMM ortamında explicit categorical regime labels, policy'ye zaten sunulan continuous volatility signal'ın ötesinde robust incremental value sağlamamaktadır. Bu ifade ortam ve kalibrasyon bandı ile sınırlıdır; labels'ın sıfır bilgi içerdiği veya tüm piyasa ortamlarında işlevsiz olduğu iddia edilmemektedir.

Gelecek Çalışmalar

- (1) Basit rejime koşullu envanter cezası denendi ve fayda sağlamadı; daha zengin rejime koşullu ödül tasarımları gelecekte incelenebilir.
- (2) Model misspecification strong variant — daha sert parametre farklılaşması ($L: A=3.0/k=2.0, H: A=8.0/k=1.0$) ile robustness testinin genişletilmesi.
- (3) Paper yayını: iyi nitelendirilmiş null result ile kontrollü RL vs. klasik piyasa yapıcılığı kıyaslaması.

(4) Daha agresif sinyal bozulması: WP6 sweep'i kalibrasyon aralığında ($\alpha=0.40$ noisy, $k=20$ lagged, coarsened binning) σ_{hat} 'in monotonic decay'ini göstermedi. Daha agresif bozulmalar (örn. $\alpha=0.80$, $k=50$) bu çalışmanın kapsamı dışındadır; kategorik kanalın değeri kazandığı bir rejim mevcutsa, bu aralıkta ortaya çıkabilir.

KAYNAKLAR

- [1] Avellaneda, M., & Stoikov, S. (2008). High-frequency trading in a limit order book. *Quantitative Finance*, 8(3), 217-224.
- [2] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*.
- [3] Spooner, T., Fearnley, J., Savani, R., & Koukorinis, A. (2018). Market making via reinforcement learning. In *Proceedings of AAMAS* (pp. 434-442).
- [4] Raffin, A., Hill, A., Gleave, A., Kanervisto, A., Ernestus, M., & Dormann, N. (2021). Stable-baselines3: Reliable reinforcement learning implementations. *JMLR*, 22(268), 1-8.
- [5] Cont, R. (2001). Empirical characteristics of asset returns: Stylized facts. *Quantitative Finance*, 1(2), 223-236.
- [6] Hamilton, J. D. (1989). A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2), 357-384.
- [7] Guéant, O., Lehalle, C.-A., & Fernandez-Tapia, J. (2013). Dealing with the inventory risk: a solution to the market making problem. *Mathematics and Financial Economics*, 7, 477-507.
- [8] Fodra, P., & Labadie, M. (2012). High-frequency market-making with inventory constraints and directional bets. *Preprint, arXiv:1206.4810*.
- [9] Fodra, P., & Labadie, M. (2013). High-frequency market-making for multi-dimensional Markov processes. *Preprint, arXiv:1303.7177*.
- [10] Spooner, T., & Savani, R. (2020). Robust market making via adversarial reinforcement learning. *Proceedings of the Twenty-Ninth International Joint Conference on Artificial Intelligence*, 4590-4596.
- [11] Gašperov, B., & Kostanjčar, Z. (2021). Market making with signals through deep reinforcement learning. *IEEE Access*, 9, 61611-61622.
- [12] Gašperov, B., Begušić, S., Posedel Šimović, P., & Kostanjčar, Z. (2021). Reinforcement learning approaches to optimal market making. *Mathematics*, 9(21), 2689.

[13] Gašperov, B., & Kostanjčar, Z. (2022). Deep reinforcement learning for market making under a Hawkes process-based limit order book model. IEEE Control Systems Letters, 6, 2485-2490.

[14] Zimmer, R., & Costa, O. L. V. (2025). Reinforcement learning-based market making as a stochastic control on non-stationary limit order book dynamics. Preprint, arXiv:2509.12456.

[15] Lakens, D. (2017). Equivalence tests: A practical primer for t tests, correlations, and meta-analyses. Social Psychological and Personality Science, 8(4), 355-362.

[16] Lakens, D., Scheel, A. M., & Isager, P. M. (2018). Equivalence testing for psychological research: A tutorial. Advances in Methods and Practices in Psychological Science, 1(2), 259-269.

Appendix B: Source Code File Index

This appendix lists all active source code files in the project repository. Files are organized by module.

Dosya Yolu	Açıklama
run.py	Ana iş paketi dispatcher'ı
src/run_context.py	RunContext, logger, seed yönetimi, config snapshot
src/w0_smoke.py	WP0 smoke test
src/w1_as_baseline.py	Avellaneda-Stoikov baseline stratejisi
src/w1_compare.py	WP1 strateji karşılaştırması
src/w1_naive_sweep.py	Naive sabit-spread sweep deneyi
src/w3_sanity.py	Gymnasium ortamı sanity check
src/wp1/sim.py	Piyasa simülatörü (ABM + Poisson dolum modeli)
src/wp2/synth_regime.py	Sentetik rejim üretimi (Markov zinciri)
src/wp2/job_w2_synth.py	WP2 job entry
src/wp2/compare_detectors.py	Rejim dedektörü karşılaştırması
src/wp3/env.py	Gymnasium MMEEnv ortamı
src/wp4/job_w4_ppo.py	PPO eğitimi (Stable-Baselines3)
src/wp5/job_w5_eval.py	Out-of-sample değerlendirme (20 tohum)
src/wp5/job_w5_ablation_eta.py	η envanter ceza katsayısı ablasyon deneyi
src/wp5/job_w5_ablation_skew.py	Skew penalty ablasyon deneyi
src/wp5/job_w5_detector_compare.py	Detector robustness deneyi (120 model)
src/wp5/analyze_actions.py	Eylem dağılımı analizi
src/wp5/figure_thesis.py	Tez figürlerinin üretimi
src/wp5/figure_thesis_23.py	Model misspecification ve eta-regime ek figürlerinin üretimi (legacy dosya adı korunmuştur)
src/wp5/stats_detector_robustness.py	İstatistiksel testler (paired t-test ve ANOVA)

scripts/gen_thesis_docx.py	Tez DOCX üretim scripti
scripts/gen_thesis_draft.js	Tez taslak üretim scripti (Node.js)